燕 山 大 学

本科毕业设计（论文）中期报告

课题名称：基于深度图神经网络的板状结构超声损伤定位方法

学　　院：电气工程学院

年级专业：22 级检测技术及仪器

学生姓名：游寅龙

指导教师：温银堂

填写日期：2026 年 04 月 14 日

一、任务书中本阶段工作目标与任务要求

1.1 进行相关科学实验，阐述实验方案，论证分析实验方案的合理性

依据超声导波在板材结构中的传播机理与损伤作用规律，从弹性动力学理论及信号系统分析的角度，严密论证计算方案对后续模型训练与损伤反演的有效性与科学合理性。

1.2 设计过程中具有批判性思维和创新意识，能够对已有方法做出评判、改进或创新

在深入剖析传统时频分析与常规深度学习方法于导波信号处理中存在的局限的基础上，展现批判性思维与创新意识。重点在于对现有注意力机制与图神经网络架构做出针对性评判，并提出融合先验物理特征的改进策略或全新设计，以增强模型对复杂损伤特征的捕捉与解释能力。

1.3 掌握超声导波的探测原理及图神经网络的相关算法，了解其实际应用需求

深化对超声导波探测物理原理的理解与掌握，同时研习图神经网络及自注意力机制的核心算法。在掌握基础理论之外，洞悉二者在实际工程应用中的互补需求，探索将导波传播的物理约束形式化为图结构先验与特征变换算子的具体途径。

二、目前已完成任务情况

2.1 基础理论建立

2.1.1 多头注意力机制

注意力机制的设计灵感源于神经认知科学中的“选择性注意”理论。该理论指出，人类在面对海量信息时，会本能地将认知资源聚焦于与当前任务最相关的部分，从而显著提升信息处理的效率与决策的准确性。受此启发，研究者将这一生物现象形式化为可计算的注意力模型。对于给定的输入特征序列 $\mathbf{X}=\{x_1,x_2,\cdots,x_n\}$，注意力分配过程可表述为：

$$e_i=\mathrm{score}(x_i,q) \tag{1}$$

$$\alpha_i=\frac{\exp(e_i)}{\sum_{j=1}^{n}\exp(e_j)} \tag{2}$$

其中，q 表示查询向量，$\mathrm{score}(\cdot)$ 为得分函数，用于度量输入特征与查询之间的相关性。最终，注意力机制的输出由输入特征依所得权重加权求和得到：

$$\mathrm{Attention}(\mathbf{A})=\sum_{i=1}^{n}\alpha_i x_i \tag{3}$$

在此基础上，进一步扩展了单一注意力函数的表达能力，多头注意力机制作为 Transformer 架构的核心组件被提出。该机制通过并排执行多个独立的注意力计算，使模型能够在不同的表示子空间中联合捕捉序列内部的复杂依赖关系。其数学形式

可描述如下，首先，对于输入的查询矩阵$\mathbf{Q}$、键矩阵$\mathbf{K}$和值矩阵$\mathbf{V}$，通过h组独立学习的线性投影将其映射到不同的子空间：

$$\mathbf{h}_i = f\left(\mathbf{W}_i^{(q)}\mathbf{Q}, \mathbf{W}_i^{(k)}\mathbf{K}, \mathbf{W}_i^{(v)}\mathbf{V}\right) \tag{4}$$

其中$\mathbf{W}_i^{(q)}$、$\mathbf{W}_i^{(k)}$与$\mathbf{W}_i^{(v)}$为可学习的参数矩阵，而函数$f(\cdot)$表示注意力汇聚操作。获得所有h个头的输出$\mathbf{h}_1,\ldots,\mathbf{h}_h$之后，多头注意力机制通过拼接各头结果并施加一个线性变换$\mathbf{W}_o$生成最终输出

$$\text{MultiHead}(\mathbf{Q},\mathbf{K},\mathbf{V}) = \mathbf{W}_o\begin{bmatrix}\mathbf{h}_1\\ \vdots \\ \mathbf{h}_h\end{bmatrix} \tag{5}$$

该结构使得模型能够同时从不同角度关注输入信息，从而显著增强了对序列内多样化依赖关系的建模能力。

2.1.2 图卷积神经网络

图卷积神经网络是一类专为处理图结构数据而设计的深度学习模型，能够有效应对社交网络、交通路网、分子拓扑等非欧氏空间中的复杂数据关系。通过引入“局部连接”与“权重共享”的卷积思想，该模型实现了对图结构信息的高效特征提取与鲁棒表示学习。

图作为一种由顶点和边构成的数学结构，可形式化地表示为$\mathcal{G} = \{\mathbf{V}, \mathbf{E}\}$，其中$\mathbf{V}$为顶点集合，$\mathbf{E}$为边集合。进一步地，图的连接关系可通过邻接矩阵$\mathbf{A}$与度矩阵$\mathbf{D}$加以刻画：

$$A_{ij} = \begin{cases}1, & \text{if } (v_i, v_j) \subseteq \mathbf{E}\\ 0, & \text{otherwise}\end{cases} \tag{6}$$

$$D_{ii} = \sum_j A_{ij} \tag{7}$$

图卷积神经网络的核心思想在于通过聚合邻域节点的信息来迭代更新当前节点的特征表示。基于谱图理论，经典的图卷积操作通常借助图的拉普拉斯矩阵$\mathbf{L} = \mathbf{D} - \mathbf{A}$来定义。具体而言，拉普拉斯矩阵可进行如下特征分解：

$$\mathbf{L} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^\top \tag{8}$$

其中，$\mathbf{U}$为特征向量矩阵，$\mathbf{\Lambda}$为由特征值构成的对角矩阵。在图傅里叶域中，对于信号$\mathbf{x}$的卷积运算可表达为滤波器g_θ与信号的乘积：

$$g_\theta * \mathbf{x} = \mathbf{U}g_\theta(\mathbf{\Lambda})\mathbf{U}^\top\mathbf{x} = g_\theta(\mathbf{L})\mathbf{x} \tag{9}$$

然而，上述谱域卷积依赖于拉普拉斯矩阵的特征分解，计算代价高昂，难以直接应用于大规模图。为降低复杂度，研究者进一步采用归一化拉普拉斯矩阵$\mathbf{L}_{\text{sym}}$来近似卷积传播过程：

$$\mathbf{y} = g_\theta(\mathbf{L}_{\text{sym}})\mathbf{x} = g_\theta(\widetilde{\mathbf{D}}^{-\frac{1}{2}}\widetilde{\mathbf{A}}\widetilde{\mathbf{D}}^{-\frac{1}{2}})\mathbf{x} \tag{10}$$

据此，图卷积网络经典的逐层传播规则可表述为：

$$\mathbf{H}^{(l+1)}=\sigma(\widetilde{\mathbf{D}}^{-\frac{1}{2}}\widetilde{\mathbf{A}}\widetilde{\mathbf{D}}^{-\frac{1}{2}}\mathbf{H}^{(l)}\mathbf{W}^{(l)}) \tag{11}$$

式中，$\widetilde{\mathbf{A}}=\mathbf{A}+\mathbf{I}_N$ 表示添加了自环的邻接矩阵，用以保留节点自身的特征信息；$\widetilde{\mathbf{D}}$ 为 $\widetilde{\mathbf{A}}$ 对应的度矩阵；$\mathbf{H}^{(l)}$ 为第 l 层的节点特征矩阵；$\mathbf{W}^{(l)}$ 是该层可训练的权重矩阵；$\sigma(\cdot)$ 代表非线性激活函数。该设计在保留图拓扑结构先验的同时，实现了高效且可扩展的半监督节点表示学习。

2.2 问题定义

在结构健康检测与导波无损检测的背景下，本课题考虑一个由 M 个探头构成的监测系统，如图 1 所示。

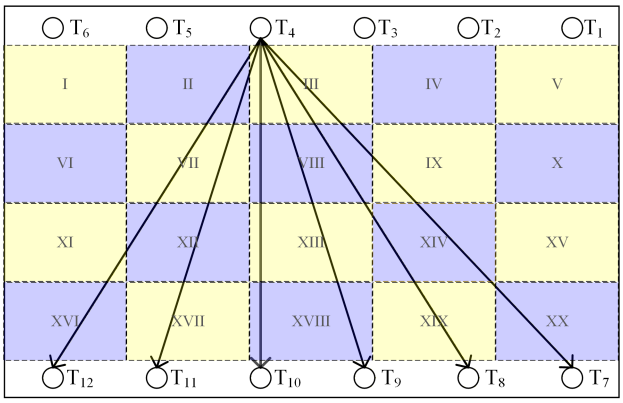


图 1 检测系统示意图

这些探头对称布置于板材结构的上下两侧，从而形成 $N=M(M-1)/2$ 个独立的测量信道。每个信道对应由发射探头 T_i 激励、接收探头 T_j 采集的导波传播信号 $x^{(i,j)}(t)$，其中 $0\le i<j<M$ 。从物理角度看，信号 $x^{(i,j)}(t)$ 可视为对总波场 $\vec{u}$ 在接收探头位置处的离散采样。给定某一时间窗口内的观测数据矩阵 $\mathbf{X}_{0:L-1}\in\mathbb{R}^{N\times L}$，其中 L 表示窗口长度，元素 $x_\tau^{(i,j)}$ 表示第 (i,j) 信道在时刻 τ 处的采样值。本研究旨在解决如何从混叠多模态入射波与环境噪声的观测信号 $\mathbf{X}$ 中，准确诊断出板材结构内部是否存在损坏以及损坏所在定位的问题。该问题可表示为学习一个映射函数 $f:\mathbb{R}^{N\times L}\to\hat{\mathbf{y}}$，其中 $\hat{\mathbf{y}}=\{0,1,\cdots,K\}$ 为损坏分类集合，0 表示无损状态，1至 K 分别对应 K 个不同的损坏定位区域。

2.3 物理信息多粒度自注意力机制

在超声导波传播过程中，频散效应导致波包发生畸变，尽管激励信号中各频率分量的频率保持不变，但波数随材质变化，使得波包在折射中难以保持原始完整性。这一现象使得传统数字信号处理方法难以从整体上对信号进行有效处理。然而，频率的不变性为数据驱动方法提供了关键的理论支撑，具体论证如下：

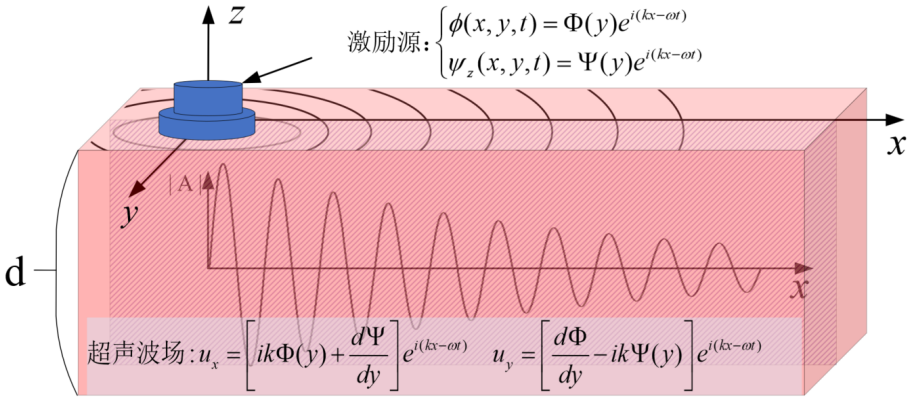


图 2 超声导波分析坐标系

超声导波在板材结构中的传播与损伤相互作用可由波动方程描述，对于各向同性均匀弹性介质，质点运动满足 Navier–Cauchy 方程：

$$\mu\nabla^2\vec{u}+(\lambda+\mu)\nabla(\nabla\cdot\vec{u})=\rho\frac{\partial^2\vec{u}}{\partial t^2} \tag{12}$$

其中 $\vec{u}=(x,y,z,t)$ 为时变位移向量场，μ 和 λ 是材料的 Lamé常数，ρ 为材料密度。针对图 2 所示的导波结构，设 $z=0$ 为其表面边界条件，忽略 z 方向的影响。通过亥姆霍兹分解，时变位移场 $\vec{u}=(x,y,0,t)$ 可表示为标量势 ϕ 与矢量势 $\vec{\psi}=(0,0,\psi_z,t)$ 的组合：

$$\vec{u}=\nabla\phi+\nabla\times\vec{\psi}\qquad\nabla\cdot\vec{\psi}=0 \tag{13}$$

将式(13)代入式(12)求解可得在亥姆霍兹分解下的位移分量的具体形式：

$$\vec{u}=(x,y,0,t)=\left(\frac{\partial\phi}{\partial x}+\frac{\partial\psi_z}{\partial y},\frac{\partial\phi}{\partial y}-\frac{\partial\psi_z}{\partial x},0\right) \tag{14}$$

考虑沿 x 方向传播、频率为 ω 的简谐信号激励，设解具有以下形式：

$$\begin{cases}\phi(x,y,z,t)=\Phi(y)e^{i(kx-\omega t)}\\ \psi_z(x,y,z,t)=\Psi(y)e^{i(kx-\omega t)}\end{cases} \tag{15}$$

则将式(15)代入式(14)得到位移场的频域-波数表达式：

$$\begin{cases}u_x=\left[ik\Phi(y)+\frac{d\Psi}{dy}\right]e^{i(kx-\omega t)}\\ u_y=\left[\frac{d\Phi}{dy}-ik\Psi(y)\right]e^{i(kx-\omega t)}\end{cases} \tag{16}$$

该式表明，在基体材料中，单一频率 ω 激励下，位移场保持简谐波形式，其模态结构及频率成分均不发生变化。然而，实际检测中通常采用宽带脉冲信号作为激励源，此时各频率分量 ω 在复合材料层间界面处可能发生折射与反射，从而激发或转换为多个传播模态，导致接收信号呈现多模态混叠与频散特性：

$$\vec{u}(x,y,t)=\int_{-\infty}^{\infty}\sum_m\vec{A}^{(m)}(y,\omega)e^{i(k^{(m)}(\omega)x-\omega t)}\mathrm{d}\omega \tag{17}$$

其中 $\vec{A}^{(m)}(y,\omega)$ 为第 m 阶模态在频率 ω 处的振幅分布函数。在实际应用中，损伤和噪声分布在未知的频率成分上，频散进一步使得信号在时频域上呈现复杂结构。

针对上述问题，一个关注导波信道间与信道内的物理信息多粒度自注意力机制被提出，其从多粒度角度出发，建模不同尺度下的信号关联模式。

在信道间重要性建模方面，信道与损伤定位之间的关系需被重点关注。具体而言，给定原始信号 $\mathbf{X}\in\mathbb{R}^{N\times L}$，首先将其样本空间划分为 m 个相互独立的子空间。对于第 i 个子空间，通过线性投影分别得到三组变换特征：

$$\mathbf{Q}_i=\mathbf{X}\mathbf{W}_i^{Q}\quad \mathbf{K}_i=\mathbf{X}\mathbf{W}_i^{K}\quad \mathbf{V}_i=\mathbf{X}\mathbf{W}_i^{V} \tag{18}$$

其中 $\mathbf{W}_i^{Q},\mathbf{W}_i^{K},\mathbf{W}_i^{V}\in\mathbb{R}^{L\times d_h}$ 为可学习投影矩阵，$d_h=L/m$ 为每个子空间的维度。在此基础上，计算特征间的相关性矩阵并进行归一化，得到融合权重：

$$\mathbf{h}_i=\mathrm{softmax}\left(\frac{\mathbf{Q}_i\mathbf{K}_i^{\top}}{\sqrt{d_h}}\right)\mathbf{V}_i \tag{19}$$

将 m 个子空间的加权聚合后的特征 $\mathbf{h}_i$ 沿最后一维拼接，得到信道间的增强特征：

$$\mathbf{Y}_t=\mathrm{Concat}(\mathbf{h}_1,\mathbf{h}_2,\ldots,\mathbf{h}_m)\in\mathbb{R}^{N\times L} \tag{20}$$

在信道内重要性建模方面，根据式(17)，需利用频率不变性针对性地突出特定频段。为此，采用离散小波变换将信号映射至时频域，以提取局部振荡特征。选用 Haar 小波基，其尺度函数 $\phi(t)$ 与小波函数 $\psi(t)$ 定义如下：

$$\phi(t)=\begin{cases}1, & 0\le t<1\\ 0, & \text{otherwise}\end{cases} \tag{21}$$

$$\psi(t)=\begin{cases}1, & 0\le t<0.5\\ -1, & 0.5\le t<1\\ 0, & \text{otherwise}\end{cases} \tag{22}$$

对单信道离散信号 $X_n[t]$ 进行单层分解，得到近似系数 $a_n[k]$ 与细节系数 $d_n[k]$：

$$a_n[k]=\sum_{t=1}^{L}X_n[t]\phi(2t-k) \tag{23}$$

$$d_n[k]=\sum_{t=1}^{L}X_n[t]\psi(2t-k) \tag{24}$$

为便于批处理，分解过程可改写为线性变换格式，构造小波变换矩阵 $\mathbf{W}_{\mathrm{DWT}}\in\mathbb{R}^{L\times L}$。每行均由尺度函数与小波函数的离散采样构成，则系数矩阵 $\mathbf{C}_f=\mathbf{X}\mathbf{W}_{\mathrm{DWT}}^{\top}\in\mathbb{R}^{N\times L}$ 的前 $L/2$ 列为近似系数，后 $L/2$ 列为细节系数。将 $\mathbf{C}_f$ 作为变换后的频域特征。采用与式(18)-(20)相同的机制，自适应增强与损伤相关的频率成分，得到更新后的系数 $\mathbf{C}'_f$。最后通过逆离散小波变换重构时域信号：

$$\mathbf{Y}_f=\mathbf{C}'_f\mathbf{W}_{\mathrm{IDWT}}^{\top} \tag{25}$$

其中 $\mathbf{W}_{\mathrm{IDWT}}$ 满足正交性，保证信号完整重构。

为综合信道间与信道内的互补信息，且保留原始信号的底层结构，并引入可学

习的加权残差连接融合策略：

$$\mathbf{Z} = \mathbf{X} + \alpha \cdot \mathbf{Y}_t + \beta \cdot \mathbf{Y}_f \tag{26}$$

其中 $\alpha, \beta \in \mathbb{R}$ 为可学习权重参数，在反向传播中进行优化更新。该设计允许模型自适应地平衡全局依赖与局部振荡特征的重要性。

2.4 物理异构图卷积提取器

在实际检测中，传感器接收到的信号通常表现为基线响应与损伤特征相互混叠的复杂波形。为实现对损伤信息的有效解耦与辨识，需借助合理的机制将二者加以分离。为此，本研究基于先验物理机理，构建了一种物理信息引导的信号分解与反演框架。

对于混杂着损伤特征的基线信号特征 $\mathbf{Z}$ 可被视为 Born 近似框架下各等效散射源强度 $\vec{s}_j$。根据 Born 近似，在弱散射条件下，总的散射波场可近似为各损伤点所等效的散射波场的线性叠加，其数学表达为：

$$\vec{u}^{\mathrm{sc}}(\mathbf{r}, t) \approx \sum_{j=1}^{N_d} \int_0^t \mathcal{G}(\mathbf{r}_i, \mathbf{r}_j, t-\tau) * \vec{s}_j(\tau) \mathrm{d}\tau \tag{27}$$

其中，$\mathcal{G}$ 为格林函数，描述了单位脉冲激励在介质中的传播规律；$\vec{s}_j(\tau)$ 表示第 j 个虚拟损伤节点处的等效源强度。从物理先验的角度而言，损伤的存在等价于在波动方程中引入一虚拟体力项 $\vec{f}_d$，修正后的控制方程可写为：

$$\mu \nabla^2 \vec{u} + (\lambda + \mu) \nabla(\nabla \cdot \vec{u}) - \overrightarrow{f_d} = \rho \frac{\partial^2 \vec{u}}{\partial t^2} \tag{28}$$

依据波场叠加原理，总波场 $\vec{u}$ 可分解为入射波 $\vec{u}^{in}$ 与散射波 $\vec{u}^{sc}$ 之和：

$$\vec{u} = \vec{u}^{in} + \vec{u}^{sc} \tag{29}$$

为实现式(29)所示物理正向过程的逆映射，从接收信号中反演等效源强度 $\vec{s}_j$，本研究构建了一种有向异构图 $\mathcal{G} = \{\mathcal{V}, \mathcal{E}\}$。其中，节点集合 $\mathcal{V}$ 由物理测量节点 $\mathcal{V}_p$ 与虚拟损伤节点 $\mathcal{V}_d$ 共同构成，即 $\mathcal{V} = \mathcal{V}_p \cup \mathcal{V}_d$。$\mathcal{V}_p$ 对应于实际的“激励-接收”探头对，其初始特征由前述物理信息多粒度自注意力机制提取的特征 $\mathbf{Z}$ 进行赋值；$\mathcal{V}_d$ 则代表潜在的损伤位置，其初始特征设为零向量。异构图的边集 $\mathcal{E}$ 严格遵循声束覆盖的物理原理加以定义：仅当虚拟损伤节点 v_j^d 位于物理节点 v_k^p 所对应的声束主覆盖区域 $\mathcal{S}_k$ 内时，二者之间方才建立连接。据此，边集 $\mathcal{E}$ 可形式化表示为：

$$\mathcal{E} = \left\{ (v_k^p, v_j^d) \mid \forall k \in [1, N_p], \forall j \in \mathcal{S}_k \right\} \tag{30}$$

为量化不同虚拟损伤节点对测量路径的贡献差异，本研究构建了边权重度量函数。设第 k 个探头对的主声轴直线为 L_k，其端点分别为 T_k^{src} 与 T_k^{rcv}。定义主声轴 L_k 的垂直距离 $d_{kj}^{\perp}$ 不大于波束半宽 r 的区域为该探头有效探测范围 $\mathcal{S}_k$，在此范围内的虚拟损伤节点 v_j^d 可能对探头对 $\mathcal{K}_k$ 的测量产生影响：

表 1 物理测量节点与虚拟损伤节点的异构图构建算法伪代码

算法 1：物理测量节点与虚拟损伤节点的异构图构建

输入：探头坐标集合 $\mathcal{T}=\{(x_m,y_m)\}$，探头对列表 $\mathcal{K}=\{(T_n^{\mathrm{src}},T_n^{\mathrm{rcv}})\}$，损伤探测区域 $\mathcal{A}\subset\mathbb{R}^2$，损伤网格数量 N_d，波束半宽 r

输出：异构图边集 $\mathcal{E}$

节点定义：

  将每个探头对 $(T_n^{\mathrm{src}},T_n^{\mathrm{rcv}})$ 定义为物理测量节点 v_k^p

  将区域 $\mathcal{A}$ 离散化为 N_d 个网格单元，每个单元定义为虚拟损伤节点 v_j^d

边集计算：

  $\mathcal{E}\leftarrow\varnothing$

  for 每个探头对 $k=1$ 到 N_p ***do***

    $(x_{\mathrm{src}},y_{\mathrm{src}})\leftarrow T_k^{\mathrm{src}},(x_{\mathrm{rcv}},y_{\mathrm{rcv}})\leftarrow T_k^{\mathrm{rcv}}$

    $L_k\leftarrow\mathrm{LineSegment}((x_{\mathrm{src}},y_{\mathrm{src}}),(x_{\mathrm{rcv}},y_{\mathrm{rcv}}))$

    $\mathcal{D}_k\leftarrow\mathrm{GenerateParallelLines}(L_k,r,\Delta d)$

    $\mathcal{S}_k\leftarrow\varnothing$

    for 每条探测线 $D_i\in\mathcal{D}_k$ ***do***

      for 每个损伤节点 v_j^d ***do***

        if D_i 与 v_j^d 对应的网格单元相交 ***then***

          $\mathcal{S}_k\leftarrow\mathcal{S}_k\cup\{j\}$

        end if

      end for

    end for

    $\mathcal{S}_k\leftarrow\mathrm{Unique}(\mathcal{S}_k)$

    for 每个 $j\in\mathcal{S}_k$ ***do***

      $\mathcal{E}\leftarrow\mathcal{E}\cup\{(v_k^p,v_j^d)\}$

    end for

  end for

return $\mathcal{E}$

$$r_{kj}=\mathbb{I}\left(d_{kj}^{\perp}\le r\right) \tag{31}$$

其中 $\mathbb{I}(\cdot)$ 为指示函数，当条件成立时取值为 1，否则为 0。将节点排序为物理测量节点在前、虚拟损伤节点在后，则整体邻接矩阵 $\mathbf{A}\in\mathbb{R}^{(N_p+N_d)\times(N_p+N_d)}$ 具有分块稀疏结构：

$$\mathbf{A}=\begin{bmatrix}\mathbf{0}_{N_p\times N_p} & \mathbf{R}\\ \mathbf{0}_{N_d\times N_p} & \mathbf{0}_{N_d\times N_d}\end{bmatrix} \tag{32}$$

具体边集构造算法详见表 1 的算法，将此邻接矩阵 A 和零填充后的节点向量 Z' 应用于式(11)的前向传播公式，可实现先验物理机制上的散射源强度隐式求解。经过多次迭代更新，节点特征 $\mathbf{H}$ 中逐步编码了损伤位置与强度信息的隐式表征。

2.5 基于物理异构图神经网络的板材损失定位框架

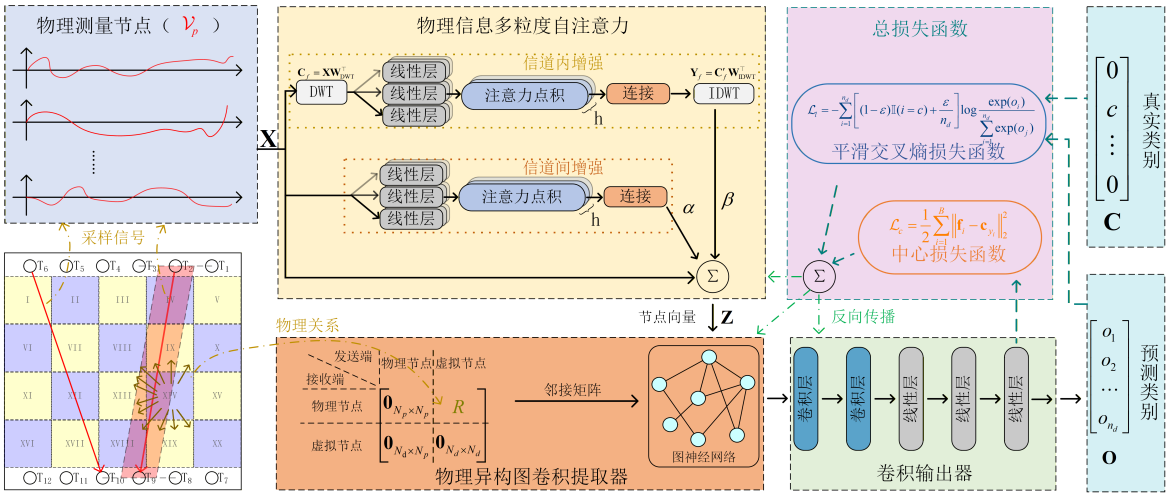


图 3 基于物理异构图神经网络的板材损失定位框架

基于前述的物理信息多粒度自注意力机制与物理异构图卷积提取器，本研究构建了一种面向复合板材的损伤定位深度学习网络。其具体训练流程如表 2 所示，网络总体架构如图 3 所示。该网络能够充分融合多源监测信息的时空特征，从而显著提升超声导波板材损伤定位的准确性与泛化能力。完整的损伤定位流程包含以下几个步骤：

1）数据采集与预处理：从部署于板材表面的多通道超声波换能器阵列中采集原始导波监测数据，随后对信号依次执行异常值剔除与同步对齐等预处理操作，以形成满足模型输入要求的规范化信号样本。

2）物理信息多粒度自注意力特征提取：将预处理后的传感器序列输入物理信息多粒度自注意力模块。该模块融合卷积结构与注意力机制，深入捕获信号序列内部的依赖关系及退化趋势特征，进而提取出传感器节点的高维时序表示。

3）物理异构图卷积信息传播与散射源反演：通过物理异构图卷积分类器，在预先构建的异构边集约束下进行信息传播。该异构边集由物理测量节点与虚拟损伤节点两类节点连接而成。在图卷积层的模拟扩散过程中，信息由测量节点沿预设的物理连接路径定向传播至虚拟损伤节点，并逐步更新后者的特征表示。这一过程在先验物理特征的约束下，实现了从观测信号到散射源分布的反向推理。

4）损伤类别映射与定位输出：卷积分类器将更新后的虚拟损伤节点特征图作为输入，经一维卷积层进一步提取深层特征，最终由全连接层映射为损伤类别的概率预测 $\mathbf{O}$，并输出最终预测类别 $\hat{\mathbf{y}} = \arg\max_i \mathbf{O}_i$。

表 2 物理异构图神经网络方法训练流程算法伪代码

算法 2：物理异构图神经网络方法训练流程

输入：带标签训练数据集 $\{\mathbf{X}, y\}$，探头物理参数 $\{\mathcal{T}, \mathcal{K}, r\}$，损伤探测参数 $\{\mathcal{A}, N_d\}$，小批量大小 B，学习率 η_t，平滑因子 z，超参数 δ，迭代轮数 T

输出：训练完成的模型参数 θ_T

初始化模型参数 θ_0

构建小波变换矩阵 $\mathbf{W}_{\mathrm{DWT}}$，并计算逆变换矩阵 $\mathbf{W}_{\mathrm{IDWT}} = \mathbf{W}_{\mathrm{DWT}}^{-1}$

依据表 1 的算法计算异构图边集 $\mathcal{E}$

for 迭代轮数 $\mathrm{iter} = 1$ ***to*** T ***do***

  for 每个小批量数据 ***do***

    根据式(19)至(20)计算通道内增强特征 $\mathbf{Y}_{\mathrm{time}}$

    计算离散小波变换 $\mathbf{C}_{\mathrm{freq}} = \mathbf{X}_b \mathbf{W}_{\mathrm{DWT}}^{\top}$ 增强特征后，按式(25)进行逆变换 $\mathbf{Y}_{\mathrm{freq}}$

    根据式(26)融合两分支并引入残差连接：$\mathbf{Z} = \mathbf{X}_b + \alpha \cdot \mathbf{Y}_{\mathrm{time}} + \beta \cdot \mathbf{Y}_{\mathrm{freq}}$

    将增强特征 $\mathbf{Z} \in \mathbb{R}^{B \times N_p \times L}$ 零填充为 $\mathbf{Z}' \in \mathbb{R}^{B \times (N_p + N_d) \times L}$

    将 $\mathbf{Z}'$ 与图 $\mathcal{G} = \{\mathcal{V}, \mathcal{E}\}$ 输入图卷积层，根据式(11)计算更新后的节点特征 $\mathbf{H}$

    对 $\mathbf{H}$ 执行卷积操作，并经全连接层映射为类别预测概率 $\mathbf{O}$

    获取预测类别：$\hat{\mathbf{y}} = \arg\max_i \mathbf{O}_i$

    根据式(34)计算标签平滑交叉熵损失 $\mathcal{L}_l$

    根据式(35)计算中心损失：$\mathcal{L}_c = \frac{1}{2} \sum_{i=1}^{B} \| \mathbf{f}_i - \mathbf{c}_{y_i} \|_2^2$

    根据式(33)计算总损失：$\mathcal{L} = \mathcal{L}_l + \delta \cdot \mathcal{L}_c$

    计算梯度 $\nabla_\theta \mathcal{L}$，并采用 Adam 优化器更新模型参数

  end for

end for

return θ_T

为引导模型原始阵列信号 $\mathbf{X}$ 中准确推断损伤类别，本研究设计了一个联合优化目标，包含标签平滑交叉熵损失 $\mathcal{L}_l$ 和中心损失 $\mathcal{L}_c$。总损失函数定义为：

$$\mathcal{L} = \mathcal{L}_l + \lambda \mathcal{L}_c \tag{33}$$

其中 λ 为平衡两类损失贡献的超参数。传统的交叉熵损失采用独热标签，容易导致模型对训练样本过度自信，降低泛化能力。为缓解这一问题，引入了标签平滑技术，构造平滑后的标签分布。对于真实类别为 c 的样本，模型输出层第 i 类的逻辑值为 o_i，则 $\mathcal{L}_c$ 可统一表示为：

$$\mathcal{L}_l = -\sum_{i=1}^{n_d}\left[(1-\varepsilon)\mathbb{I}(i=c)+\frac{\varepsilon}{n_d}\right]\log\frac{\exp(o_i)}{\sum_{j=1}^{n_d}\exp(o_j)} \tag{34}$$

其中ε为平滑因子，$\mathbb{I}(\cdot)$为指示函数，当$i=c$时取 1，否则为 0。该损失函数促使模型输出概率分布更加平滑，避免过拟合，从而提升对未知工况的泛化能力。

为进一步增强特征的可判别性，引入了中心损失函数，其通过最小化样本特征与其对应类别中心之间的距离，使得同一损伤类别的特征在嵌入空间中更加聚集：

$$\mathcal{L}_c = \frac{1}{2}\sum_{i=1}^{B}\left\|\mathbf{f}_i-\mathbf{c}_{y_i}\right\|_2^2 \tag{35}$$

其中B为批大小，$\mathbf{f}_i\in\mathbb{R}^d$为分类器倒数第一层输出的特征向量，$\mathbf{c}_{y_i}$为第$y_i$类的特征中心。

模型采用 Adam 优化器进行端到端训练，初始学习率设为1×10^{-3}，中心损失平衡系数$\lambda=0.01$。学习率采用余弦退火策略动态调整，以稳定收敛并提升泛化性能。通过最小化联合损失$\mathcal{L}$，模型能够在先验物理特征与监测数据特征的共同引导下，学习到具有强判别力与泛化性能的损伤特征，从而实现高精度的损伤定位。

三、存在的问题和拟解决方法

3.1 常规图卷积网络在导波相位特征提取中的局限性

在阵列超声导波检测中，各通道信号间的相位关系承载着损伤空间定位的关键信息。设激励信号的频谱为$S(\omega)$，则由第l个探头r_l激励、第j个探头r_j接收的信号频谱$X_{lj}(\omega)$可表示为：

$$X_{lj}(\omega)=S(\omega)\cdot G(r_l,r_j,\omega) \tag{36}$$

其中，$G(r_l,r_j,\omega)$为介质中的格林函数。相应的传递函数定义为：

$$H_{lj}(\omega)=\frac{X_{lj}(\omega)}{S(\omega)}=G(r_l,r_j,\omega)\approx\frac{C(\omega)}{\sqrt{k(\omega)d_{lj}}}\cdot e^{-\alpha(\omega)d_{lj}}\cdot e^{i\left(k(\omega)d_{lj}-\frac{\pi}{4}\right)}\triangleq\Gamma_{lj}(\omega),e^{i\phi_{lj}(\omega)} \tag{37}$$

式中，$k(\omega)$为波数；$C(\omega)$表征与频率相关的幅值因子；$\alpha(\omega)$为材料衰减系数；d_{lj}为收发探头间距；常数项$\pi/4$源自二维格林函数的远场渐近展开。$\Gamma_{lj}(\omega)$与$\phi_{lj}(\omega)$分别代表幅值衰减因子与相位延迟。鉴于实际检测通常采用宽带脉冲激励，接收信号本质上是各频率分量响应的线性叠加，其相位谱中蕴含了损伤位置与传播路径的丰富信息。

传统图卷积网络通常基于实值图拉普拉斯矩阵构建卷积算子，其层间传播规则如式(10)所示。尽管上述架构在图节点特征聚合与扩散建模方面表现优异，但因其图拉普拉斯算子的构造仅依赖实值邻接关系，故本质上忽视了信号在波导中传播时由

频率决定的相位延迟效应。由式(37)可知，不同频率分量在跨越相同空间距离 d_{ij} 时，将经历不同的相位偏移 $\phi_{ij}(\omega)=k(\omega)d_{ij}-\pi/4$。这一频率–相位耦合特性意味着，传感器阵列各通道间的信息交互不仅取决于空间拓扑连接，更显著地依赖于信号频域成分的具体分布。然而，常规图神经网络所采用的图移位算子 $\widetilde{\mathbf{D}}^{-1/2}\widetilde{\mathbf{A}}\widetilde{\mathbf{D}}^{-1/2}$ 为实对称矩阵，其特征分解仅能刻画实值信号在图上的平滑扩散过程，缺乏对复数域中相位旋转及频率选择性传播行为的编码能力。因此，将传统图神经网络直接应用于多通道导波信号处理将面临以下两方面的固有局限：

1. 相位信息丢失：图卷积网络对节点特征的聚合本质上是实值加权求和，这一操作在复数域中等价于仅对幅值进行调制而忽略相位旋转，导致通道间精细的时延与相干结构无法被有效捕捉。

2. 频率混叠与分辨率受限：宽带激励下，不同频率的相位响应在图卷积网络的单一实值聚合框架下发生混叠，限制了网络对多模态频散特征的解耦能力。

因此为实现对导波阵列信号中隐含的损伤散射信息的充分挖掘，有必要在传统图卷积结构的基础上引入复数域表示或频域自适应机制，使网络能够同时感知幅值衰减与相位延迟，从而提升对损伤位置与程度的反演精度。

3.1.1 图希尔伯特变换

为在不额外增加网络监督负担的前提下，赋予图神经网络对信号瞬时相位特征的感知能力，本课题拟引入希尔伯特变换作为图信号预处理与结构化先验嵌入的关键环节。在经典信号处理理论中，希尔伯特变换提供了构建解析信号、提取瞬时幅值与瞬时相位的数学框架。其时域定义为主值积分形式的卷积运算：

$$\mathcal{H}[x(t)]=x(t)*\frac{1}{\pi t}=\frac{1}{\pi}\int_{-\infty}^{+\infty}\frac{x(\tau)}{t-\tau}\mathrm{d}\tau \tag{38}$$

尽管变换算子本身作用于实信号空间，其实质在于通过卷积核 $1/(\pi t)$ 引入一个 $\pm\pi/2$ 的正交相位偏移。由此构成的复解析信号在不丢失物理可观测能量信息的前提下，将一维实信号嵌入二维复平面，从而赋予了信号明晰的瞬时幅值包络与瞬时相位演化轨迹：

$$z(t)=x(t)+j\mathcal{H}[x(t)]\triangleq A(t)e^{j\phi(t)} \tag{39}$$

其中，瞬时相位 $\phi(t)$ 的微分特性与波达时刻紧密相关，恰好对应导波检测中损伤散射波包的到达时间与群延迟信息。

然而，上述经典定义严格依赖于连续时间变量 t 下的傅里叶变换性质，无法直接应用于定义在离散、不规则传感器拓扑图结构上的阵列信号。为将时频域中的正交移相思想推广至图信号处理领域，需借助图傅里叶变换在图谱空间中构建等效的频率相关相位偏移操作。

具体而言，传统傅里叶变换中的复指数基函数 $e^{j\omega t}$ 在图域被图拉普拉斯矩阵 $\mathbf{L}$ 的特征向量 $\mathbf{U}$ 所替代。对于定义在图节点上的实信号 $\mathbf{x}\in\mathbb{R}^N$，其图傅里叶变换为 $\hat{\mathbf{x}}=\mathbf{U}^\top\mathbf{x}$。为了在谱域实现类似希尔伯特变换的 90° 相位滞后，需构造一个依赖于图谱虚部符号的移相算子。为此，本课题将式(8)中的特征值矩阵 $\mathbf{\Lambda}=\mathrm{diag}(\lambda_1,\lambda_2,\cdots,\lambda_n)$ 替换为基于特征值虚部极性定义的复数对角矩阵 $\widehat{\mathbf{H}}$：

$$\widehat{\mathbf{H}}[k,k]=\begin{cases}-j & ,\mathrm{Im}(\lambda_k)>0\\ 0 & ,\mathrm{Im}(\lambda_k)=0\\ j & ,\mathrm{Im}(\lambda_k)<0\end{cases} \tag{40}$$

该定义调整各路信号的相位，基于此谱域核函数，定义在图上的信号 $\mathbf{x}$ 的图希尔伯特变换可严格表述为其在图傅里叶基下的谱域加权与逆变换过程：

$$\mathcal{H}[\mathbf{x}]=\mathbf{U}\widehat{\mathbf{H}}\mathbf{U}^\top\mathbf{x} \tag{41}$$

通过式(41)构造希尔伯特图卷积神经网络：

$$\tilde{\mathbf{x}}=\mathbf{x}+j\mathcal{H}[\mathbf{x}]=\mathbf{U}(\mathbf{I}+j\widehat{\mathbf{H}})\mathbf{U}^\top\mathbf{x} \tag{42}$$

相比于式(11)图卷积神经网络，该方案表示能够将式(37)中隐含的频率-相位耦合关系显式地表征于图节点特征中。

3.2 下一步工作计划

3.2.1 复数特征嵌入与相位感知图网络融合

为弥补传统实值图卷积网络在导波相位特征提取中的不足，后续研究将图希尔伯特变换输出的复解析信号 $\widetilde{\mathbf{X}}=\mathbf{X}+j\mathcal{H}[\mathbf{X}]$ 无缝嵌入深度图网络架构，探索两条技术路径：一是复值图卷积网络集成，即将复数特征直接输入复值图卷积层，利用复数权重矩阵在前向传播中同时调制幅值与相位，使邻域聚合过程能自然区分同相叠加与反相抵消；二是构建相位注意力图变换器，在注意力得分中引入相位差余弦项作为偏置，使模型优先关注具有稳定相位关系的节点对。该融合策略将导波传播的物理相位约束显式编码进网络计算，预期可显著增强对损伤微小扰动引起的相位异常检测灵敏度，为高准确率损伤定位提供更坚实的算法基础。

3.2.2 对比实验设计与有效性验证

为系统评估所提框架的性能优势，后续将设计多维对比实验：选取传统时频方法、纯数据驱动深度模型及若干消融变体作为基线，以损伤定位准确率、F1 分数及抗噪泛化性为核心定量指标，在复合材料层合板数据集上进行统一评估。同时辅以注意力权重热力图等定性分析手段，从机理层面验证物理先验嵌入与相位感知机制对多模态频散条件下损伤特征解耦的实际贡献。通过上述实验，预期可充分证明所提方法在定位精度、鲁棒性与物理可解释性方面的综合优势。

指导教师意见 是否同意参加中期检查答辩：☐同意　☐不同意 指导教师签字：
考核组长意见 是否通过中期检查：☐通过　☐不通过 考核组长签字（章）：
中期检查分数：
系级教学单位审核意见 系主任签字（章）： 年　月　日