燕山大学
YANSHAN UNIVERSITY

本科毕业设计（论文）

论文题目　基于深度图神经网络的板状结构超声损伤定位方法

作者姓名　游寅龙

专　　业　测控技术与仪器

指导教师　温银堂　研究员

2026 年 6 月

燕山大学本科毕业设计（论文）

基于深度图神经网络的板状结构超声损伤定位方法

学　　院	电气工程学院
专　　业	测控技术与仪器
姓　　名	游寅龙
学　　号	202211030001
指导教师	温银堂 研究员
答辩日期	2026 年 6 月

学位论文原创性声明

郑重声明：所呈交的学位论文《基于深度图神经网络的板状结构超声损伤定位方法》，是本人在导师的指导下，独立进行研究取得的成果。除文中已经注明引用的内容外，本论文不包括他人或集体已经发表或撰写过的作品成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果，并承诺因本声明而产生的法律结果由本人承担。

学位论文作者签名：  　　日期：2026 年　06 月　11 日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权燕山大学将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

保　密☐，在__年解密后适用本授权书。

本学位论文属于

不保密☐。

(请在以上相应方框内打“ √ ”)

学位论文作者签名：  　　日期：2026 年　06 月　11 日

指导教师签名：  　　日期：2026 年　06 月　11 日

燕山大学毕业设计(论文)任务书

学院：电气工程学院　　专业(方向)：　测控技术与仪器

<table>
<tr><td>学号</td><td>202211030001</td><td>学生姓名</td><td>游寅龙</td><td>专 业
班 级</td><td>检测 22-2 班</td></tr>
<tr><td rowspan="4">题目</td><td>题目名称</td><td colspan="4">基于深度图神经网络的板状结构超声损伤定位方法</td></tr>
<tr><td>题目性质</td><td colspan="4">1. 理工类：工程设计 （ √ ）；工程技术实验研究型（ ）；
理论研究型（ ）；计算机软件型（ ）；综合型（ ）。
2. 文管类（ ）；3. 外语类（ ）；4. 艺术类（ ）。</td></tr>
<tr><td>题目类型</td><td colspan="4">1. 毕业设计（ √ ）　　2. 论文（ ）</td></tr>
<tr><td>题目来源</td><td colspan="4">科研课题（ ）　生产实际（ ）　自选题目（ √ ）</td></tr>
<tr><td>主要内容</td><td colspan="5">基于深度学习的方案实现对板状结构的超声无损探伤。设计一套基于物理信息图神经网络的智能损伤识别系统，针对捕获的超声导波信号进行信号提取和处理，能够自动、精确地识别板状结构中的损伤位置，实现板状结构安全的智能化预警。</td></tr>
<tr><td>基本要求</td><td colspan="5">1. 掌握超声导波的探测原理及图神经网络的相关算法，了解其实际应用需求。
2. 功能与性能要求：针对所采集到的多通道超声导波信号，基于射线投射理论构建物理异构图，利用图神经网络模型实现损伤位置的自动化分类识别。模型在测试集上的损伤定位准确率不低于 85%；具备处理实测噪声信号的鲁棒性；算法效率需满足准实时分析要求；模型决策需具有一定的物理可解释性。
3. 完成基于物理信息的图神经网络设计，搭建实验设备获取超声导波信号，通过实验验证设计方法的可行性。
4. 通过查阅相关参考文献等手段进行自主学习，对参考文献进行比较分析，描述课题领域的应用前景和科学价值。（开题答辩时考核）
5. 在开题答辩前至少给出两种以上解决方案并在开题报告中进行描述，在综合分析比较不同解决方案优缺点的基础上，与指导教师研讨，选择并确定所执行的方案，并给出合理、明确的技术路线。（开题答辩时考核）
6. 在设计解决方案时就方案的发展前景，合理性等因素在毕业设计论文中进行阐述说明，（开题答辩时考核）设计解决方案时应考虑工程造价、成本并给出计算依据和过程，解决方案的阐述中应给出系统各个部分的结构、功能和工作流程。（最终答辩时考核）</td></tr>
</table>

<table>
<tr><td></td><td colspan="5">7. 进行相关科学实验，阐述实验方案，论证分析实验方案的合理性。（中期答辩时考核）
8. 学生应在毕业设计中阐述所设计内容的应用价值及对社会可持续发展的作用、损害或隐患。（最终答辩时考核）
9. 设计过程中具有批判性思维和创新意识，能够对已有方法做出评判、改进或创新。（中期答辩时考核）
10. 论文撰写中，应该包括对相关技术标准、产业政策或相关法规的引用和评述。（最终答辩时考核）
11. 毕业设计过程中，需结合专业工程项目的实际应用场景，明确服务对象、利益相关方和工作条件，分析和评价专业工程实践对社会、健康、安全、法律以及文化的影响，并理解应承担的责任与义务。（最终答辩时考核）
12. 毕业设计论文的撰写字数不少于 2 万字。
13. 毕业设计的参考文献不少于 15 篇，其中近 5 年参考文献不少于总数量的 1/3，外文文献不少于 1/3。
14. 毕业设计撰写应严格按照《电气工程学院本科毕业设计撰写规范》执行。</td></tr>
<tr><td>参考资料</td><td colspan="5">1. 深度图神经网络相关书籍
2. 超声无损检测相关资料
3. 人工智能及无损探伤相关资料</td></tr>
<tr><td>周 次</td><td>1 — 5周</td><td>6 — 10 周</td><td>11 — 12 周</td><td>13 — 15 周</td><td>16— 17 周</td></tr>
<tr><td>应完成的内容</td><td>熟悉任务书所下发课题和任务，查阅相关参考资料，确定设计方案并参加开题报告答辩。</td><td>完成图神经网络的构建。撰写中期答辩报告并参加中期答辩。</td><td>完成超声导波无损检测的实验搭建，进行相关实验数据采集。</td><td>完成系统整合与综合测试，分析数据。撰写毕业设计论文。</td><td>整理材料，按照毕业设计论文撰写规范修改毕业设计论文，提交相关材料并准备参加毕业设计答辩。</td></tr>
<tr><td colspan="6">指导教师：温银堂
职称：研究员 2025 年 12 月 12 日</td></tr>
</table>

摘 要

随着复合板材被广泛运用于各类工程中，对超声导波的结构健康监测与损伤检测技术的需求逐渐庞大。近些年来，神经网络被大量应用到导波无损检测中，期望借助数据驱动的方式改善检测的泛化性能和鲁棒性，不过目前大多数模型在检测精度上还需要进一步提高。其根本原因在于现有的方法大多只停留在数据驱动范式和物理推导范式的单一模式中，两者无法有机地结合起来，且对于阵列式传感器所采集到的多通道导波信号，普遍没有从阵列整体的角度出发来建立系统的模型，直接把它们当作彼此独立的通道来处理，从而使得各个阵元之间的相位关系一直无法被显式地表示出来并加以利用。本课题基于以上问题开展研究，主要研究工作涵盖以下几个方面：

（1）对板材结构健康监测领域各种主流的监测技术进行了整理，给出其适用范围和不足之处。在此基础上，针对超声导波信号处理方案，查阅相关文献，提出目前主流的发展发现和研究困境，并且以图卷积神经网络为出发点，对它在相关领域的应用现状进行了探讨，为本文方法创新打下了坚实的理论基础和文献基础。

（2）对超声导波在板状结构中传播的机理，弹性波尤其是兰姆波的传播特性及频散行为做了详细的论述，并证明了兰姆波的传播频率不变性。在此基础上，进一步对损伤与导波相互作用机理进行深入的研究，运用波场传播理论和损伤力学原理来分析损伤缺陷引起信号幅值衰减和相位偏移的理论依据，给之后设计物理信息嵌入的图神经网络模型赋予了明确的物理先验以及数据可解释性的支持。

（3）根据以上研究，本文首先建立物理异构图神经网络损伤定位模型，该模型打破了传统同构图结构的限制，创造性地构建了异构边集，把蕴含先验几何特征的物理特征嵌入到网络中，在训练过程中，模型会自发受到物理规律的约束，降低损伤特征提取的难度。接着针对导波复数信号的幅值和相位信息长期被分开处理、相互割裂的问题，提出了一个复数自适应图卷积网络损伤定位模型，用分数阶希尔伯特图变换在复数域上重新定义了图卷积运算，使得网络可以同时学习复数特征实部和虚部之间存在的内在耦合关系。

（4）为了展现所提模型的优越性，将所提出的模型与经典机器学习模型及最新

的图神经网络模型进行对比实验。结果表明，物理异构图神经网络的检测准确率最大提升达 82.77%，平均提升 42.67%；复数自适应图卷积网络在前者基础上又进一步提升了 6.78%。此外，通过消融实验与权重可视化，直观验证了所提各模块的有效性。

关键词：结构健康检测；损伤定位；图神经网络；超声导波

Abstract

With the widespread application of composite plates in all sectors of engineering construction, people's demand for structural health monitoring and damage detection technology based on ultrasonic guided waves has been growing day by day. Recently, many neural networks have been applied to the problem of guided-wave nondestructive testing, and with the help of data-driven methods, it is hoped that better generalisation and robustness of detection can be achieved. The detection accuracy of most of the current models is still relatively low. Most of the current methods are either purely data-driven or based on physics, and an organic combination of the two has not been realised yet. At the same time, the multi-channel guided-wave signals obtained by array sensors are generally not modelled according to the whole array from this perspective; rather, these signals are treated as independent channels and their phase relationships among array elements are never explicitly mentioned or used. Based on the problems mentioned above, this paper will investigate them and take the following measures:

(1) Some studies have been conducted to investigate all kinds of monitoring methods for the health status of plate structures, and their applicable ranges and defects are known. Based on the above, this paper will introduce some typical development trends and research problems of ultrasonic guided-wave signal processing schemes through the review of related literature. Graph convolutional networks have been used as the starting point, and the present development situation of this technology in related fields is discussed to lay a solid theoretical and literature foundation for the methodological innovation in this paper.

(2) Based on the propagation mechanism of ultrasonic guided waves in plate-like structures, the features and dispersion behaviour of elastic waves, especially Lamb waves, have been systematically explained, and the frequency independence of Lamb wave propagation has been shown. Based on the above, the mechanism of damage-guided wave interaction will be examined in detail. According to the theory of wave-field propagation

and damage mechanics, theoretical analysis will be conducted to determine how much the amplitude of the signal is reduced and by how much its phase shifts due to damage defects; thus, a clear physical basis and data-interpretability support have been provided for the subsequent design of physics-informed graph neural networks.

(3) Based on the above research, a physics-informed heterogeneous graph neural network model for damage localisation will be constructed in this paper first. This model solves the problem of homogeneity in the previous graph structure by adding a new kind of heterogeneity to the edge set and thus combining physical attributes with intrinsic geometric properties of the network. Thus, the model is naturally restricted by the laws of physics during training and the problem of damage feature extraction is simplified. Later, given the long-standing problem that the amplitude and phase information of complex-valued guided-wave signals are processed independently and do not have a connection, a new model for damage location based on complex adaptive graph convolutional networks has been proposed. The model reformulates the graph convolution operation in the complex domain by constructing a fractional-order Hilbert graph transform and can learn the intrinsic coupling relationship between the real and imaginary parts of complex features at the same time.

(4) To show that the proposed model is better, we will perform comparative experiments with classical machine learning models and leading graph neural network models. Based on the above results, the maximum improvement in the detection accuracy of the physics-informed heterogeneous graph neural network is 82.77%, and the average improvement is 42.67%; additionally, it can be seen from this that the complex adaptive graph convolutional network further enhances accuracy by 6.78%. Ablation studies and weight visualisations can help us know which of the proposed modules are effective.

Keywords: structural health testing; damage localization; graph neural network
ultrasonic guided waves

目 录

摘 要 I
Abstract III
第 1 章 绪 论 ..... - 1 -
1.1 背景及研究意义 ..... - 1 -
1.2 板材无损检测方法 ..... - 2 -
1.2.1 光栅传感器法 ..... - 2 -
1.2.2 热成像法 ..... - 2 -
1.2.3 射线检测法 ..... - 2 -
1.2.4 超声导波法 ..... - 3 -
1.3 超声导波损伤定位技术的国内外研究现状 ..... - 3 -
1.4 图神经网络在无损检测领域的研究 ..... - 5 -
1.5 本文主要研究问题和章节内容 ..... - 6 -
1.5.1 研究内容及思路 ..... - 6 -
1.5.2 论文结构及章节内容 ..... - 7 -
第 2 章 超声导波信号的基础理论 ..... - 9 -
2.1 引言 ..... - 9 -
2.2 弹性波的基础理论 ..... - 9 -
2.2.1 弹性波的基本概念 ..... - 9 -
2.2.2 弹性波的波动方程 ..... - 9 -
2.3 兰姆波的理论基础 ..... - 10 -
2.3.1 兰姆波的基本概念 ..... - 10 -
2.3.2 兰姆波的波动方程 ..... - 11 -
2.3.3 兰姆波的频散方程 ..... - 11 -
2.3.4 兰姆波的传播曲线 ..... - 13 -
2.4 兰姆波探伤的基础理论 ..... - 14 -
2.5 本章小结 ..... - 14 -
第 3 章 基于物理异构图神经网络的损伤定位模型 ..... - 15 -
3.1 引言 ..... - 15 -
3.2 基础理论建立 ..... - 15 -
3.2.1 多头注意力机制 ..... - 15 -
3.2.2 图卷积神经网络 ..... - 16 -

3.3 物理异构图神经网络框架的设计 ..... - 17 -
3.2.1 物理信息多粒度自注意力机制 ..... - 17 -
3.3.2 物理异构图卷积提取器 ..... - 20 -
3.3.3 物理异构图神经网络的设计 ..... - 22 -
3.4 实验验证 ..... - 24 -
3.4.1 数据介绍 ..... - 24 -
3.4.2 实验分析 ..... - 26 -
3.5 本章小结 ..... - 32 -
第 4 章 基于复数自适应图卷积网络的损伤定位模型 ..... - 33 -
4.1 引言 ..... - 33 -
4.2 复数自适应图卷积网络框架的设计 ..... - 33 -
4.2.1 双向令牌信息提取模块 ..... - 33 -
4.2.2 分数阶希尔伯特图卷积层 ..... - 35 -
4.2.3 复数自适应图卷积网络的设计 ..... - 38 -
4.3 实验验证 ..... - 40 -
4.3.1 数据介绍 ..... - 40 -
4.3.2 实验分析 ..... - 40 -
4.4 本章小结 ..... - 43 -
结 论 ..... - 45 -
参考文献 ..... - 47 -
致 谢 ..... - 51 -
附录 1 物理异构图神经网络主要代码
附录 2 复数自适应图卷积网络主要代码

第 1 章 绪　论

1.1 背景及研究意义

20 世纪中期以后，由于国内的基建工程以及高铁网络等国家重大战略项目的需求，我国复合板材产业得到了迅速的发展。伴随着工业化的持续推进，复合板材由于具有轻质高强、耐腐蚀、易成型等优点，正在逐步取代传统的木材、金属合金等，成为了汽车、船舶、航空航天等运输装备制造领域的主要材料。高速列车轻量化设计、大型船舶结构优化、新能源汽车车身制造等都会出现复合材料比例不断的提高，而服役性能的好坏又会影响到整个装备的运载效率以及使用寿命[1]。

在此背景下，工程项目的规模化发展以及质量标准的不断提高，给构件检测提出了更高的要求，在不破坏构件力学性能的基础上，实现检测过程的实时化、在线化、结果的高精度量化。大型工程结构的主要承力骨架、重要的载荷传递单元，复合板材构件在制造及服役期间，不可能不受到各种复杂的因素相互影响。化学腐蚀环境会引起点蚀、晶间腐蚀等局部损伤，极端温度场会改变材料的微观组织结构和力学行为，静载、动载、交变应力的长期作用，会造成疲劳裂纹的产生和扩展。表面损伤属于构件失效的早期敏感区，微小的腐蚀坑、划痕都会使有效承载截面变小，是局部应力集中的地方，受到服役载荷的影响后很容易产生、加剧裂纹，从而引起突然的断裂现象[2]。此类损伤演化过程具有显著的隐蔽性与累积性特征：初期损伤往往深埋于材料表层之下，或表现为肉眼难以识别的微观缺陷，常规检测手段难以有效捕捉；随着服役时间延长，损伤将经历从量变到质变的渐进式演化，一旦达到临界尺寸，便可能引发结构性能的急剧劣化[3]。

大量工程实践表明，表面缺陷的漏检或误判，是导致大型工程结构承载能力下降、剩余寿命缩短的主要原因之一[4]。若未能建立有效的在线监测与定期检测机制，及时识别并评估早期损伤状态，这些初始缺陷将持续扩展，严重削弱结构完整性，甚至引发灾难性连锁失效。因此，在众多针对复合材料缺陷特征的理论研究与实验分析基础上，采用有效的无损检测技术手段，对先进复合材料结构的生产过程与服役状态进行全生命周期监测，已成为保障产品品质进步、使用安全的重要技术路径。

1.2 板材无损检测方法

当前，板材的无损检测方法主要通过在目标结构中部署智能传感元件来进行。常见的方案包括光栅传感器法[7]，热成像法[8]，射线检测法[9]和超声导波法[10]。

1.2.1 光栅传感器法

光栅传感器法的核心是利用光栅对应变场中拉伸部分或压缩部分的敏感性来测量。具体而言，光纤布拉格光栅作为传感元，反射特定波长的光。当应变场发生改变的时候，光栅周期和纤芯折射率随之改变，从而引起反射波长发生漂移，利用解调仪实时精确地探测波长变化量，根据线性关系反演出被测点的应变值[13]。该方案可实现高精度、分布式、抗电磁干扰的应变场测量，但探测光只能探测表面损失，内部微损伤难以探测。

1.2.2 热成像法

热成像法的核心是利用损伤区域与完整区域的热特性差异而测量。具体而言，采用高能脉冲闪光灯激励源对被试件表面进行瞬时加热，外激励热流在试件内部发生热传导，热流在传导过程中，由于试件内部热特性存在不连续性结构，将导致对应表面温度分布发生异常[14]。该方案操作简单，检测速度快，可大面积检测，然而，热扩散过程本身也会带来显著局限。一方面，热波在固体中传播时振幅随深度呈指数级急剧衰减，且伴随强烈的横向热扩散效应，使缺陷边缘模糊、信号对比度下降；另一方面，测量极易受到探测器噪声、环境红外辐射反射以及表面发射率不均匀等因素的干扰，引入大量随机与系统噪声。

1.2.3 射线检测法

射线检测法的核心是利用 X 射线或γ射线在穿透板材时，因材料内部结构差异而产生不同衰减的特性来识别损伤。具体而言，当强度均匀的射线穿透板材时，其能量会因材料的吸收和散射而发生衰减，缺陷区域的厚度减小或者密度降低会减弱射线的衰减作用，因此穿过损伤区域的射线强度会高于周围完好区域。检测装置将射线强度图像转化为灰度图像，通过深浅对比来判断是否存在损伤[15]。该方案适用材料广，可直观判断缺陷位置，但检测成本高昂、效率较低，且射线对人体有害，

因此难以大范围推广使用。

1.2.4 超声导波法

超声导波法的核心是利用了超声波场在板材内部传播的弹性波场来进行检测[16]。具体而言，换能器在板中激励特定模态的导波，当导波遇到裂纹或腐蚀等损伤时，会发生反射、透射、散射及模态转换等现象。通过布置在板面上的接收传感器阵列采集这些携带损伤信息的波信号。分析接收信号的离散数字特征来判断成像[17]。该方案具有传播距离远、衰减小、可一次性大范围快速检测的优点，是目前公认最有前景的方案，但导波固有的多模态与频散特性导致信号处理方面仍有不小挑战。

1.3 超声导波损伤定位技术的国内外研究现状

超声导波的早期的损伤定位研究主要依赖于兰姆波传播的物理机制。1967 年，前苏联科学家 Viktorov[18]阐述了瑞利波和兰姆波的理论方程，并仔细探讨其在超声导波检测方面的重要用途。之后，Auld[19]进一步在声学理论上推导了各种超声导波的传播方式和模态，提出声波经过多重的反射和模态转换后会以波包的形式沿着板材的延展方向传播，从而形成导波。这一研究既证明了超声导波在板材检测领域的可行性，也提出超声导波具有的多模态和频散特性将对超声检测带来负面影响。之后的众多学者，也针对此特性提出了不同的解决方案，其中基于波包飞渡时间的椭圆定位法是应用最广泛的手段之一。该方法利用压电传感器网络激发并接收兰姆波，通过计算损伤散射波到达各传感器的时间差，结合波速构建椭圆轨迹，多椭圆交点即为损伤位置。例如，张海燕[20]等人采用采用椭圆轨迹定位法布置了传感器网络对铝板进行了损伤定位，应用图像融合的方法绘制了损伤概率成像图，有效确定了损伤的尺寸大小与分布位置；魏诺柯[21]等人提出了无基准双曲线定位算法，并开展了铝板不同位置的缺陷定位实验研究，可大致确定损伤位置，误差可以控制在 10%以下。然而，由于复合材料的各向异性及兰姆波固有的频散与多模态特性，波速难以精确获取，且手动提取 ToF 存在主观误差。

为克服上述问题，研究者通过引入概率成像和贝叶斯推断方法。例如，Yun 等[22]比较了基于散射波 ToF 的概率矩阵算法与人工神经网络算法，指出前者定位精度受人为选择参数和材料各向异性影响较大；Yan 等[23]提出了基于贝叶斯理论的损伤定

位框架，该框架结合连续小波变换提取的 ToF 数据，利用马尔可夫链和蒙特卡洛方法更新参数的后验概率分布。该方法在加筋铝板和复合材料层合板上不仅给出了损伤位置的估计值，还得以量化了由测量误差和模型简化带来的不确定性，取得了一定的效果。针对塑料管道的早期裂纹难以检测的问题，Hong 等[24]利用非线性超声调制技术，提取对裂纹敏感的一阶边频带信号，并通过小波包能量进行损伤评价，展示了非线性特征在小损伤检测中的潜力。尽管上述传统方法在实验室条件下取得了一定效果，但其在实际工程应用中面临诸多严峻挑战。Hughes 等[25]认为以上方法性能高度依赖于材料特性的精确建模，但实际复合材料往往存在工艺偏差和性能分散性导致各向异性的产生，加之多模态叠加、边界反射及环境噪声干扰导致时域波形复杂，使得精确提取损伤散射波到达时刻基本不成立。其根本原因主要是传统方法缺乏对海量监测数据的自适应学习能力，难以处理复杂损伤模式。

随着人工智能的复兴，深度学习凭借其强大的特征自提取和非线性映射能力，为解决传统方法中复杂的信号解读难题提供了新思路。最直接的方法是将传感器采集的原始一维兰姆波信号或其衍生的损伤指数输入神经网络。Zhang 等[26]指出，传统损伤指数虽能指示损伤存在，但缺乏时间信息。为此，他们提出了一种基于短时傅里叶变换的时变损伤指数，并结合一维卷积神经网络建立该指数与损伤坐标的映射关系。实验证明，仅用 4 个传感器即可在铝板上实现定位，且模型展现出了一定的跨板泛化能力。Zhuang 等[27]则采用门控循环单元网络，融合原始时域信号和连续小波变换提取的能量信号，在仅用一对激励-接收传感器的情况下，实现了对复合材料板的全场损伤定位，显著提高了模型在有限数据下的抗干扰能力。近些年来，有学者将图像识别技术引入该领域，将一维信号转换为二维图像，充分利用卷积神经网络在图像处理领域的优势增强识别的可靠性。转换方式主要分为时频分析和空间编码两类。前者基于经典数字信号处理手段，将时域转化为频域扩充，Rautela 等[28]通过连续小波变换将一维超声波数据转换为二维时频图像，并利用 CNN 和 LSTM 混合模型实现损伤检测与定位。Liu 等[29]则利用同步挤压小波变换的高分辨率时频表示，结合分水岭分割算法，实现了对牛胫骨板和钢板中多模态导波的自动分离与重构。后者则基于格拉姆角场，将离散点首位相连形成的线段转化为角度，从而保留信号的完整性和时间依赖性。Liao 等[30]提出了一种改进的分段聚合近似算法对导波信号进行压缩和特征提取，然后将多路径融合后的损伤指数序列通过 GAF 编码为二

维图像。结合引入卷积块注意力模块的 CNN 网络，该方法在碳纤维复合材料板上实现了高精度的损伤坐标回归，其性能优于传统的一维 CNN 和 RAPID 成像算法。Shao 等[10]进一步拓展了该思路，将 GAF 图像与一维损伤指数序列共同输入到多维度特征融合网络中，同时实现了对单源偏移损伤和多源累积损伤的定位与量化，并在不同传感器阵列布局间验证了迁移学习的可行性。

虽然深度学习给从超声导波信号中自动提取损伤特征提供强大的工具，但是以卷积神经网络为代表的主流方法，把传感器阵列数据当作规则网格或者独立序列来处理，没有很好地建模传感器之间的非结构化空间拓扑关系，也没有把导波传播的物理机理显式地融合进去。这就使得模型很难很好地挖掘出传感器布局、波动信号和损伤状态之间的深层次耦合关系，在复杂的实际场景中也存在着泛化能力和物理可信度的问题。

1.4 图神经网络在无损检测领域的研究

近年来，图神经网络凭借邻接矩阵的高维复杂连接方案，在处理非欧几里得结构数据方面展现出独特优势。该类网络能够显式构建实体之间的交互与依赖关系，在挖掘数据深层结构方面表现出显著潜力，尤其适用于多通道时间序列的异常检测任务。Deng 等[31]于 2021 年首次将图神经网络引入时间序列异常检测，在多变量数据集上系统验证了其有效性，为相关研究奠定了方法论基础。受此启发，Neves 等[32]构建了基于脑区功能连接的图结构，将多通道脑电信号转化为图数据，并成功应用于阿尔茨海默症的病理特征识别。在应用场景不断拓展的背景下，图神经网络被逐步引入更具挑战性的多模态任务中。姜彦吉等[33]针对复杂行车环境下的声音事件检测问题，提出一种融合交叉模态信息的图神经网络方法。该方法首先通过声音事件窗提取信号中的共时与历时关系，经噪声过滤后构建关系图结构；随后改进图卷积网络以平衡邻居节点与自身节点的权重，缓解过度平滑问题；最后结合卷积循环网络学习声学特征与时序信息，通过交叉模态融合提升事件检测性能。金罡等[34]则提出融合图神经网络与局部熵的双波段红外图像目标检测方法，采用单尺度 Retinex 增强图像，通过加权局部熵获取显著图，并联合卷积网络与图神经网络进行目标特征提取，实验结果表明该方法在信息保留和检测精度方面均表现优异。在软件安全领域，GNN 亦展现出强大的语义建模能力。姚军等[35]提出基于代码属性图与双向 GNN

的嵌入式设备固件漏洞检测方法，从源代码层面实现自动化漏洞识别。在 SARD 数据集和真实漏洞数据集上的实验结果表明，该方法在检测精度和 F1 分数上分别达到 93.4%和 86.54%，显著提升了漏洞识别性能。进入 2025 年，图神经网络的应用进一步向工业制造领域深化。Sorensen 等[36]针对半导体工艺过程中产生的海量多源跨尺度时序数据，将相互关联的工艺参数构建为图结构，通过图卷积操作捕捉变量间的复杂交互，实现高效异常监控。Lucchetti 等[37]则从理论层面拓展了对图神经网络应用潜力的认识，指出图神经网络不仅适用于静态图模式识别，还可作为结构模拟器用于动态场景下的结构运动分析，为探索复杂动态系统中的异常行为提供了新的理论视角。尽管图神经网络在工程实践中已取得初步成效，目前研究仍主要停留于纯粹的数据驱动范式。由于缺乏物理机制的引导与约束，现有方法普遍存在模型可解释性较差、泛化能力不足等问题，这已成为制约图神经网络进一步发展的关键挑战。如何将图结构学习与物理规律深度融合，有望成为下一阶段研究的重点方向。

1.5 本文主要研究问题和章节内容

1.5.1 研究内容及思路

目前超声导波技术由于具有经济性、准确性、安全性等各方面优势，已经成为板材结构检测的最佳方案之一。但是复合板材的层间各向异性特征使得损伤信号很容易被材料本构的复杂性所淹没，提取难度很大。目前已有许多学者对复合板材超声导波检测进行了相关研究，也取得了一定成果，但仍存在一些不足，具体表现为如下几个方面。

（1）现有的模型大多只停留在纯数据驱动的模式上，没有把超声导波的物理机理纳入其中。造成模型在小样本条件下，不能从有限的损伤信号中自动获取稳健、可解释的损伤特征，不能建立有效的物理约束处理机制，当训练数据不能充分覆盖损伤类型或者工况变化时，模型的泛化能力急剧下降，不能适应实际检测中复杂多变的缺陷识别需求。

（2）现有的模型把阵列信号看作彼此独立的通道，主要研究各个通道的幅值、频谱以及它们之间的关系，而没有直接建模和利用阵列信号的相位。实际上各个阵元信号之间的相位差就是导波到达时序和波程差，它包含着损伤的方位、距离、传播路径等重要的空间信息。把阵列当作彼此无关的独立传感器，实际上就放弃了波

场的空间相干性，使得基于相位控制的聚焦和干涉定位方法无法实现。

因此，基于以上问题，本文的解决方案和研究思路如下：

（1）针对问题 1 模型缺乏物理引导、小样本下泛化能力受限的问题，本文提出了一种物理异构图神经网络模型，该模型根据先验物理知识引导设计，将板材的物理传播模型、阵列探头的几何空间尺寸与经典机器学习方案相结合，从而将物理规律作为归纳偏置注入网络，有效简化了模型对深层损伤特征的学习难度，使模型在小规模样本下也能自动捕捉具有物理可解释性的稳健损伤表征，显著增强模型在不同损伤类型和工况下的泛化性能与分类精度。

（2）针对问题 2 现有模型忽视阵列信号相位，本课题通过将分数阶希尔伯特变换嵌入进图卷积神经网络当中，提出一种复数自适应图卷积网络来分别融合阵列信号的幅度特征和相位特征。在该网络中，通过设计双向令牌机制和时频双分支充分提取各信号片段内容的幅度特征。并在此基础上，利用多元高斯分布对各阵元信号间的相关关系进行概率拟合，自适应建立信号的拓扑图结构，进而在复数图卷积过程中协同聚合幅度与相位信息。通过直接挖掘阵列的相位差与波程差隐含的空间线索，该网络能够有效实现相干聚焦与精确定位，大幅提升复合板材损伤检测的分辨率与可靠性。

1.5.2 论文结构及章节内容

针对当前研究的主要问题，本文进行了对应的研究和实验验证工作，本文的主要章节内容如下。

第一章，绪论。主要介绍了复合板材超声导波无损检测研究的背景和意义，简要的阐述了当前现有处理超声导波的传统信号处理方案和基础神经网络方案，着重给出了图神经网络在该领域内容研究现状，总结了当前研究所面临的问题，并针对性地开展了本文的研究内容。

第二章，超声导波信号的基础理论。首先说明了超声导波信号的相关理论知识，并在其基础上分析了兰姆波场的传播模态和频散曲线，建立其在板材探伤方面的模型，为后续的工作建立了相应的理论基础。

第三章，基于物理异构图神经网络的损伤定位模型。提出一种物理异构图神经网络框架，用以复合板材的无损检测。首先利用导波传播的频率不变性，设计了一

种用于信道间和信道内的物理知情多粒度自关注机制来抑制噪声信号的干扰。然后，构造一个物理异构图卷积提取器来挖掘先验物理几何，从而实现结构感知特征聚合。最后，实验结果表明，所提出的模型优于几个著名的诊断模型，并在决策过程中证明了其优越的物理可解释性。

第四章，基于复数自适应图卷积网络的损伤定位模型。提出了一种复数自适应图卷积网络框架。通过自适应图学习模块将邻接矩阵参数化为复数权重，实部建模幅值耦合、虚部刻画相位同步，从数据中自主挖掘传感器间动态隐性关联，并设计分数阶希尔伯特图卷积网络，同步提取幅值和相位特征，克服频散混叠。在测试数据集上，该方法分类准确率较第三章模型有所提高，且优于其他主流方法，验证了复数编码与自适应图学习的协同增益。

第五章，结论。总结分析了本文的研究工作与成果，说明了相关的创新点和后续有价值的研究方向。

第 2 章 超声导波信号的基础理论

2.1 引言

兰姆波是薄板结构中的一种典型的导波，由于传播距离远、能量衰减小、对结构损伤高度敏感，已经成为结构健康监测领域的重要技术。随着航空航天、交通运输、建筑业等各个领域对于结构健康监测的需求越来越大，兰姆波在板结构损伤识别中所起的作用也越来越重要。准确地识别损伤要了解损伤的基本理论和传播规律。

本章对兰姆波的基础理论进行阐述。首先介绍基本概念和物理本质，然后分析传播特性，即理论频散方程的推导、传播速度的计算方法、兰姆波固有的多模态和频散特性。这些理论为认识兰姆波和结构损伤之间的关系打下了基础。

2.2 弹性波的基础理论

2.2.1 弹性波的基本概念

弹性介质中，质点间通过弹性恢复力相互联系，局部扰动会以机械波的形式向外传播，这种波称为弹性波。在无限均匀的理想弹性体中，弹性波仅以体波形式存在，主要包括纵波和横波两类，不存在边界面所产生的反射、折射以及表面波。纵波，又称压缩波或无旋波，质点的振动方向与波的传播方向平行，使介质发生体积胀缩；横波，又称剪切波或等容波，质点振动方向与传播方向垂直，引起介质发生剪切形变。在无界的均匀介质中，二者各自以恒定的速度独立传播，不发生波形转换和能量耦合，且无频散现象。这样的体波特性构成了地震波理论及弹性动力学的基础，在工程抗震、地质勘探、无损检测和材料动态力学性能表征等方面发挥着重要作用。

2.2.2 弹性波的波动方程

在各向同性均匀弹性介质中，质点运动满足 Navier-Cauchy 控制方程：

$$\mu\nabla^2\vec{u}+(\lambda+\mu)\nabla(\nabla\cdot\vec{u})=\rho\frac{\partial^2\vec{u}}{\partial t^2} \tag{2-1}$$

其中 $\vec{u}=(x,y,z,t)$ 为时变位移向量场，μ 和 λ 是材料的拉梅常数，ρ 为材料密度。

对位移矢量进行亥姆霍兹分解，有：

$$\vec{u}=\nabla\phi+\nabla\times\vec{\psi},\qquad \nabla\cdot\vec{\psi}=0 \tag{2-2}$$

将式(2-2)代入式(2-1)，通过分离变量和矢量恒等式可得：

$$\nabla[(\lambda+2\mu)\nabla^2\phi-\rho\frac{\partial^2\phi}{\partial t^2}]+\nabla\times[\mu\nabla^2\vec{\psi}-\rho\frac{\partial^2\vec{\psi}}{\partial t^2}]=0 \tag{2-3}$$

显然式(2-3)取等的条件是梯度和旋度分别为零，由此总波场分解成了两个简单的波动方程，一个表示纵波，另一个表示横波：

$$\nabla^2\phi=\frac{\rho}{\lambda+2\mu}\cdot\frac{\partial^2\phi}{\partial t^2}\triangleq\frac{1}{c_L^2}\frac{\partial^2\phi}{\partial t^2} \tag{2-4}$$

$$\nabla^2\vec{\psi}=\frac{\rho}{\mu}\cdot\frac{\nabla^2\vec{\psi}}{\nabla t^2}\triangleq\frac{1}{c_T^2}\frac{\partial^2\vec{\psi}}{\partial t^2} \tag{2-5}$$

式中，c_L 表示纵波波速，c_T 表示横波波速。

2.3 兰姆波的理论基础

2.3.1 兰姆波的基本概念

兰姆波是由英国力学家 Horace Lamb 于 20 世纪初首次从理论上证明的一种在薄板结构中传播的弹性波。由于薄板存在上下边界，板内的横波与纵波并非独立传播的基本波，而是在边界处反复反射、发生模态转换并相互耦合形成整体振动。这些复杂的波动经叠加干涉，最终构成具有稳定波形的导波模式，如图 2-1 所示。

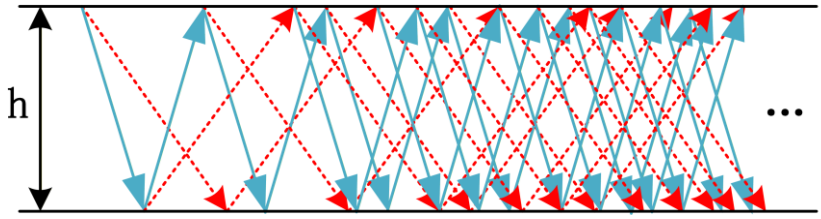


图 2-1 兰姆波传播示意图

作为一种弹性波，兰姆波是薄板中经上下表面耦合形成的超声导波，能量约束在板内，单点激励即可长距离传播、覆盖全板。遇缺陷会发生反射、散射和模式转换，通过接收信号变化实现定位与评估，特别适用于飞机蒙皮、储罐等大面积薄壁结构。目前，主要采用压电换能器或激光超声等手段进行激励与接收，以快速筛查腐蚀、分层等损伤。兰姆波固有的多模态与频散效应使信号解读困难，通常需借助短时傅里叶变换、小波变换等时频分析进行模式分离和色散补偿。

2.3.2 兰姆波的波动方程

兰姆波的几何模型如图 2-2 所示，两个表面 $z=0$ 和 $z=-d$ 为上下边界。

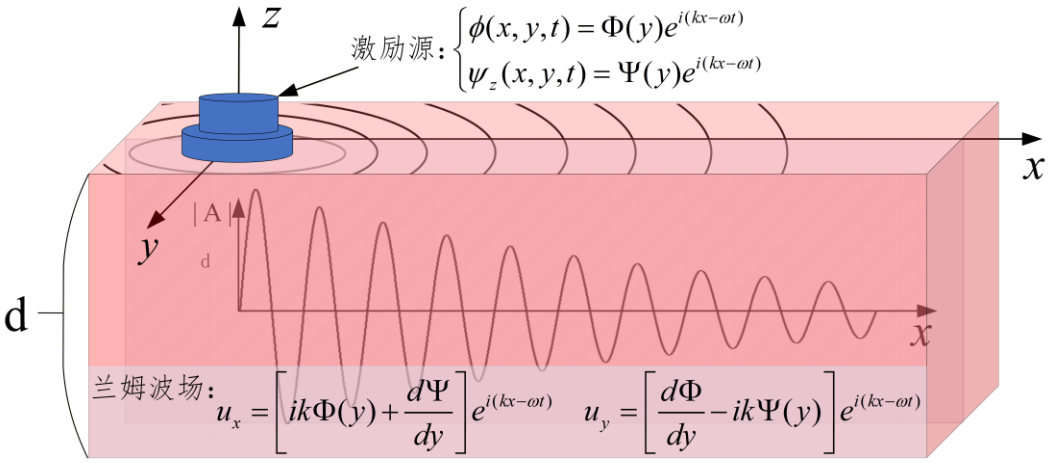


图 2-2 兰姆波分析坐标系

考虑到板材上下边界对波场的强约束作用及水平剪切波与兰姆波相互解耦，在此只考虑平面内应变，故波长信号与 y 坐标无关，式(2-2)中的矢量势可进一步简化为 $\vec{\psi}=(0,\psi_y,0)$。此时式(2-4)和式(2-5)满足如下波动方程：

$$\frac{\partial^2\phi}{\partial x^2}+\frac{\partial^2\phi}{\partial z^2}=\frac{1}{c_L^2}\frac{\partial^2\phi}{\partial t^2} \tag{2-6}$$

$$\frac{\partial^2\psi_y}{\partial x^2}+\frac{\partial^2\psi_y}{\partial z^2}=\frac{1}{c_T^2}\frac{\partial^2\psi_y}{\partial t^2} \tag{2-7}$$

设波动沿 x 方向传播，波数为 k，角频率为 ω。势函数的解可写为简谐形式：

$$\phi=\Phi(z)e^{i(kx-\omega t)} \tag{2-8}$$

$$\psi_y=\Psi(z)e^{i(kx-\omega t)} \tag{2-9}$$

代入式(2-6)和式(2-7)，可得关于 $\Phi(z)$ 和 $\Psi(z)$ 的常微分方程通解：

$$\Phi(z)=A_1\sin(pz)+A_2\cos(pz) \tag{2-10}$$

$$\Psi(z)=B_1\sin(qz)+B_2\cos(qz) \tag{2-11}$$

其中，定义了纵波的横向波数 $p^2=\omega^2/c_L^2-k^2$ 和横波的横向波数 $q^2=\omega^2/c_T^2-k^2$。

2.3.3 兰姆波的频散方程

将简化后的标量势和矢量势代入式(2-1)求解可得在亥姆霍兹分解下的位移分量的具体形式：

$$\vec{u}=(u_x,0,u_z,t)=(\frac{\partial\phi}{\partial x}+\frac{\partial\psi_y}{\partial z},\frac{\partial\phi}{\partial z}-\frac{\partial\psi_y}{\partial x},0) \tag{2-12}$$

则将势函数简谐方程式(2-8)和式(2-9)代入式(2-12)得到位移场的频域-波数表达式：

$$u_x=[ik\Phi(z)+\frac{\mathrm{d}\Psi}{\mathrm{d}z}]e^{i(kx-\omega t)} \tag{2-13}$$

$$u_z=[\frac{\mathrm{d}\Phi}{\mathrm{d}z}-ik\Psi(z)]e^{i(kx-\omega t)} \tag{2-14}$$

同时，相应的应力分量σ_z和τ_{zx}由本构关系给出：

$$\sigma_z=\lambda(\frac{\partial u_x}{\partial x}+\frac{\partial u_z}{\partial z})+2\mu\frac{\partial u_z}{\partial z} \tag{2-15}$$

$$\tau_{zx}=\mu(\frac{\partial u_x}{\partial z}+\frac{\partial u_z}{\partial x}) \tag{2-16}$$

由此通过式(2-10)和式(2-11)的势函数通解、式(2-13)和式(2-14)的位移场方程、式(2-15)和式(2-16)的应力本构关系构成了六个表达式。根据势函数的奇偶性和物理边界条件约束下，方程组可进一步分为对称模式：

$$\begin{cases}\Phi(z) & =A_2\cos(pz)\\ \Psi(z) & =B_1\sin(qz)\\ u_x & =[ik\Phi(z)+\dfrac{\mathrm{d}\Psi}{\mathrm{d}z}]e^{i(kx-\omega t)}\\ u_z & =[\dfrac{\mathrm{d}\Phi}{\mathrm{d}z}-ik\Psi(z)]e^{i(kx-\omega t)}\\ \sigma_z|_{z=0,d} & =\lambda(\dfrac{\partial u_x}{\partial x}+\dfrac{\partial u_z}{\partial z})+2\mu\dfrac{\partial u_z}{\partial z}=0\\ \tau_{zx}|_{z=0,d} & =\mu(\dfrac{\partial u_x}{\partial z}+\dfrac{\partial u_z}{\partial x})=0\end{cases} \tag{2-17}$$

和反对称模式：

$$\begin{cases}\Phi(z) & =A_1\sin(pz)\\ \Psi(z) & =B_2\cos(qz)\\ u_x & =[ik\Phi(z)+\dfrac{\mathrm{d}\Psi}{\mathrm{d}z}]e^{i(kx-\omega t)}\\ u_z & =[\dfrac{\mathrm{d}\Phi}{\mathrm{d}z}-ik\Psi(z)]e^{i(kx-\omega t)}\\ \sigma_z|_{z=0,d} & =\lambda(\dfrac{\partial u_x}{\partial x}+\dfrac{\partial u_z}{\partial z})+2\mu\dfrac{\partial u_z}{\partial z}=0\\ \tau_{zx}|_{z=0,d} & =\mu(\dfrac{\partial u_x}{\partial z}+\dfrac{\partial u_z}{\partial x})=0\end{cases} \tag{2-18}$$

经过推导整理，对称模态的频散方程为：

$$\frac{\tan(qd/2)}{\tan(pd/2)}=-\frac{4k^2pq}{(q^2-k^2)^2} \tag{2-19}$$

反对称模态的频散方程为：

$$\frac{\tan(qd/2)}{\tan(pd/2)}=-\frac{(q^2-k^2)^2}{4k^2pq} \tag{2-20}$$

式(2-19)和式(2-20)统称为频散方程。该方程建立了角频率 ω 与波数 k 之间的隐式关系，是兰姆波相关理论的核心公式。尽管方程简单扼要不涉及太多参数，但只能用数值方案求解，因此导致实际信号处理的难度较高。

2.3.4 兰姆波的传播曲线

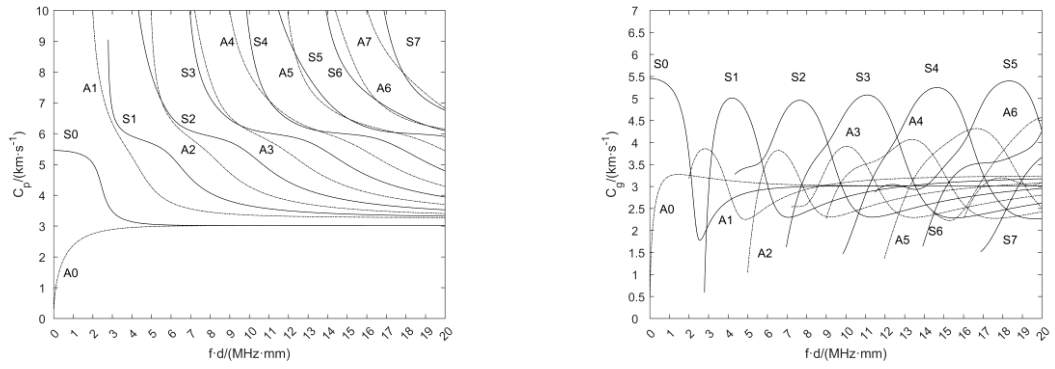
兰姆波的传播速度通常以相速度 c_p 和群速度 c_g 表征描述。相速度指单一频率成分的等相位面沿传播方向的移动速度，定义为：

$$c_p=\frac{\omega}{k} \tag{2-21}$$

群速度则反映波包或能量传播的速度，定义为：

$$c_g=\frac{\mathrm{d}\omega}{\mathrm{d}k}=c_p^2(c_p-\omega\frac{\mathrm{d}c_p}{\mathrm{d}\omega})^{-1}=c_p^2[c_p-(fd)\frac{\mathrm{d}c_p}{\mathrm{d}(fd)}]^{-1} \tag{2-22}$$

其中 fd 为频率厚度积。对于给定的材料参数和频厚积 fd，可获得一系列满足方程的相速度值，每个解对应一种兰姆波模态。为清晰展示其传播特性，通常绘制相速度与群速度随频厚积变化的频散曲线。图 2-3 给出了典型铁板中兰姆波相速度和群速度的频散曲线示意。在低频区域，仅存在基本对称模态 S0 和基本反对称模态 A0，随着频厚积增加，高阶模态依次出现，出现模态数目逐渐增多。各模态的相速度随频率显著变化，这一现象即为频散。



(a)相速度频散曲线　　(b)群速度频散曲线

图 2-3 波包传播频散曲线

2.4 兰姆波探伤的基础理论

前文通过式(2-1)给出了理想无损板中兰姆波的弹性动力学统一描述。当板内出现裂纹、腐蚀或材料退化，导致局部密度 ρ 与弹性张量 $\mathbf{C}$ 发生扰动时，可将该扰动从背景场中分离出来，从而将损伤等效为附加体力源 $\vec{f}_d$。此时控制方程改写为：

$$\mu\nabla^2\vec{u}+(\lambda+\mu)\nabla(\nabla\cdot\vec{u})-\vec{f}_d(\Delta\rho,\Delta\mathbf{C})=\rho\frac{\partial^2\vec{u}}{\partial t^2} \tag{2-23}$$

由于控制方程线性的，总波场可视为无损伤基线波场与损伤散射波场的叠加。在弱散射条件下，采用 Born 近似，总波场可分解为：

$$\vec{u}=\vec{u}^{\text{in}}+\vec{u}^{\text{sc}} \tag{2-24}$$

进一步考虑一发一收的换能器配置，如图 2-4 所示。

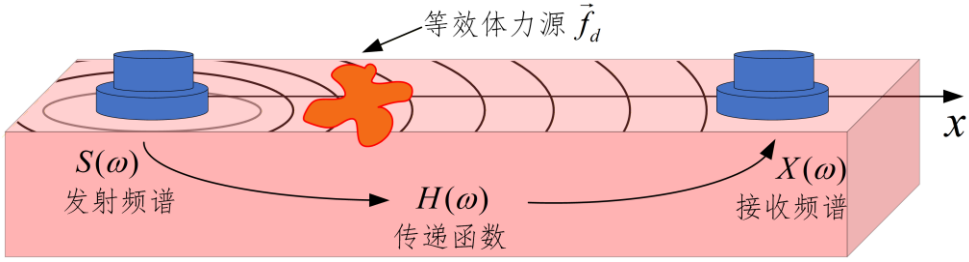


图 2-4 超声接收装置

设发射探头的频谱为 $S(\omega)$，由探头 r_l 发射、探头 r_j 接收的信号频谱为 $X_{lj}(\omega)$。在远场条件下，接收信号近似满足：

$$X_{lj}(\omega)=S(\omega)\cdot G(r_l,r_j,\omega) \tag{2-25}$$

其传递函数为：

$$H_{lj}(\omega)=\frac{X_{lj}(\omega)}{S(\omega)}=G(r_l,r_j,\omega)\approx\frac{C(\omega)}{\sqrt{k(\omega)d_{lj}}}\cdot e^{-\alpha(\omega)d_{lj}}\cdot e^{i(k(\omega)d_{lj}-\frac{\pi}{4})} \tag{2-26}$$

其中，$k(\omega)$ 为波数，$C(\omega)$ 为幅值因子，$\alpha(\omega)$ 为衰减系数。由于发射信号为宽带信号，接收信号在时域上表现为各频率分量响应的叠加。

2.5 本章小结

本章从弹性力学基本方程出发，对兰姆波的基本概念及重要推导过程进行了系统的阐述，给出了相、群速度的定义及计算方法，分析了兰姆波的多模态和频散特性。为兰姆波损伤检测中激励信号的传播路径的分析，信号特征的提取提供的理论基础。

第 3 章 基于物理异构图神经网络的损伤定位模型

3.1 引言

对于当前基于超声导波的板结构损伤定位方案，准确刻画传感器间的非结构化空间拓扑关系与导波传播的物理机理是重要的一环，但在实际部署中，传感器阵列往往呈不规则分布，导致精确的物理建模十分困难，因此，构建由物理信息驱动的异构图神经网络框架具有重要的应用价值。然而，当前的神经网络方法大多将传感器阵列视作规则网格或独立序列，与实际波场传播过程存在显著差距，因此难以对复杂板结构进行有效的空间关系建模和损伤定位。而部分纯数据驱动的方法则完全忽略了导波的先验物理知识，容易受到噪声和边界反射等因素的干扰，影响了定位结果的稳健性。

针对上述问题，本章构建了一种物理异构图神经网络框架。在该框架中，首先根据第二章证明的导波传播的频率不变性，设计了一种用于信道间和信道内的物理知情多粒度自关注机制来抑制噪声信号的干扰。然后，构建物理异构图卷积提取器来挖掘先验物理几何，从而实现结构感知特征聚合。最后，实验结果表明，所提出的物理异构图神经网络优于几个著名的诊断模型，并在决策过程中证明了其优越的物理可解释性。

3.2 基础理论建立

3.2.1 多头注意力机制

注意力机制的设计灵感来源于神经认知科学中有关选择性注意的理论。该理论认为，人类面对海量信息的时候，会本能地把认知资源集中到和当前任务最相关的地方，从而大大提高信息处理的速度和决策的准确性。受到启发，研究者把这一生物现象形式化为可以计算的注意力模型。对于给定的输入特征序列 $\mathbf{X}=\{x_1,x_2,\cdots,x_n\}$，注意力分配过程可表述为：

$$e_i=\mathrm{score}(x_i,q) \tag{3-1}$$

$$\alpha_i = \frac{\exp(e_i)}{\sum_{j=1}^{n}\exp(e_j)} \tag{3-2}$$

其中，q 表示查询向量，score(·) 为得分函数，用于度量输入特征与查询之间的相关性。最终，注意力机制的输出由输入特征依所得权重加权求和得到：

$$\text{Attention}(\mathbf{A}) = \sum_{i=1}^{n}\alpha_i x_i \tag{3-3}$$

在此基础上，进一步扩展了单一注意力函数的表达能力，多头注意力机制作为 Transformer 架构的核心组件被提出。该机制通过并排执行多个独立的注意力计算，使模型能够在不同的表示子空间中联合捕捉序列内部的复杂依赖关系。其数学形式可描述如下，首先，对于输入的查询矩阵 $\mathbf{Q}$、键矩阵 $\mathbf{K}$ 和值矩阵 $\mathbf{V}$，通过 h 组独立学习的线性投影将其映射到不同的子空间：

$$\mathbf{h}_i = f\left(\mathbf{W}_i^{(q)}\mathbf{Q}, \mathbf{W}_i^{(k)}\mathbf{K}, \mathbf{W}_i^{(v)}\mathbf{V}\right) \tag{3-4}$$

其中 $\mathbf{W}_i^{(q)}$、$\mathbf{W}_i^{(k)}$ 与 $\mathbf{W}_i^{(v)}$ 为可学习的参数矩阵，而函数 $f(\cdot)$ 表示注意力汇聚操作。获得所有 h 个头的输出 $\mathbf{h}_1,\ldots,\mathbf{h}_h$ 之后，多头注意力机制通过拼接各头结果并施加一个线性变换 $\mathbf{W}_o$ 生成最终输出：

$$\text{MultiHead}(\mathbf{Q},\mathbf{K},\mathbf{V}) = \mathbf{W}_o\begin{bmatrix}\mathbf{h}_1\\ \vdots \\ \mathbf{h}_h\end{bmatrix} \tag{3-5}$$

该结构使得模型能够同时从不同角度关注输入信息，从而显著增强了对序列内多样化依赖关系的建模能力。

3.2.2 图卷积神经网络

图卷积神经网络是一类专为处理图结构数据而设计的深度学习模型，能够有效应对社交网络、交通路网、分子拓扑等非欧氏空间中的复杂数据关系。通过引入“局部连接”与“权重共享”的卷积思想，该模型实现了对图结构信息的高效特征提取与鲁棒表示学习。

图作为一种由顶点和边构成的数学结构，可形式化地表示为 $\mathcal{G}=\{\mathcal{V},\mathcal{E}\}$，其中 $\mathcal{V}$ 为顶点集合，$\mathcal{E}$ 为边集合。进一步地，图的连接关系可通过邻接矩阵 $\mathbf{A}$ 与度矩阵 $\mathbf{D}$ 加以刻画：

$$\mathbf{A}_{ij}=\begin{cases}1, & \text{if } (v_i,v_j)\subseteq\mathbf{E}\\ 0, & \text{otherwise}\end{cases} \tag{3-6}$$

$$\mathbf{D}_{ii}=\sum_j \mathbf{A}_{ij} \tag{3-7}$$

图卷积神经网络的核心思想在于通过聚合邻域节点的信息来迭代更新当前节点的特征表示。基于谱图理论，经典的图卷积操作通常借助图的拉普拉斯矩阵$\mathbf{L}=\mathbf{D}-\mathbf{A}$来定义。具体而言，拉普拉斯矩阵可进行如下特征分解：

$$\mathbf{L}=\mathbf{U}\mathbf{\Lambda}\mathbf{U}^{\top} \tag{3-8}$$

其中，$\mathbf{U}$为特征向量矩阵，$\mathbf{\Lambda}$为由特征值构成的对角矩阵。在图傅里叶域中，对于信号$\mathbf{x}$的卷积运算可表达为滤波器g_θ与信号的乘积：

$$g_\theta * \mathbf{x}=\mathbf{U}g_\theta(\mathbf{\Lambda})\mathbf{U}^{\top}\mathbf{x}=g_\theta(\mathbf{L})\mathbf{x} \tag{3-9}$$

然而，上述谱域卷积依赖于拉普拉斯矩阵的特征分解，计算代价高昂，难以直接应用于大规模图。为降低复杂度，研究者进一步采用归一化拉普拉斯矩阵来近似卷积传播过程：

$$\mathbf{y}=g_\theta(\mathbf{L}_{\text{sym}})\mathbf{x}=g_\theta(\mathbf{D}^{-\frac{1}{2}}\mathbf{A}\mathbf{D}^{-\frac{1}{2}})\mathbf{x} \tag{3-10}$$

据此，图卷积网络经典的逐层传播规则可表述为：

$$\mathbf{H}^{(l+1)}=\sigma(\mathbf{D}^{-\frac{1}{2}}\mathbf{A}\mathbf{D}^{-\frac{1}{2}}\mathbf{H}^{(l)}\mathbf{W}^{(l)}) \tag{3-11}$$

式中，$\mathbf{A}=\mathbf{A}+\mathbf{I}_N$表示添加了自环的邻接矩阵，用以保留节点自身的特征信息；$\mathbf{D}$为$\mathbf{A}$对应的度矩阵；$\mathbf{H}^{(l)}$为第l层的节点特征矩阵；$\mathbf{W}^{(l)}$是该层可训练的权重矩阵；$\sigma(\cdot)$代表非线性激活函数。该设计在保留图拓扑结构先验的同时，实现了高效且可扩展的半监督节点表示学习。

3.3 物理异构图神经网络框架的设计

在充分运用超声导波信号处理理论和机器识别相关理论上，提出物理信息多粒度自注意力机制和物理异构图卷积提取器两个模块，旨在优化损伤信号的增强和提取，并最终级联而成构建物理异构图神经网络框架，从而端到端的进行损伤区域分类。

3.2.1 物理信息多粒度自注意力机制

超声导波传播时，由于频散效应，不同频率分量的波数非线性变化，波包时域

上展宽、畸变。激励信号中包含的频率成分在传播过程中各自保持频率不变，但是材质的频散特性会使各个频率分量的相速度产生差异，从而破坏波包原有的完整性与紧凑性。因此，用整体波形建模的传统信号处理方法遇到很大的困难。但是频率在传播过程中保持不变的物理性质，给用频谱或者时频的角度来建立数据驱动模型打下了坚实的基础。本文提出了一种物理信息引导的多粒度自注意力机制，从导波信道内、信道间两个粒度来对信号进行关联建模，从多视角去捕捉不同的尺度特征交互模式。

在信道间重要性建模方面，需要重点关注不同导波信道与损伤定位之间的关联关系，损伤会在空间上引起各传感器接收信号的差异化响应。为此，引入多头自注意力机制，通过计算查询与键之间的相似度，为各个传感器动态分配关注权重。具体地，给定原始信号矩阵 $\mathbf{X}\in\mathbb{R}^{N\times L}$，其中 N 为传感器数，L 为信号长度。首先沿特征维度将 L 均匀划分为 m 个相互独立的子空间，每个子空间维度 $d_h=L/m$。对第 i 个子空间，通过可学习的投影矩阵 $\mathbf{W}_i^Q,\mathbf{W}_i^K,\mathbf{W}_i^V\in\mathbb{R}^{L\times d_h}$ 在各自子空间内线性投影得到查询、键和值：

$$\mathbf{Q}_i=\mathbf{X}\mathbf{W}_i^Q,\quad \mathbf{K}_i=\mathbf{X}\mathbf{W}_i^K,\quad \mathbf{V}_i=\mathbf{X}\mathbf{W}_i^V \tag{3-12}$$

随后，在第 i 个子空间内计算传感器特征间的缩放点积注意力，经激活函数 softmax 归一化后对值进行聚合，得到该注意力头的输出：

$$\mathbf{h}_i=\mathrm{softmax}\left(\frac{\mathbf{Q}_i\mathbf{K}_i^{\top}}{\sqrt{d_h}}\right)\mathbf{V}_i \tag{3-13}$$

最后，将 m 个注意力头的输出 $\mathbf{h}_i$ 沿特征维度拼接，恢复至原始维度，形成信道间增强的特征表示：

$$\mathbf{Y}_t=\mathrm{Concat}(\mathbf{h}_1,\mathbf{h}_2,\ldots,\mathbf{h}_m)\in\mathbb{R}^{N\times L} \tag{3-14}$$

该机制以完全数据驱动的方式学习各传感器之间的交互权重，能够自动辨识对损伤定位贡献度高的传感器，并灵活捕获跨通道的复杂依赖关系。

在信道内重要性建模中，由式(2-10)和式(2-11)描述的势函数简谐方程可知，系统响应具有频率不变性，即不同频率成分在传播过程中保持相对独立，而损伤往往只对某些特定窄带振荡模式产生调制。为充分利用这一先验知识，需要突出损伤敏感频段并提取时变的局部振荡信息。为此，本研究采用离散小波变换将单信道信号映射至联合时频域，以暴露具有不同时间定位的频谱变化。选用具有紧支撑和正交

特性的 Haar 小波基，其尺度函数 $\phi(t)$ 与小波函数 $\psi(t)$ 分别定义如下：

$$\phi(t)=\begin{cases}1, & 0\le t<1\\ 0, & \text{otherwise}\end{cases} \tag{3-15}$$

$$\psi(t)=\begin{cases}1, & 0\le t<0.5\\ -1, & 0.5\le t<1\\ 0, & \text{otherwise}\end{cases} \tag{3-16}$$

对于第 n 个传感器采集到的离散信号 $X_n[t]$，单层小波分解给出近似系数 $a_n[k]$ 与细节系数 $d_n[k]$：

$$a_n[k]=\sum_{t=1}^{L}X_n[t]\phi(2t-k) \tag{3-17}$$

$$d_n[k]=\sum_{t=1}^{L}X_n[t]\psi(2t-k) \tag{3-18}$$

近似系数刻画信号的低频概貌，细节系数则捕获高频瞬变与局部振荡。

为了便于批量处理并与后续注意力模块无缝衔接，可将上述小波分解过程统一为线性变换。构造正交小波变换矩阵 $\mathbf{W}_{\mathrm{DWT}}\in\mathbb{R}^{L\times L}$，其前 $L/2$ 行由尺度函数 $\phi(2t-k)$ 在不同平移 k 的离散采样组成，后 $L/2$ 行由小波函数的离散采样 $\psi(2t-k)$ 组成，且满足 $\mathbf{W}_{\mathrm{DWT}}\mathbf{W}_{\mathrm{DWT}}^{\top}=\mathbf{I}$。对于包含 N 条信道的信号矩阵 $\mathbf{X}\in\mathbb{R}^{N\times L}$，频域系数矩阵可直接通过线性变换获得：

$$\mathbf{C}_f=\mathbf{X}\mathbf{W}_{\mathrm{DWT}}^{\top}\in\mathbb{R}^{N\times L} \tag{3-19}$$

其中 $\mathbf{C}_f$ 的前 $L/2$ 列对应近似系数，后 $L/2$ 列对应细节系数。这样得到的系数矩阵既保留了时频局部化信息，又为后续的自适应频率增强提供了结构化的特征表示。在此基础上，将 $\mathbf{C}_f$ 视为变换后的频域特征，采用与式(3-12)-式(3-14)相同的多头自注意力机制，对频率维度进行上下文建模。具体而言，将每个频率系数位置看作一个词元，通过可学习的线性投影生成查询、键和值，计算缩放点积注意力，从而自适应地聚合全局频率信息：

$$\mathbf{C}'_f=\mathrm{MHA}(\mathbf{C}_f) \tag{3-20}$$

其中多头注意力则自动增强与损伤状态高度相关的频率成分，同时抑制噪声和无关频带。随后，利用逆离散小波变换将其映射回时域，完成信号的增强重构：

$$\mathbf{Y}_f=\mathbf{C}'_f\mathbf{W}_{\mathrm{IDWT}}^{\top}, \tag{3-21}$$

其中逆变换矩阵 $\mathbf{W}_{\mathrm{IDWT}}$ 满足 $\mathbf{W}_{\mathrm{IDWT}}=\mathbf{W}_{\mathrm{DWT}}^{-1}$，因此当 $\mathbf{C}'_f=\mathbf{C}_f$ 时可保证 $\mathbf{Y}_f=\mathbf{X}$，实现信号的完整重构。

为将信道间与信道内两种互补表征进行整合，同时保留原始信号的底层结构，以确保模型既不丢失全局空间依赖，又能捕捉局部时频细节。采用可学习的加权残差连接实现融合：

$$\mathbf{Z} = \mathbf{X} + \alpha \cdot \mathbf{Y}_t + \beta \cdot \mathbf{Y}_f \tag{3-22}$$

其中 $\alpha, \beta \in \mathbb{R}$ 为可训练的权重，通过反向传播在训练过程中自动学习最优平衡策略。这种设计赋予模型充分的灵活性，使其能根据当前数据分布动态调节全局信道依赖与局部振荡特征在最终表示中的贡献度，从而为后续损伤识别与定位任务提供更具判别力的特征表达。

3.3.2 物理异构图卷积提取器

在实际检测中，传感器接收到的信号往往呈现为基线响应与损伤散射特征高度混叠的复杂波形。为了从这种混合信号中有效解耦并辨识出微弱的损伤信息，必须借助合理的物理机制对入射、散射成分进行分离，并在此基础上实现损伤的定量反演。为此，本研究基于先验物理机理，构建了一种物理信息引导的信号分解与反演框架，将波动方程、Born 近似与异构图神经网络深度融合，以端到端的方式完成从测量信号到损伤表征的逆映射。

为实现式(2-24)所示物理正向过程的逆映射，从接收信号中反演等效源强度 $\vec{s}_j$，本研究构建了一种有向异构图 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$。其中，节点集合 $\mathcal{V}$ 由物理测量节点 $\mathcal{V}_p$ 与虚拟损伤节点 $\mathcal{V}_d$ 共同构成，即 $\mathcal{V} = \mathcal{V}_p \cup \mathcal{V}_d$。$\mathcal{V}_p$ 对应于实际的“激励－接收”探头对，其初始特征由前述物理信息多粒度自注意力机制提取的特征 $\mathbf{Z}$ 进行赋值；$\mathcal{V}_d$ 则代表潜在的损伤位置，其初始特征设为零向量。异构图的边集 $\mathcal{E}$ 严格遵循声束覆盖的物理原理加以定义：仅当虚拟损伤节点 v_j^d 位于物理节点 v_k^p 所对应的声束主覆盖区域 $\mathcal{S}_k$ 内时，二者之间方才建立连接。据此，边集 $\mathcal{E}$ 可形式化表示为：

$$\mathcal{E} = \left\{ (v_k^p, v_j^d) \mid \forall k \in [1, N_p], \forall j \in \mathcal{S}_k \right\} \tag{3-23}$$

为量化不同虚拟损伤节点对测量路径的贡献差异，本研究构建了边权重度量函数。设第 k 个探头对的主声轴直线为 L_k，其端点分别为 T_k^{src} 与 T_k^{rcv}。定义主声轴 L_k 的垂直距离 $d_{kj}^{\perp}$ 不大于波束半宽 r 的区域为该探头有效探测范围 $\mathcal{S}_k$，在此范围内的虚拟损伤节点 v_j^d 可能对探头对 $\mathcal{K}_k$ 的测量产生影响：

$$r_{kj} = \mathbb{I}\left(d_{kj}^{\perp} \le r \right) \tag{3-24}$$

表 3-1 物理测量节点与虚拟损伤节点的异构图构建

算法 1：物理测量节点与虚拟损伤节点的异构图构建

输入：探头坐标集合 $\mathcal{T}=\{(x_m,y_m)\}$，探头对列表 $\mathcal{K}=\{(T_n^{\mathrm{src}},T_n^{\mathrm{rcv}})\}$，损伤探测区域 $\mathcal{A}\subset\mathbb{R}^2$，损伤网格数量 N_d，波束半宽 r

输出：异构图边集 $\mathcal{E}$

节点定义：

将每个探头对 $(T_n^{\mathrm{src}},T_n^{\mathrm{rcv}})$ 定义为物理测量节点 v_k^p

将区域 $\mathcal{A}$ 离散化为 N_d 个网格单元，每个单元定义为虚拟损伤节点 v_j^d

边集计算：

$\mathcal{E}\leftarrow\varnothing$

for 每个探头对 $k=1$ 到 N_p ***do***

$(x_{\mathrm{src}},y_{\mathrm{src}})\leftarrow T_k^{\mathrm{src}},(x_{\mathrm{rcv}},y_{\mathrm{rcv}})\leftarrow T_k^{\mathrm{rcv}}$

$L_k\leftarrow\mathrm{LineSegment}((x_{\mathrm{src}},y_{\mathrm{src}}),(x_{\mathrm{rcv}},y_{\mathrm{rcv}}))$

$\mathcal{D}_k\leftarrow\mathrm{GenerateParallelLines}(L_k,r,\Delta d)$

$\mathcal{S}_k\leftarrow\varnothing$

for 每条探测线 $D_i\in\mathcal{D}_k$ ***do***

for 每个损伤节点 v_j^d ***do***

if D_i 与 v_j^d 对应的网格单元相交 ***then***

$\mathcal{S}_k\leftarrow\mathcal{S}_k\cup\{j\}$

end if

end for

end for

$\mathcal{S}_k\leftarrow\mathrm{Unique}(\mathcal{S}_k)$

for 每个 $j\in\mathcal{S}_k$ ***do***

$\mathcal{E}\leftarrow\mathcal{E}\cup\{(v_k^p,v_j^d)\}$

end for

end for

return $\mathcal{E}$

其中 $\mathbb{I}(\cdot)$ 为指示函数，当条件成立时取值为 1，否则为 0。将节点排序为物理测量节

点在前、虚拟损伤节点在后，则整体邻接矩阵 $\mathbf{A}\in\mathbb{R}^{(N_p+N_d)\times(N_p+N_d)}$ 具有分块稀疏结构：

$$\mathbf{A}=\begin{bmatrix}\mathbf{0}_{N_p\times N_p} & \mathbf{R}\\ \mathbf{0}_{N_d\times N_p} & \mathbf{0}_{N_d\times N_d}\end{bmatrix} \tag{3-25}$$

具体边集构造算法详见表 3-1 的算法，将此邻接矩阵 $\mathbf{A}$ 和零填充后的节点向量 Z' 应用于式(3-11)的前向传播公式，可实现先验物理机制上的散射源强度隐式求解。经过多次迭代更新，节点特征 $\mathbf{H}$ 中逐步编码了损伤位置与强度信息的隐式表征。

3.3.3 物理异构图神经网络的设计

基于前述的物理信息多粒度自注意力机制与物理异构图卷积提取器，本章构建了一种面向复合板材的损伤定位深度学习网络。其具体训练流程如表 3-2 所示，网络总体架构如图 3-1 所示。该网络能够充分融合多源监测信息的时空特征，从而显著提升超声导波板材损伤定位的准确性与泛化能力。

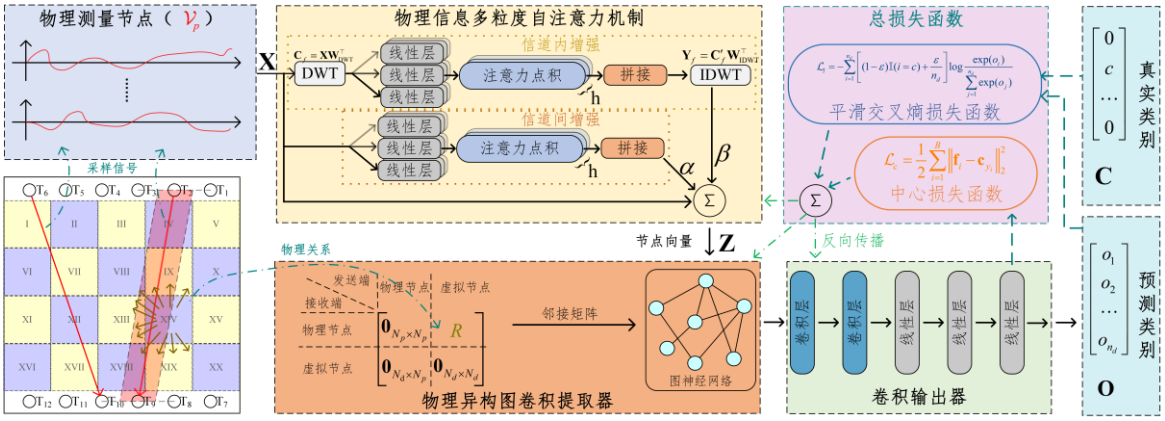


图 3-1 物理异构图神经网络结构框架图

完整的损伤定位流程包含以下几个步骤：

（1） 数据采集与预处理：从部署于板材表面的多通道超声波换能器阵列中采集原始导波监测数据，随后对信号依次执行异常值剔除与同步对齐等预处理操作，以形成满足模型输入要求的规范化信号样本。

（2） 物理信息多粒度自注意力特征提取：将预处理后的传感器序列输入物理信息多粒度自注意力模块。该模块融合卷积结构与注意力机制，深入捕获信号序列内部的依赖关系及退化趋势特征，进而提取出传感器节点的高维时序表示。

（3） 物理异构图卷积信息传播与散射源反演：通过物理异构图卷积分类器，在预先构建的异构边集约束下进行信息传播。该异构边集由物理测量节点与虚拟损

伤节点两类节点连接而成。在图卷积层的模拟扩散过程中，信息由测量节点沿预设的物理连接路径定向传播至虚拟损伤节点，并逐步更新后者的特征表示。这一过程在先验物理特征的约束下，实现了从观测信号到散射源分布的反向推理。

表 3-2 物理异构图神经网络方法训练流程

算法 2：物理异构图神经网络方法训练流程

输入：带标签训练数据集$\{\mathbf{X}, y\}$，探头物理参数$\{\mathcal{T}, \mathcal{K}, r\}$，损伤探测参数$\{\mathcal{A}, N_d\}$，小批量大小$B$，学习率$\eta_t$，平滑因子$z$，超参数$\delta$，迭代轮数$T$

输出：训练完成的模型参数θ_T

初始化模型参数θ_0

构建小波变换矩阵$\mathbf{W}_{\text{DWT}}$，并计算逆变换矩阵$\mathbf{W}_{\text{IDWT}} = \mathbf{W}_{\text{DWT}}^{-1}$

依据表 3-1 的算法计算异构图边集$\mathcal{E}$

for 迭代轮数$\text{iter} = 1$ ***to*** T ***do***

  for 每个小批量数据 ***do***

    根据式(3-12)至式(3-14)计算通道内增强特征$\mathbf{Y}_{\text{time}}$

    计算离散小波变换$\mathbf{C}_{\text{freq}} = \mathbf{X}_b \mathbf{W}_{\text{DWT}}^{\top}$增强特征后，按式(3-21)进行逆变换$\mathbf{Y}_{\text{freq}}$

    根据式(3-22)融合两分支并引入残差连接：$\mathbf{Z} = \mathbf{X}_b + \alpha \cdot \mathbf{Y}_{\text{time}} + \beta \cdot \mathbf{Y}_{\text{freq}}$

    将增强特征$\mathbf{Z} \in \mathbb{R}^{B \times N_p \times L}$零填充为$\mathbf{Z}' \in \mathbb{R}^{B \times (N_p + N_d) \times L}$

    将$\mathbf{Z}'$与图$\mathcal{G} = \{\mathcal{V}, \mathcal{E}\}$输入图卷积层，根据式计算更新后的节点特征$\mathbf{H}$

    对$\mathbf{H}$执行卷积操作，并经全连接层映射为类别预测概率$\mathbf{O}$

    获取预测类别：$\mathbf{y} = \arg\max_i \mathbf{O}_i$

    根据式(3-27)计算标签平滑交叉熵损失$\mathcal{L}_l$

    根据式(3-28)计算中心损失：$\mathcal{L}_c = \frac{1}{2}\sum_{i=1}^{B} \| \mathbf{f}_i - \mathbf{c}_{y_i} \|_2^2$

    根据式(3-26)计算总损失：$\mathcal{L} = \mathcal{L}_l + \delta \cdot \mathcal{L}_c$

    计算梯度$\nabla_\theta \mathcal{L}$，并采用 Adam 优化器更新模型参数

  end for

end for

return θ_T

（4） 损伤类别映射与定位输出：卷积分类器将更新后的虚拟损伤节点特征图

作为输入，经一维卷积层进一步提取深层特征，最终由全连接层映射为损伤类别的概率预测 $\mathbf{O}$，并输出最终预测类别 $\mathbf{y}=\arg\max_i \mathbf{O}_i$。

为引导模型原始阵列信号 $\mathbf{X}$ 中准确推断损伤类别，本研究设计了一个联合优化目标，包含标签平滑交叉熵损失 $\mathcal{L}_l$ 和中心损失 $\mathcal{L}_c$。总损失函数定义为：

$$\mathcal{L}=\mathcal{L}_l+\lambda\mathcal{L}_c \tag{3-26}$$

其中 λ 为平衡两类损失贡献的超参数。传统的交叉熵损失采用独热标签，容易导致模型对训练样本过度自信，降低泛化能力。为缓解这一问题，引入了标签平滑技术，构造平滑后的标签分布。对于真实类别为 c 的样本，模型输出层第 i 类的逻辑值为 o_i，则 $\mathcal{L}_c$ 可统一表示为：

$$\mathcal{L}_l=-\sum_{i=1}^{n_d}\left[(1-\varepsilon)\mathbb{I}(i=c)+\frac{\varepsilon}{n_d}\right]\log\frac{\exp(o_i)}{\sum_{j=1}^{n_d}\exp(o_j)} \tag{3-27}$$

其中 ε 为平滑因子，$\mathbb{I}(\cdot)$ 为指示函数，当 $i=c$ 时取 1，否则为 0。该损失函数促使模型输出概率分布更加平滑，避免过拟合，从而提升对未知工况的泛化能力。

为进一步增强特征的可判别性，引入了中心损失函数，其通过最小化样本特征与其对应类别中心之间的距离，使得同一损伤类别的特征在嵌入空间中更加聚集：

$$\mathcal{L}_c=\frac{1}{2}\sum_{i=1}^{B}\left\|\mathbf{f}_i-\mathbf{c}_{y_i}\right\|_2^2 \tag{3-28}$$

其中 B 为批大小，$\mathbf{f}_i\in\mathbb{R}^d$ 为分类器倒数第一层输出的特征向量，$\mathbf{c}_{y_i}$ 为第 y_i 类的特征中心。

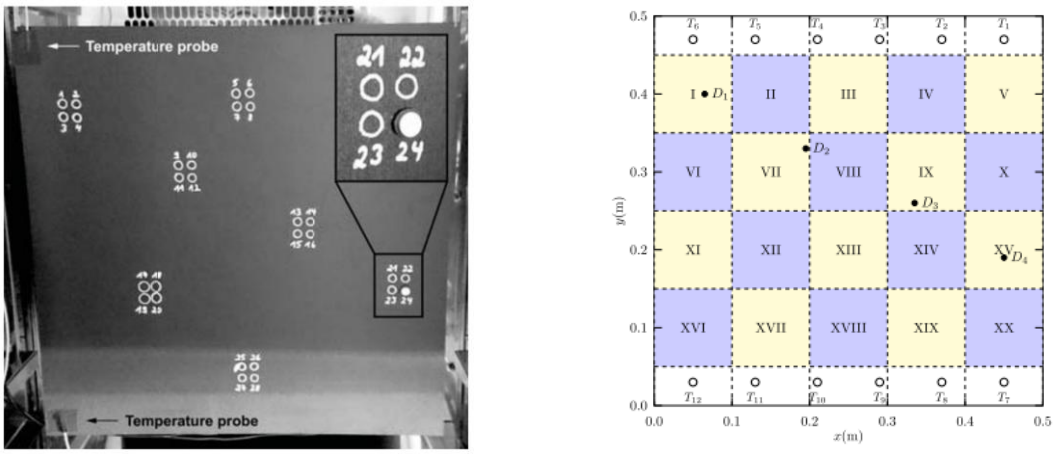
模型采用 AdamW 优化器进行端到端训练，初始学习率设为 1×10^{-3}，中心损失平衡系数 $\lambda=0.01$。学习率采用余弦退火策略动态调整，以稳定收敛并提升泛化性能。通过最小化联合损失 $\mathcal{L}$，模型能够在先验物理特征与监测数据特征的共同引导下，学习到具有强判别力与泛化性能的损伤特征，从而实现高精度的损伤定位。

3.4 实验验证

3.4.1 数据介绍

本次实验数据源自 SHM 导波数据集[38]，该数据集系统采集了温度变化条件下碳纤维增强复合材料板中的超声导波信号，测试环境如图 3-2 所示。实验平台主要由

CFRP 板、恒温箱、超声探头和 PD200 电压放大器构成。实验采用一块尺寸为 500mm×500mm、厚度为2mm 的 CFRP 板，板上布置 12 个直径10mm、厚度0.2mm 的压电传感器，通过可逆铝盘模拟四个不同位置的损伤。数据在恒湿 50%的气候箱中采集，温度范围 20℃至 60℃，步进 0.5℃。在每个温度点下，分别针对五种结构状态进行测试，包括正常状态（NC）和四种典型损伤工况：区域 I 损伤（D_1）、区域 VII 损伤（D_2）、区域 IX 损伤（D_3）和区域 XV 损伤（D_4）。



(a)损伤测试板材实物图　　(b)板材损伤划分示意图

图 3-2 SHM 导波数据实验平台示意图

激励信号采用经汉宁窗调制的 5 周期正弦脉冲，频率覆盖 40kHz 至 260kHz，步长 20kHz。所有激励-接收组合信号通过多路复用技术以一对剩余的方式采集。每个样本由 66 个传感通道的时域波形构成，包含 13108 个采样点，典型信号如图 3-3 所示。

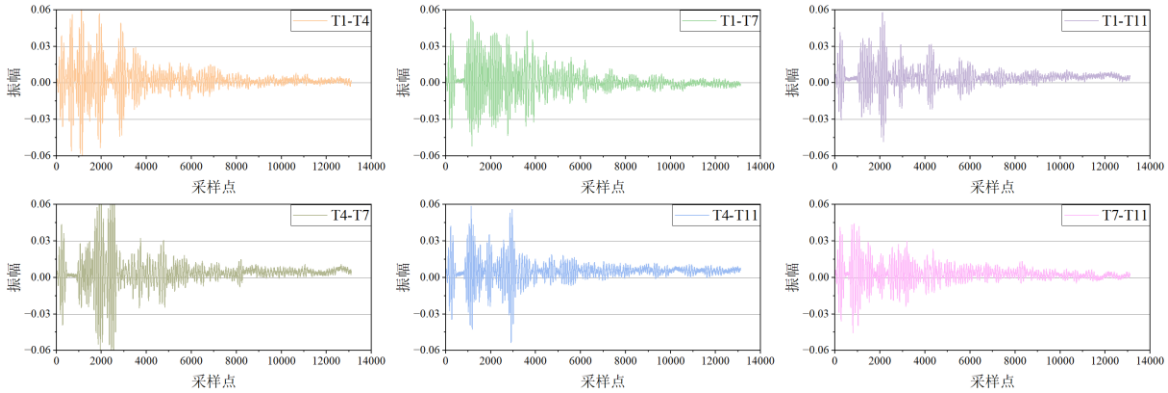


图 3-3 不同激励接收路径典型导波信号示意图

基于上述数据集，本研究构建了单温域和宽温域两种分类场景：单温域场景对某一固定温度点下的导波信号进行损伤检测；宽温域场景则混合多个温度点的信号，

以模拟更复杂的温度变化环境。两类场景的数据集划分如表 3-3 所示，所有数据集均按 4:1 的比例随机划分为训练集与测试集。

表 3-3 分类场景数据集划分列表

单温域分类场景			宽温域分类场景		
数据集名称	温度范围(℃)	样本数量	数据集名称	温度范围(℃)	样本数量
A	20	2600	E	20-25	35620
B	30	6240	F	37-42	37440
C	40	6240	G	55-60	39520
D	50	6500	H	20-23 和 57-60	43680

相较于单温域场景，宽温域场景样本量更大，且模型所受的温度干扰更为显著，从而能够有效评估物理异构图神经网络模型在温度变化下的抗干扰性能。模型详细的超参数设置见表 3-4。

表 3-4 训练超参数列表

变量名	值	变量名	值	变量名	值
学习率	10^{-3}	优化器	AdamW	训练轮次	300
权重退化	10^{-4}	激活函数	ReLU	丢弃率	0.4

3.4.2 实验分析

3.4.2.1 超参数寻优

对于所提出的物理异构图卷积网络模型，导波中心频率对信号解析难度起关键作用。具体而言，频率较低的导波频散信号杂乱，噪声去除难度大；频率较高的导波包含信息较少，难以得到有效区分。

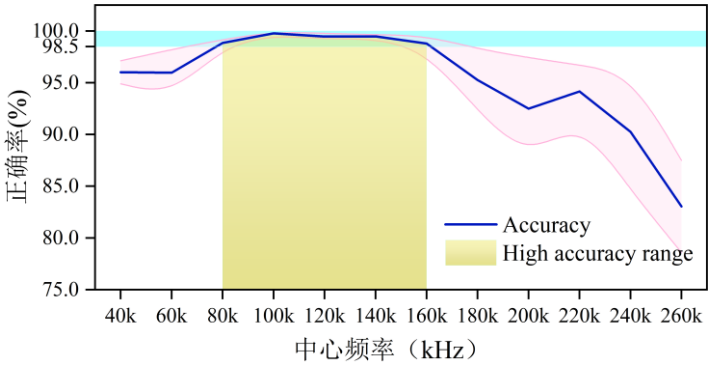
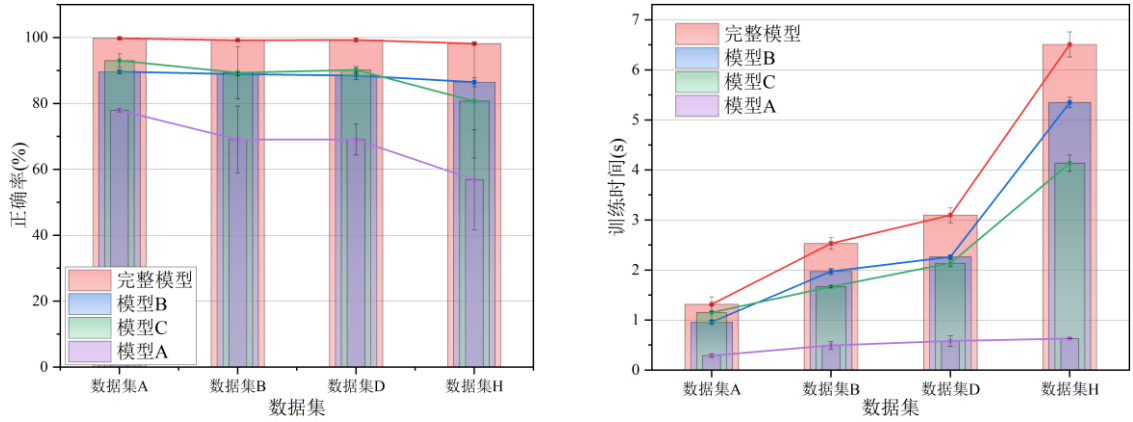


图 3-4 导波中心频率对正确率的影响

因此，以单温域工况下的多个温度点场景为例进行多次实验，图 3-4 展示了不同中心频率下的实验结果。其中频率取值范围为[40, 260]kHz，步长为 20kHz。由图可见，当中心频率在[80,160]kHz 范围内时诊断准确率较高且收敛稳定，故选定此频段中性能最佳的100kHz 作为最终配置。此外，为更严谨地评估物理异构图神经网络的普适性，宽温域分类场景中的中心频率设置与单温域场景保持一致。

3.4.2.2 消融实验

本小节将物理异构图神经网络与三个变体模型进行对比：模型 A（去除物理异构图卷积提取器）、模型 B（去除物理信息多粒度自注意力机制）和模型 C（去除卷积输出器）。所有模型均在单温域和宽温域两种场景下分别进行测试，实验结果如图 3-5 所示。可以明显看出，随着各模块被依次移除，模型的诊断准确率持续下降，训练稳定性也逐渐变差。这些结果充分验证了物理异构图神经网络中物理嵌入及各组成模块的有效性。



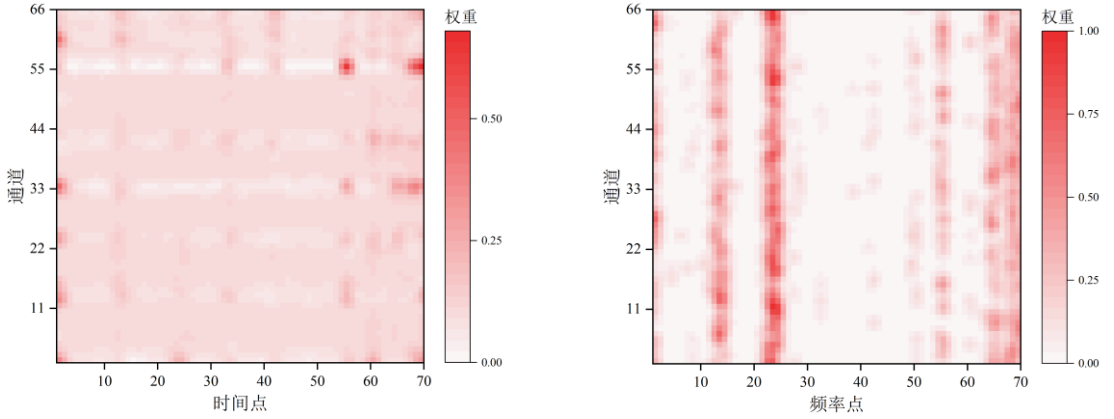
(a)完整网络与变体模型的正确率对比　　(b)完整网络与变体模型的时间对比

图 3-5 完整网络与变体的消融实验结果图

3.4.2.3 单温域工况检测场景

首先，为直观展示所提物理信息多粒度自注意力机制的内在运作方式，图 3-6 分别可视化了经过加权处理后的注意力权重。其中，x 轴分别表示信道间和信道内的采样点序号，y 轴表示信道序号。信道间分支主要通过自适应调整各信道的重要性权重，实现关键信道的筛选。而信道内分支则对特定频率成分表现出较强的关注，这与式(2-26)的分析结果相吻合。上述结果表明，借助先验物理引导的数据驱动策略，模型能够自主的在原始信号中自适应地增强有效特征。

随后，本章基于表 3-3 中构建的单温度分类场景在相同的实验设置下将提出的物



(a)信道间注意力热力图　　(b)信道内注意力热力图

图 3-6 注意力权重热力图

理异构图神经网络与几种典型方法进行了比较，以验证其有效性。比较的方法包括经典深度学习方法损伤检测贝叶斯卷积神经网络（DD-BCNN）[39]、具有宽第一层核的深度卷积神经网络（WDCNN）[26]和最大似然估计的长短期记忆神经网络（MLE-LSTM）[40]，以及图神经网络方法中的多层耦合注意图网络（MCAGN）[41]和多注意力时空图神经网络（MA-STGNN）[42]。此外，检测率（DR）、误报率（FAR）和准确度（ACC）被用作评估指标。

从表 3-3 可以看出，传统机器学习方法稳定性差，主要因为严重依赖人工特征提取，不能很好地捕捉到深层故障特征，WDCNN 在 30℃和 50℃时表现最好，但是在 20℃和 40℃时性能大幅下降，说明它对特定温度条件有很强的依赖性。尽管使用了现代的大模型技术手段提高模型的解释性、收敛性，但是对于故障的物理本质的挖掘还不够深入，从而存在误报率较低的问题，即在 20℃时 MA-STGNN 的误报率为 82.14%，完全不能满足故障诊断的要求。相比而言，所提物理异构图神经网络各项指标的诊断准确率最高，稳定性最好。这不仅表明其性能优于传统机器学习方法，也领先于其他对比的深度学习方法。

为了进一步评价各个模型性能上的差别，图 3-7 给出了典型工况下各个方法测试集准确率变化曲线。从图中可以看出，传统的机器学习方法收敛速度慢，一般需要训练 150 轮以上才能达到较高的准确率，曲线波动大，说明在没有先验物理信息的情况下，训练不稳定。深度学习方法收敛速度有所提高，但是整体准确率仍然不能超过 90%；尤其值得注意的是，MA-STGNN 方法的准确率随训练过程呈下降趋势，说明它不能从数据中很好地提取故障特征。本章提出的物理异构图神经网络在不同

表 3-3 单温域工况下 PHGNN 与其他模型的评估指标对比表

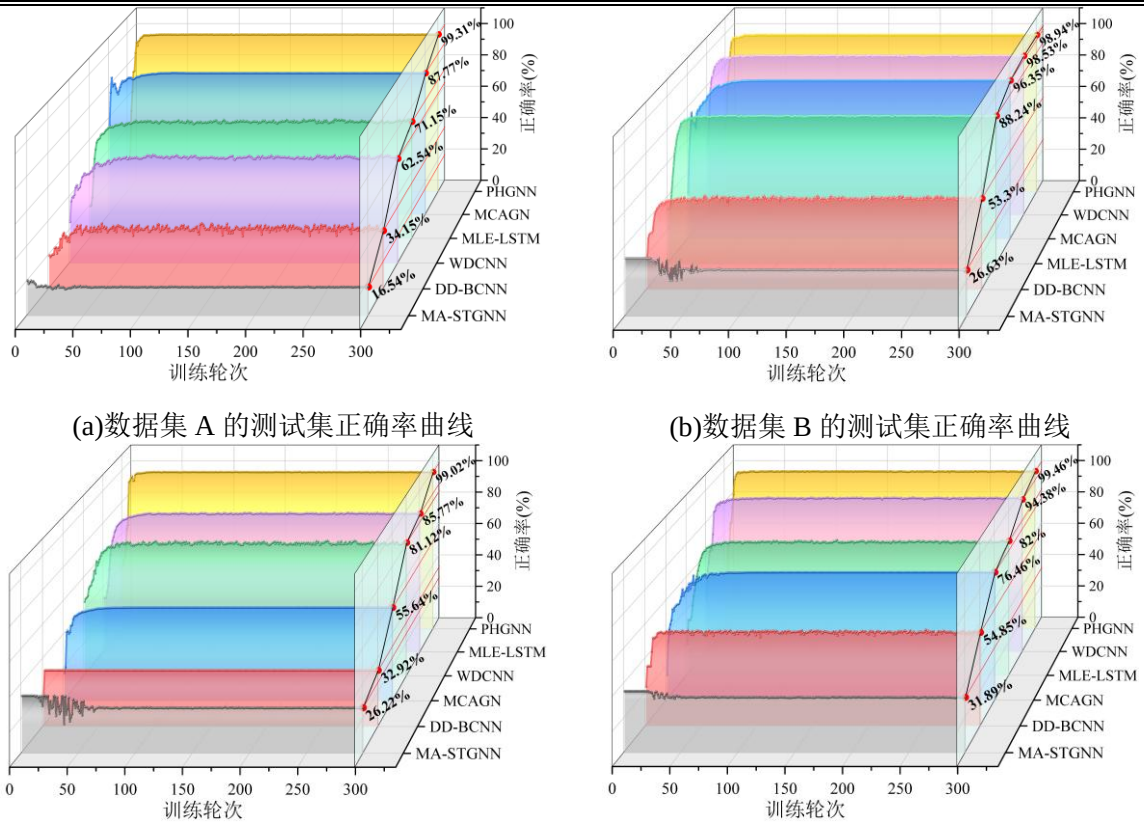
数据集	指标	DD-BCNN	WDCNN	MLE-LSTM	MCAGN	MA-STGNN	**PHGNN**
	ACC	34.15%	62.54%	71.15%	87.77%	16.54%	**99.31%**
A	DR	35.46%	61.36%	71.00%	87.14%	17.14%	**97.90%**
	FAR	52.56%	32.92%	24.63%	08.84%	82.14%	**01.42%**
	ACC	53.30%	98.53%	88.24%	96.35%	26.64%	**98.94%**
B	DR	43.52%	97.43%	84.60%	94.01%	21.03%	**98.36%**
	FAR	53.73%	02.11%	10.09%	04.37%	58.13%	**01.49%**
	ACC	32.92%	81.12%	85.77%	55.64%	26.22%	**99.02%**
C	DR	20.00%	76.50%	82.20%	46.00%	20.78%	**95.62%**
	FAR	13.48%	18.22%	11.45%	11.64%	71.44%	**03.75%**
	ACC	54.85%	94.39%	82.00%	76.46%	31.89%	**99.46%**
D	DR	40.48%	92.79%	76.61%	69.58%	22.20%	**96.19%**
	FAR	49.86%	05.39%	14.36%	32.26%	43.30%	**03.01%**

的单一恒定温度工况下，分类准确率均保持在 98.9%以上，表现出稳定且优越的分类性能；同时训练曲线平滑、收敛迅速，再次证明了模型在收敛效率和训练稳定性方面具有明显优势。

图 3-8 给出了各个模型在训练过程中损失的变化情况。所提的物理异构图神经网络模型在训练初期损失迅速下降，很快收敛。而其他对比模型各有各的不足，MA-STGNN、DD-BCNN 等模型下降缓慢，收敛周期长；DD-BCNN 等模型的损失函数很难再下降，说明其泛化能力受限。物理异构图神经网络模型稳定一致的收敛行为，既提高了训练效率，又从优化角度证明了它的架构设计是合理性和有效性。

3.4.2.4 宽温域工况检测场景

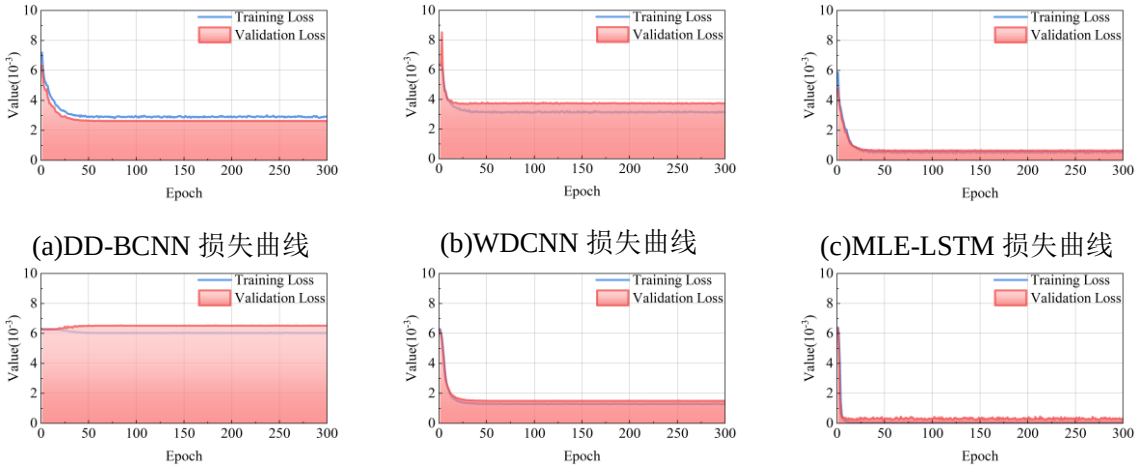
为进一步评估物理异构图神经网络在长期服役环境下的损伤诊断性能，基于表 3-1 中数据集 E、F、G、H 构建了宽温域工况检测场景，模拟板状结构在实际服役条件下的温度变化环境。采用与单温域场景相同的对比方法，实验结果见表 3-4。相较于单一温度条件，宽温域场景中各方法的准确率普遍下降，其原因不仅在于数据量增加带来的干扰放大，更在于不同温度下的声场传播参数改变，导致特征提取复杂性增加。PHGNN 模型在四个数据集中均表现出稳定的诊断能力，准确率始终保持在



(a)数据集 A 的测试集正确率曲线　(b)数据集 B 的测试集正确率曲线

(c)数据集 C 的测试集正确率曲线　(d)数据集 D 的测试集正确率曲线

图 3-7 单温域工况下各模型训练的测试准确率变化曲线



(a)DD-BCNN 损失曲线　(b)WDCNN 损失曲线　(c)MLE-LSTM 损失曲线

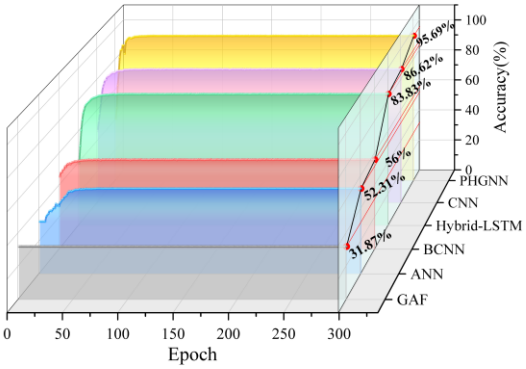
(d)MA-STGNN 损失曲线　(e)MCAGN 损失曲线　(f)PHGNN 损失曲线

图 3-8 单温域工况下各模型训练集和测试集损失函数

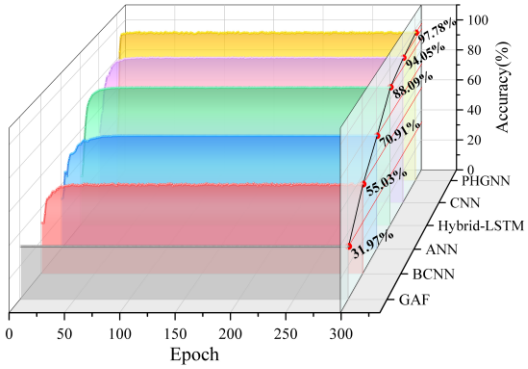
95%以上，同时在混合温度条件下实现最低误报率。相比之下，其他模型存在明显局限，WDCNN 和 MLE-LSTM 在单一温度下尚可，但在混合温度下性能显著退化；MCAGN 和 DD-BCNN 准确率普遍较低且波动剧烈；MA-STGNN 模型则在所有条件

表 3-4 宽温域工况下 PHGNN 与其他模型的评估指标对比表

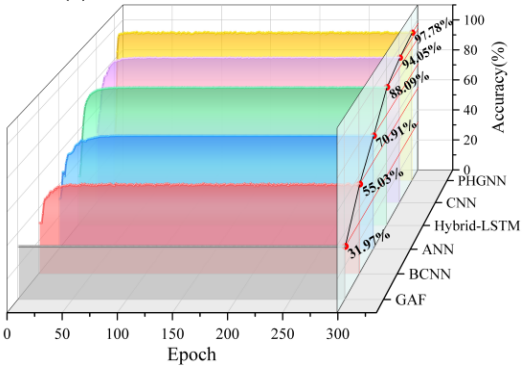
数据集	指标	DD-BCNN	WDCNN	MLE-LSTM	MA-STGNN	MCAGN	**PHGNN**
	ACC	56.00%	86.62%	83.83%	31.87%	52.31%	**95.69%**
E	DR	47.78%	84.31%	81.78%	20.00%	44.65%	**94.72%**
	FAR	21.94%	14.77%	16.65%	13.63%	31.72%	**05.22%**
	ACC	55.03%	94.05%	88.09%	31.97%	70.91%	**97.78%**
F	DR	48.69%	92.59%	85.53%	20.00%	65.51%	**96.92%**
	FAR	51.39%	7.53%	12.58%	13.61%	16.75%	**02.62%**
	ACC	58.40%	88.52%	85.45%	28.81%	34.34%	**97.09%**
G	DR	49.07%	86.54%	83.41%	22.38%	20.00%	**96.09%**
	FAR	32.90%	12.75%	15.05%	72.57%	13.13%	**03.79%**
	ACC	47.95%	74.69%	57.07%	31.87%	70.80%	**97.43%**
H	DR	38.92%	70.57%	52.34%	23.09%	65.04%	**96.50%**
	FAR	61.37%	28.45%	38.75%	13.62%	28.51%	**03.21%**



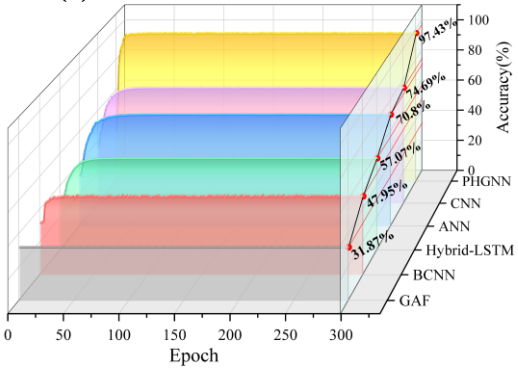
(a)数据集 E 的测试集正确率曲线



(b)数据集 F 的测试集正确率曲线



(c)数据集 G 的测试集正确率曲线



(d)数据集 H 的测试集正确率曲线

图 3-9 宽温域工况下各模型训练的测试准确率变化曲线

下基本失效。

此外，图 3-7 绘制了典型的训练曲线，显示了相比于其他模型，物理异构图神经网络具备优异的特征判别能力和收敛性能，训练过程更迅速稳定。

3.5 本章小结

本章提出了一种物理异构图卷积网络，能够准确地自适应地捕获传感器信号的时间演化特征，有效地识别传感器节点之间的复杂非线性空间关联关系。

其中，物理信息多粒度自注意力机制融合经典自注意力机制和残差网络，创新设计双回归注意力机制，深入挖掘信道间和信道内复杂的依赖关系，结合先验物理特征对信号进行增强，解决传统滤噪手段对宽频信号效果差的问题；物理异构图卷积提取器根据探头的相关位置关系，强约束图结构的构建，达到物理嵌入和数据驱动的双重结合，从而大幅度提升模型对多传感器间隐性依赖关系的捕捉，突破固定图结构无法自适应调整监控数据的局限。

本章在 SHM 导波数据集上进行了多组对比实验，实验结果表明所提方法是有效的。通过和目前主流的机器学习模型、相关固定图结构的方法进行对比，进一步证明该模型在预测精度、泛化性能、复杂工况适应性等方面具有明显的优势。

第 4 章 基于复数自适应图卷积网络的损伤定位模型

4.1 引言

由在第三章物理异构图神经网络实验结果中，基于物理信息嵌入的图神经网络已经在 SHM 导波数据集上得到了良好的结果，单温域工况均能达到 98.9%以上，较基准模型有了明显的提升，基本满足了实验室恒温检测的要求。但是在宽温域工况下正确率仅在 95-97%，误报率最高达到了 5%，说明该模型在长期监测的工况下仍然有待优化。

针对上述问题，本章进一步构建了一种复数自适应图卷积网络框架。在该框架中，首先设计了一种双向令牌信息提取模块，通过重排信号特征以增强模块感知。然后构建分数阶希尔伯特图卷积网络，将实信号变换为复信号进行进一步的深度处理。最终，实验结果表明，所提出的复数自适应图卷积网络在单温域和宽温域内均能高效的进行识别。

4.2 复数自适应图卷积网络框架的设计

在上一章给出的物理异构图神经网络框架之上，本章节进一步构建双向令牌信息提取模块和分数阶希尔伯特图卷积层，进一步重视阵列信号的相位关系解析，从而优化对宽温域工况的识别，并最终级联而成构建复数自适应图卷积网络框架，从而更精确的进行损伤区域分类。

4.2.1 双向令牌信息提取模块

与单一传感器数据不同，阵列多通道传感器信号序列在时间维度上兼具各自独特的动态演化规律与复杂的跨序列耦合关系。基于此，本文设计了双向令牌信息提取模块，如图 4-1 所示。

针对多源传感器信号序列间关系，本研究通过计算查询和密钥之间的相似度，为每个传感器动态分配关注权重。设第 i 个窗口的多源传感器信号序列为 $\mathbf{X}_i \in \mathbb{R}^{N\times W}$ 其中 N 表示传感器数量，W 表示滑动窗口大小，则其计算过程如下：

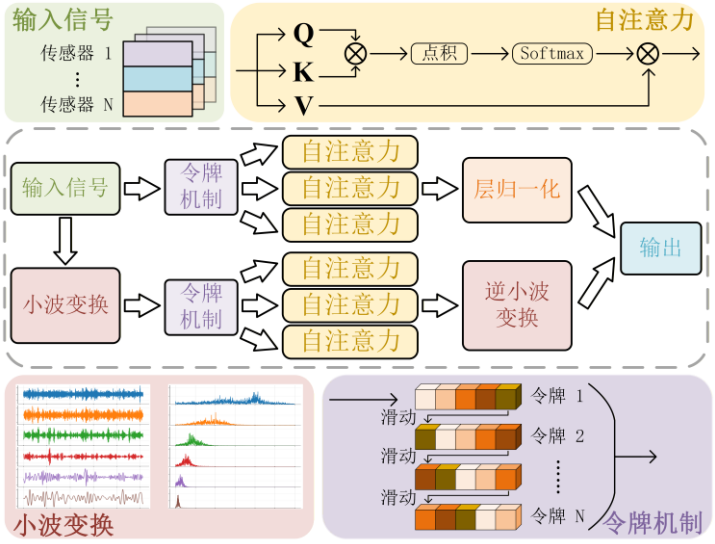


图 4-1 双向令牌信息提取模块示意图

$$\mathbf{Q}=\mathbf{X}_i\mathbf{W}_i^Q \quad \mathbf{K}=\mathbf{X}_i\mathbf{W}_i^K \quad \mathbf{V}=\mathbf{X}_i\mathbf{W}_i^V \tag{4-1}$$

$$\mathrm{Attn}=\mathrm{softmax}(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}})\mathbf{V} \tag{4-2}$$

$$\mathrm{Attn}_{\mathrm{out}}=\mathrm{LayerNorm}(\mathrm{Attn}+\mathbf{X}_i) \tag{4-3}$$

$$\mathbf{H}_{\mathrm{inter}}=\mathrm{LayerNorm}(\mathrm{FFN}(\mathrm{Attn}_{\mathrm{out}})+\mathrm{Attn}) \tag{4-4}$$

其中，$\mathbf{W}_i^Q$、$\mathbf{W}_i^K$ 和 $\mathbf{W}_i^V$ 为可训练权重矩阵，$\mathrm{LayerNorm}(\cdot)$ 代表层归一化操作，$\mathrm{FFN}(\cdot)$ 代表前馈网络层。这种方法使模型能够自动识别各传感器的重要性，并以相应的权重对其特征进行汇总。因此，自注意力机制能够灵活捕捉传感器之间复杂的跨序列依赖关系。

此外，在多传感器系统中，每个传感器信号通常都包含不同的时间变化模式，表现出周期性变化、趋势波动和局部异常等动态特征。针对每个传感器信号序列内的关系，本文提出了一种片段自回归注意力机制。由于时间序列中的单个点不像自然语言中的单词具有明确语义，直接对每个点计算注意力容易产生次优的注意力图。因此，本研究将每个时间窗口划分为若干片段，并通过计算片段之间的注意力来替代传统的点对点注意力。

考虑到片段长度是一个超参数，需要通过大量实验来确定最佳取值，且固定长度难以适应不同时刻的时间特征动态变化，尤其是在数据中存在能量较大的时变频率成分时。为此，本研究通过对多传感器信号进行小波变换动态分析，提取主要频率成分，从而实现自适应的片段分割。鉴于不同传感器的采样频率往往存在差异，

需分别对每个传感器的信号序列进行分析，其计算过程如下：

$$\mathbf{F} = \mathrm{Avg}(\mathrm{Amp}(\mathrm{DWT}(\mathbf{X}_i^j))) \tag{4-5}$$

$$\mathbf{f}_m = \max(\mathbf{F}) \tag{4-6}$$

$$s_i = \frac{W}{\mathbf{f}_m} \tag{4-7}$$

其中，Avg(·) 表示平均运算；DWT(·) 和 Amp(·) 分别表示小波变换和幅值计算。基于所估计的时间尺度 s_i，可以将每个样本划分为 $\mathbf{f}_m$ 个片段。考虑到将信号序列划分为多个片段不可避免地会引入信息丢失问题，本研究采用循环滑动片段的方式构建词元表示，以在充分保留原始信号完整信息的同时，部分重现时间序列中的动态变化特征，从而有效减轻该问题的影响。其具体构建过程如下：

$$\mathrm{Token}^j[d,:] = \mathrm{concat}(\mathbf{X}_i^j[d \cdot s_j : W-1, \mathbf{X}_i^j[0 : d \cdot s_j - 1]]) \tag{4-8}$$

所提出的自回归注意力机制的计算公式定义如下：

$$\mathbf{Q}_o = \mathbf{X}_i^j \mathbf{W}_o^Q \quad \mathbf{K}_o = \mathrm{Token}_o^j \mathbf{W}_o^K \quad \mathbf{V}_o = \mathrm{Token}_o^j \mathbf{W}_o^V \tag{4-9}$$

$$\alpha_o = \mathrm{softmax}(\frac{\mathbf{Q}_o \mathbf{K}_o^\top}{\sqrt{d_k}})\mathbf{V}_o \tag{4-10}$$

$$\alpha_{\mathrm{out}} = \mathrm{LayerNorm}(\alpha_o + \mathbf{X}_i^j) \tag{4-11}$$

$$\mathbf{H}_{\mathrm{intra}} = \mathrm{LayerNorm}(\mathrm{FFN}(\alpha_{\mathrm{out}}) + \alpha_o) \tag{4-12}$$

在提取出传感器信号之间的系列间关系 $\mathbf{H}_{\mathrm{inter}}$ 和每个传感器信号的系列内关系 $\mathbf{H}_{\mathrm{intra}}$ 后，这两种关系特征将通过以下方法进行聚合：

$$\mathbf{H} = \mathbf{H}_{\mathrm{inter}} + \mathbf{H}_{\mathrm{intra}} \tag{4-13}$$

最后，得到统一的时序特征表示 $\mathbf{H}$，输入进接下来的模块。

4.2.2 分数阶希尔伯特图卷积层

超声阵列探头在板材损伤检测中常采用多通道形式，各通道间存在复杂的几何关系，接收信号的相位与幅值均承载着关键的故障信息。为有效提取相位特征，本文首先通过分数阶希尔伯特变换对其进行显式表征，如图 4-2 所示。

具体而言，由希尔伯特变换公式：

$$\mathbf{x}(t) = \mathcal{H}[\mathbf{x}(t)] = \frac{1}{\pi}\mathrm{p.v.}\int_{-\infty}^{\infty}\frac{\mathbf{x}(\tau)}{t-\tau}\mathrm{d}\tau \tag{4-14}$$

可构造解析信号 $\mathbf{z}[n] = \mathbf{x}[n] + j\mathbf{x}[n]$，其中虚部对所有频率分量施加固定的 90° 相移。

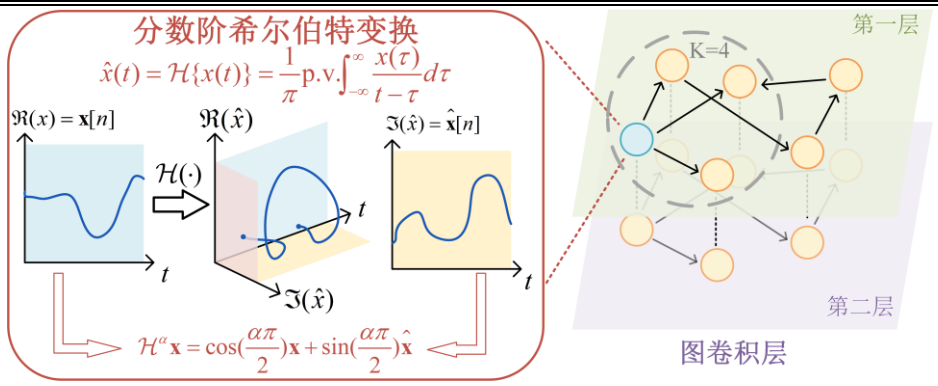


图 4-2 分数阶希尔伯特图卷积层示意图

为使相位偏移能够根据信号特性自适应调整，引入可学习的分数阶参数 α，将标准希尔伯特变换推广为分数阶希尔伯特变换 $\mathcal{H}^{\alpha}$，其频域乘子为：

$$\mathcal{F}[\mathcal{H}^{\alpha}\mathbf{x}](\omega)=\exp(-j\cdot\frac{\alpha\pi}{2}\cdot\text{sgn}(\omega))\mathcal{F}[\mathbf{x}](\omega) \tag{4-15}$$

该频域乘子本质对信号施加了 $\alpha\pi/2$ 的相移偏移。在时域中，该变换可表示为原信号与其希尔伯特变换的线性组合：

$$\mathcal{H}^{\alpha}\mathbf{x}[n]=\cos(\frac{\alpha\pi}{2})\mathbf{x}[n]+\sin(\frac{\alpha\pi}{2})\mathbf{x}[n] \tag{4-16}$$

基于此构造分数阶解析信号：

$$\mathbf{x}^{\alpha}[n]=\mathbf{x}[n]+j\mathcal{H}^{\alpha}\mathbf{x}[n] \tag{4-17}$$

该信号以角度可调的相位旋转替代固定的正交分量，能够自适应捕捉阵列信号中任意方向的瞬时相位特征，更细腻地表征故障信息。

随后，为了在非欧几里得域上有效聚合多通道阵列数据，进一步引入图卷积神经网络。具体而言，对于图 $\mathcal{G}=\{\mathcal{V},\mathcal{E}\}$，其中 $\mathcal{V}$ 为顶点集合，$\mathcal{E}$ 为边集合，定义：

$$\mathbf{A}_{ij}=\begin{cases}1, & \text{if } (v_i,v_j)\subseteq\mathbf{E}\\ 0, & \text{otherwise}\end{cases} \tag{4-18}$$

$$\mathbf{D}_{ii}=\sum_{j}\mathbf{A}_{ij} \tag{4-19}$$

$$\mathbf{L}=\mathbf{D}-\mathbf{A} \tag{4-20}$$

$$g_{\theta}*\mathbf{x}=g_{\theta}(\mathbf{L}) \tag{4-21}$$

输入信号 $\mathbf{x}$ 经图滤波器 g_{θ} 卷积后得到相应输出。为了简化公式，根据 Real Symmetric Matrices 理论，将实对阵矩阵 $\mathbf{L}$ 进行正交对角化：

$$\mathbf{L}=\mathbf{U}\Lambda\mathbf{U}^{-1} \tag{4-22}$$

其中，对角矩阵 $\Lambda=\text{diag}(\lambda_1,\lambda_2,\cdots,\lambda_n)$ 由 $\mathbf{L}$ 的特征值构成。将式(4-17)和式(4-22)代入

式(4-21)可得：

$$g_\theta * \mathbf{x}^\alpha = \mathbf{U} g_\theta(\Lambda)\mathbf{U}^{-1}(I + j\mathcal{H}^\alpha)\mathbf{x} \tag{4-23}$$

此时进一步沿用分数阶的思想，引入阶次 β 对特征向量矩阵 $\mathbf{U}$ 进行变换以旋转时频平面。令 $\mathbf{L}^\beta = \mathbf{U}^\beta \mathbf{L}\mathbf{U}^{-\beta}$，其特征值 λ_k 可为复数，据此设计分数阶希尔伯特图滤波器 $\mathbf{H}^\alpha$，并化简式(4-23)，给出最终的希尔伯特图卷积公式：

$$\mathbf{y} = \mathbf{U}^\beta (I + j\mathbf{H}^\alpha)\mathbf{U}^{-\beta}\mathbf{x} \tag{4-24}$$

$$\mathbf{H}^\alpha[k,k] = \begin{cases} \exp(-j\alpha) & \Im(\lambda_k) > 0 \\ \cos(\alpha) & \Im(\lambda_k) = 0 \\ \exp(j\alpha) & \Im(\lambda_k) < 0 \end{cases} \tag{4-25}$$

在边集构造阶段，将每个接收通道视为图的顶点，并采用 Wasserstein 距离度量各批次内通道信号分布之间的差异，进而建立边连接，示意图如图 4-3 所示。

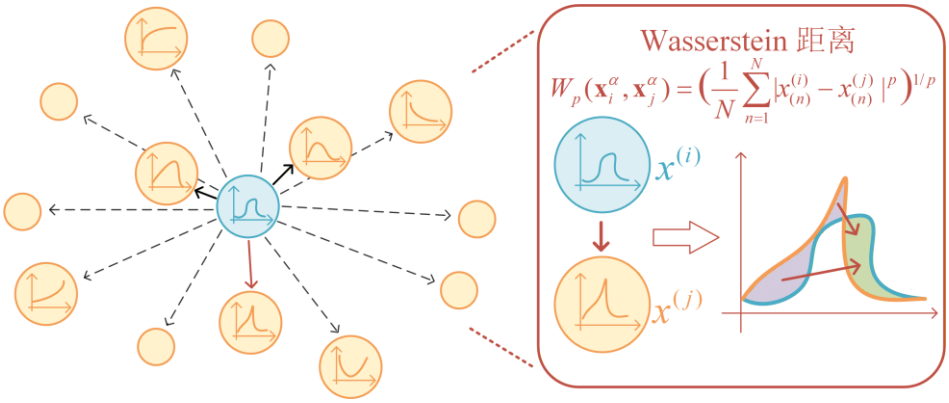


图 4-3 Wasserstein 度量的边集构造示意图

具体而言，设一个训练批次的信号张量为 $\mathbf{X} \in \mathbb{R}^{B\times C\times N}$，其中 B 为批次样本数，C 为通道数，N 为窗口长度。直接利用极大似然估计算法求解类分布参数，设给定批次中的通道 c，将其 B 个 N 维样本记作 $\{\mathbf{x}_{c,i} \in \mathbb{R}^N\}_{i=1}^B$ 的对数似然函数可定义为：

$$\begin{aligned} \mathcal{L}(\boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c) &= \log \mathcal{L}(\mathbf{x}_{c,1}, \mathbf{x}_{c,2}, \cdots, \mathbf{x}_{c,B}; \boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c) \\ &= \log \prod_{i=1}^{B} f(\mathbf{x}_{c,i}) = \sum_{i=1}^{B} \log f(\mathbf{x}_{c,i}) \end{aligned} \tag{4-26}$$

式中 $\boldsymbol{\mu}_c$，和 $\boldsymbol{\Sigma}_c$ 分别表示第 c 类分布参数的均值向量和协方差矩阵，$f(\cdot)$ 表示分布 $\mathcal{N}(\boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)$ 的概率密度函数。对上式求偏导可得：

$$\frac{\partial \mathcal{L}(\boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)}{\partial \boldsymbol{\mu}_c} = \frac{\partial}{\partial \boldsymbol{\mu}_c}\left[\sum_{i=1}^{B} \mathbf{x}_{c,i}^\top \boldsymbol{\Sigma}_c^{-1} \boldsymbol{\mu}_c\right] - \frac{B}{2}\frac{\partial}{\partial \boldsymbol{\mu}_c}\left[\sum_{i=1}^{B} \boldsymbol{\mu}_c^\top \boldsymbol{\Sigma}_c^{-1} \boldsymbol{\mu}_c\right] \tag{4-27}$$

$$\frac{\partial \mathcal{L}(\boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)}{\partial \boldsymbol{\Sigma}_c} = -\frac{B}{2}\frac{\partial \log|\boldsymbol{\Sigma}_c|}{\partial \boldsymbol{\Sigma}_c} - \frac{1}{2}\frac{\partial}{\partial \boldsymbol{\Sigma}_c}\left[\frac{1}{B}\sum_{i=1}^{B}(\mathbf{x}_{c,i} - \boldsymbol{\mu}_c)^\top \boldsymbol{\Sigma}_c^{-1}(\mathbf{x}_{c,i} - \boldsymbol{\mu}_c)\right] \tag{4-28}$$

令上式偏导均为 0，可求解出分布参数：

$$\boldsymbol{\mu}_c = \frac{1}{B}\sum_{i=1}^{B}\mathbf{x}_{c,i} \tag{4-29}$$

$$\boldsymbol{\Sigma}_c = \frac{1}{B}\sum_{i=1}^{B}(\mathbf{x}_{c,i}-\boldsymbol{\mu}_c)(\mathbf{x}_{c,i}-\boldsymbol{\mu}_c)^{\top} \tag{4-30}$$

可得到该批次下的所有通道中的高斯分布$\{\mathcal{N}(\boldsymbol{\mu}_c,\boldsymbol{\Sigma}_c)\}_{c=1}^{C}$。

在此基础上，本文选取 Wasserstein 距离作为通道间边权重构建的度量，对于$\mathbb{R}^N$上的两个概率测度P与Q，其 p -Wasserstein 距离定义为：

$$W_p(P,Q)=\left(\inf_{\gamma\in\Pi(P,Q)}\int\|x-y\|^p\,\mathrm{d}\gamma(x,y)\right)^{\frac{1}{p}} \tag{4-31}$$

当P和Q均为多元高斯分布且$p=2$时，该距离存在简洁的闭式解，故本文采用 2-Wasserstein 距离。对于通道u与v所对应的高斯分布$U=\mathcal{N}(\boldsymbol{\mu}_u,\boldsymbol{\Sigma}_u)$与$V=\mathcal{N}(\boldsymbol{\mu}_v,\boldsymbol{\Sigma}_v)$，其 2-Wasserstein 距离的闭式表达为：

$$W_2^2(u,v)=\|\boldsymbol{\mu}_u-\boldsymbol{\mu}_v\|_2^2+\mathrm{tr}\left(\boldsymbol{\Sigma}_u+\boldsymbol{\Sigma}_v-2\left(\boldsymbol{\Sigma}_u^{\frac{1}{2}}\boldsymbol{\Sigma}_v\boldsymbol{\Sigma}_u^{\frac{1}{2}}\right)^{\frac{1}{2}}\right) \tag{4-32}$$

式中$\|\cdot\|_2$表示向量的欧氏范数，$\boldsymbol{\Sigma}_u^{1/2}$为$\boldsymbol{\Sigma}_u$的唯一对称正定平方根，$\mathrm{tr}(\cdot)$为矩阵的迹。该度量由两项构成，第一项描述了均值漂移，第二项描述协方差结构与各向异性差异。最终，以该距离构建全连接图，边权重定义为距离的负指数函数：

$$A_{uv}=\exp\left(-\frac{W_2^2(u,v)}{2\sigma^2}\right) \tag{4-33}$$

其中σ为带宽参数，控制相似度的衰减速度。由此得到的邻接矩阵$\mathbf{A}\in\mathbb{R}^{C\times C}$从而完整描述了当前批次下的通道拓扑结构。将式(4-33)代入式(4-19)-(4-25)，得到最终的输出。

4.2.3 复数自适应图卷积网络的设计

基于前述的双向令牌信息提取模块与分数阶希尔伯特图卷积层，本章设计了一种复合板材损伤定位的复数自适应图卷积网络框架，网络总体架构如图 4-4 所示。该网络能够充分融合阵列相位监测信息的时空特征，有效提升超声导波板材损伤定位的准确性与泛化能力。

完整的损伤定位流程包含以下几个步骤：

（1） 数据采集与预处理：从部署于板材表面的阵列超声波换能器阵列中采集

原始导波监测数据，随后对信号依次执行异常值剔除与同步对齐等预处理操作，以形成满足模型输入要求的规范化信号样本。

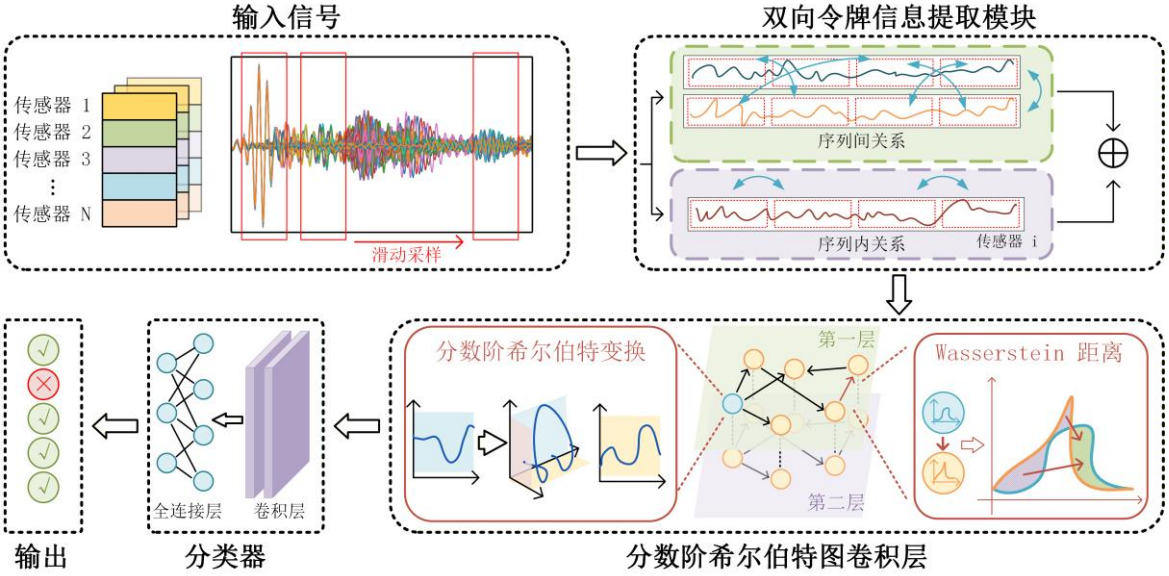


图 4-4 复数自适应图卷积网络框架示意图

（2） 双向令牌信息提取：将预处理后的离散信号序列首先通过跨序列自注意力机制，自动学习各传感器的重要性权重，捕获通道间复杂的耦合关系；同时，利用基于小波变换自适应片段划分的片段自回归注意力机制，提取离散信号序列的时序频域特征。最后将跨序列关系特征与序列内关系特征相加聚合，得到统一的时序特征表示。

（3） 分数阶希尔伯特图卷积与多通道信息聚合：对上一步输出的时序特征首先利用可学习分数阶参数的希尔伯特变换，对每个通道的信号构造角度可调的分数阶解析信号，显式表征瞬时相位特征。随后，根据极大似然估计拟合各通道的多元高斯分布，计算通道间的 2-Wasserstein 距离，构建全连接图邻接矩阵以描述通道拓扑结构。两相结合通过式(4-24)和式(4-25)的前向传播公式进行图卷积操作。

（4） 损伤类别映射与定位输出：将分数阶希尔伯特图卷积输出的通道特征图进行全局整合，经卷积和全连接层进一步提取深层特征，最终映射为损伤类别的概率预测 $\mathbf{O}$，并输出预测的损伤类别 $\mathbf{y}=\arg\max_{i}\mathbf{O}_i$ 作为最终定位结果。

模型采用 AdamW 优化器进行端到端训练，初始学习率设为 1×10^{-3}，中心损失平衡系数 $\lambda=0.01$。学习率采用余弦退火策略动态调整，以确保稳定收敛并提升泛化性能。

4.3 实验验证

4.3.1 数据介绍

本章实验数据集采用与第三章一致的 SHM 导波数据集[38]。为保证对比实验的公平性和客观性，数据采集方案、处理方案、数据集划分和模型训练超参数均与第三章基本保持一致，具体参数详见表 3-1 和表 3-2。

4.3.2 实验分析

4.3.2.1 超参数寻优

在所提出的分数阶希尔伯特图卷积层中，批次大小对阵列信号的拟合和训练效果起着关键作用。较大的批次大小能更完整地把握阵列信号的基线，但容易丢失细节，导致某些特殊信号出现分类错误；较小的批次大小则会因建图拟合次数增多，使训练时间成倍增加。为此，以单温域工况下多个温度点场景为例进行多次实验，图 4-5 展示了不同批次大小下的训练时长。可以看出，当批次大小达到 512 量级时，训练时间趋于稳定，同时也能获得较高的正确率。综合考虑细节对分类精度的影响，最终将批次大小选定为 512。

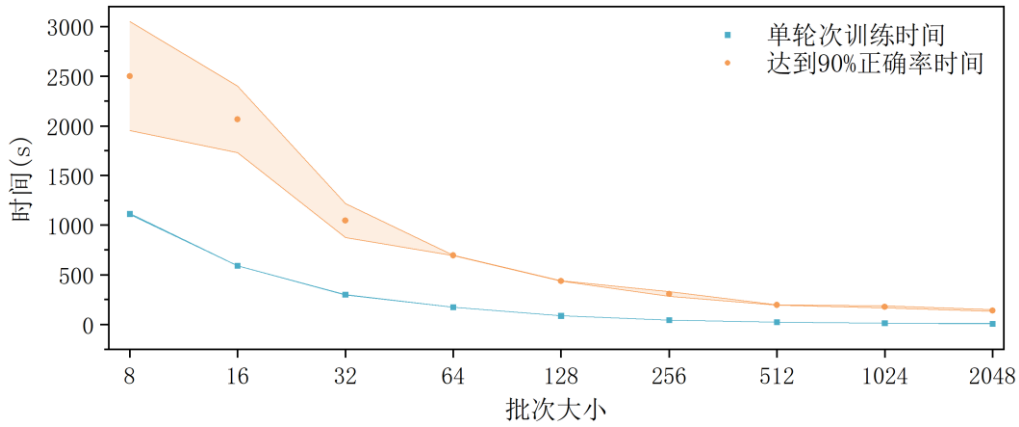


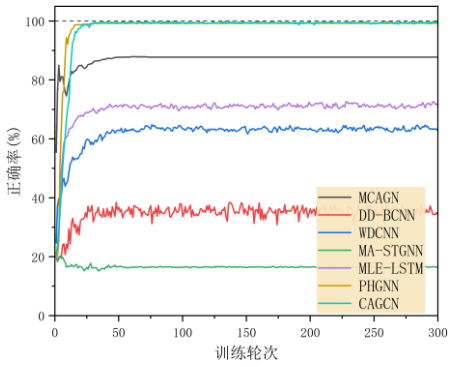
图 4-5 批次大小对训练时间的影响对比图

4.3.2.2 单温域工况检测场景

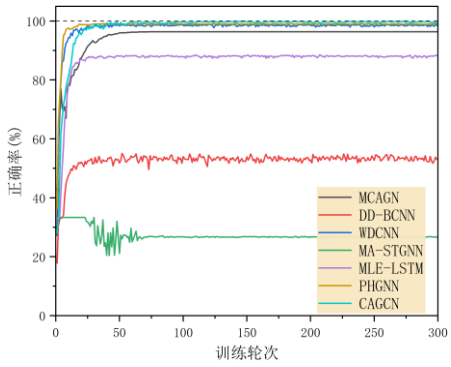
本节基于表 3-1 中构建的单温域分类场景在相同的实验设置下将提出的复数自适应图卷积神经网络（CAGCN）与第三章提出的物理异构图神经网络（PHGNN）以及损伤检测贝叶斯卷积神经网络（DD-BCNN）[39]、具有宽第一层核的深度卷积神经网络（WDCNN）[26]、最大似然估计的长短期记忆神经网络（MLE-LSTM）[40]、

表 4-1 单温域工况下 CAGCN 与其他模型的评估指标对比表

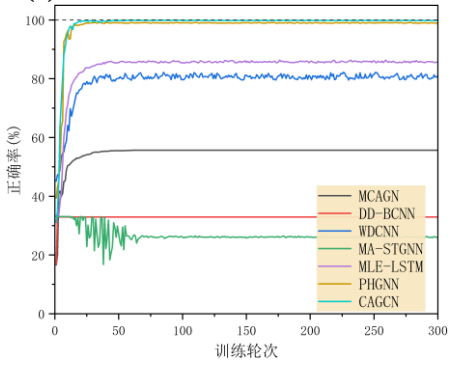
数据集	指标	DD-BCNN	WDCNN	MLE-LSTM	MCAGN	MA-STGNN	PHGNN	**CAGCN**
	ACC	34.15%	62.54%	71.15%	87.77%	16.54%	99.31%	**99.61%**
A	DR	35.46%	61.36%	71.00%	87.14%	17.14%	97.90%	**98.38%**
	FAR	52.56%	32.92%	24.63%	08.84%	82.14%	01.42%	**01.32%**
	ACC	53.30%	98.53%	88.24%	96.35%	26.64%	98.94%	**99.76%**
B	DR	43.52%	97.43%	84.60%	94.01%	21.03%	**98.36%**	97.72%
	FAR	53.73%	02.11%	10.09%	04.37%	58.13%	**01.49%**	01.59%
	ACC	32.92%	81.12%	85.77%	55.64%	26.22%	99.02%	**99.63%**
C	DR	20.00%	76.50%	82.20%	46.00%	20.78%	95.62%	**98.61%**
	FAR	13.48%	18.22%	11.45%	11.64%	71.44%	03.75%	**00.97%**
	ACC	54.85%	94.39%	82.00%	76.46%	31.89%	99.46%	**99.86%**
D	DR	40.48%	92.79%	76.61%	69.58%	22.20%	96.19%	**98.70%**
	FAR	49.86%	05.39%	14.36%	32.26%	43.30%	03.01%	**00.52%**



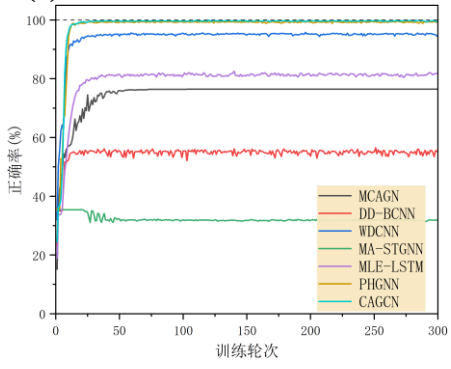
(a)数据集 A 的测试集正确率曲线



(b)数据集 B 的测试集正确率曲线



(c)数据集 C 的测试集正确率曲线



(d)数据集 D 的测试集正确率曲线

图 4-6 单温域工况下各模型训练的测试准确率变化曲线

多层耦合注意图网络（MCAGN）[41]和多注意力时空图神经网络（MA-STGNN）[42]几种方法进行了比较，以验证其有效性。

如表 4-1 所示，在四个单温域数据集上，本章提出的 CAGCN 的准确率均位列第一，分别为 99.61%、99.76%、99.63% 和 99.86%，全面优于第三章提出的 PHGNN。除数据集 B 外，CAGCN 在检测率和误报率上也均大幅领先 PHGNN，尤其在 C、D 数据集上，检测率高出约 2.5-3 个百分点，误报率降低约 2.5-2.8 个百分点。这说明在第三章的基础上，将实数特征转化入复数域切从而将相位信息纳入考量，有效深化了对信息的挖掘。

为进一步评估各模型的性能差异，图 4-6 展示了不同方法在典型工况下的测试集准确率变化曲线。可以看出，本章所提出的 CAGCN 在单温域工况下收敛速度略慢于第三章所提出的 PHGNN 架构，但是训练更为平缓，基本不会出现训练后正确率降低的现象，同时也有更高的准确率。表现出该模型在准确率与训练稳定性方面有更突出的优势。

4.3.2.3 宽温域工况检测场景

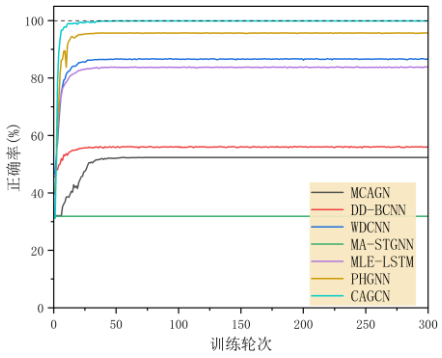
本节基于表 3-1 中数据集 E、F、G、H 构建了宽温域工况检测场景，进一步模拟板状结构在实际服役条件下的温度变化环境。对比方法与单温域场景一致，实验结果见表 4-2。

准确率方面，相较于其他模型在宽温域场景中各方法的准确率普遍下降，而本章提出的 CAGCN 准确率均在 99.4%以上，并没有明显变化。误报率方面，CAGCN 全部低于 1.5%，PHGNN 则在 2.62%-5.22%之间。各项指标对比显示，CAGCN 在宽温域工况下的分类精度与泛化性均显著强于 PHGNN。这既说明了本章所提出模型的高泛化能力和低误检率，也侧面证明了阵列相位对模型优化的重要性。

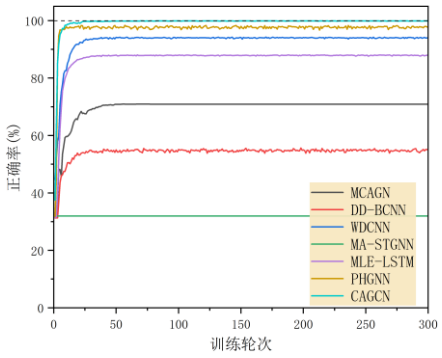
此外，图 4-7 绘制了典型的训练曲线，从曲线中可以看到，CAGCN 的损失函数在训练初期即快速下降，不到 50 个训练轮次便趋于平稳并收敛至极低水平；同时，训练损失与验证损失高度吻合，未出现明显振荡与过拟合。相比之下，其他模型的训练曲线收敛速度明显偏慢，且存在不同程度的波动，验证损失居高不下，进一步反映出特征判别能力不足。这表明 CAGCN 具备优异的特征判别能力和收敛性能，训练过程更为迅速、稳定，且对超参数选择不敏感，在工程应用中具有良好的部署潜力。

表 4-2 宽温域工况下 CAGCN 与其他模型的评估指标对比表

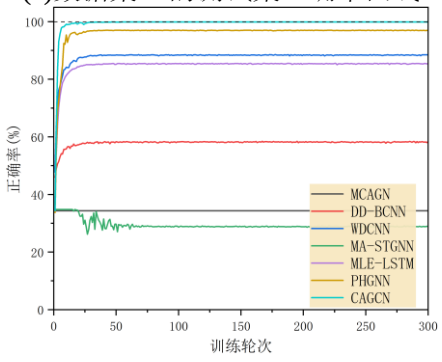
数据集	指标	DD-BCNN	WDCNN	MLE-LSTM	MCAGN	MA-STGNN	PHGNN	**CAGCN**
	ACC	56.00%	86.62%	83.83%	31.87%	52.31%	95.69%	**99.61%**
E	DR	47.78%	84.31%	81.78%	20.00%	44.65%	94.72%	**99.20%**
	FAR	21.94%	14.77%	16.65%	13.63%	31.72%	05.22%	**00.54%**
	ACC	55.03%	94.05%	88.09%	31.97%	70.91%	97.78%	**99.89%**
F	DR	48.69%	92.59%	85.53%	20.00%	65.51%	96.92%	**99.30%**
	FAR	51.39%	7.53%	12.58%	13.61%	16.75%	02.62%	**00.54%**
	ACC	58.40%	88.52%	85.45%	28.81%	34.34%	97.09%	**99.41%**
G	DR	49.07%	86.54%	83.41%	22.38%	20.00%	96.09%	**99.32%**
	FAR	32.90%	12.75%	15.05%	72.57%	13.13%	03.79%	**00.47%**
	ACC	47.95%	74.69%	57.07%	31.87%	70.80%	97.43%	**99.20%**
H	DR	38.92%	70.57%	52.34%	23.09%	65.04%	96.50%	**97.35%**
	FAR	61.37%	28.45%	38.75%	13.62%	28.51%	03.21%	**01.40%**



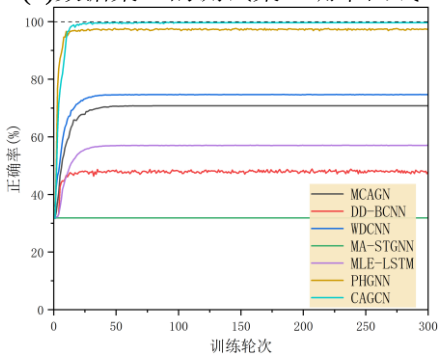
(a)数据集 E 的测试集正确率曲线



(b)数据集 F 的测试集正确率曲线



(c)数据集 G 的测试集正确率曲线



(d)数据集 H 的测试集正确率曲线

图 4-7 宽温域工况下各模型训练的测试准确率变化曲线

4.4 本章小结

针对第三章提出的物理异构图神经网络在宽温域工况下出现正确率下降的问题，本章进一步设计构建了一种复数自适应图卷积网络，通过分数阶希尔伯特图变换将实数特征变换入复数域，从而挖掘阵列信号之间的相位关系，优化模型对相位特征的提取。

其中，双向令牌信息提取模块利用离散信号的滑移来构建双向令牌，进而加强多头注意力对信号局部的关注，从而分析时频双域内的复杂关系，提取分数阶希尔伯特图卷积层根据输入批次信号拟合多元高斯分布，用 Wasserstein 距离构建图网络将分数阶希尔伯特域内的信号进行图卷积处理，显式的增强模型对相位的关注，从而提升模型对复杂几何模型的理解力。

本章在 SHM 导波数据集上做了多组对比实验，实验结果表明了所提方法的有效性和合理性。通过对提出的模型与其他主流模型的比较，证明出提出模型在预测精度、泛化性能、复杂工况适应性等方面都比其他主流模型有明显的优势。

结 论

复合板材在众多工程领域中应用广泛，随着大规模的使用，对复合板材内部损伤的无损结构检测技术变得越来越重要。目前，最可行、经济的超声导波检测方法是用稀疏布置的压电传感器阵列来建立声场探测。但是导波传播过程中经常会出现多模态、频散、边界反射等问题，并且还会受到温度等外界因素的影响而造成信号分布偏移。目前损伤信号处理大多采用时频分析、模态提取等物理特征手工提取的方法，或者用支持向量机、多层感知机等机器学习技术把传感器当作孤立的时间序列，没有考虑到阵列本身的固有的空间拓扑结构以及物理传播规律，造成判断困难、精度低。

为了克服上述的局限性，本文在查阅了大量现有的文献的基础上，从导波传播理论出发，建立了板材探伤的物理模型，根据频散曲线和波数关系把压电阵列抽象成异质传感器网络，为后续图学习提供结构化的先验知识。

本文在单温域内提出物理异构图神经网络，用物理传播节点和虚拟损伤节点创建单向异构图，从损失特征来源本身去发现导波物理交互的逻辑，从而达成先验物理指导下的信息聚合。实验结果表明，该模型在各个单温域测试集上的损伤定位分类准确率比最优基线模型最大提高了 82.77%，平均提高了 42.67%，明显优于传统的机器学习方法和主流的图卷积网络。为了解决宽温域下温度波动造成的准确度下降问题，本文进一步将阵列信号的相位特征纳入模型考量范围，从而提出了复数自适应图卷积网络，该框架加入了分数阶希尔伯特变换，把原始时域信号转化为分数阶复数解析信号，使得节点的幅值特征和相位特征都显式地表示出来，从而丰富了特征的内容，以此构建复数图卷积层，利用复数域的图卷积机制进行联合学习，增强了特征表示的完备性。在多温度区间宽温域实验中，该复数自适应图卷积网络的平均定位准确率比前面的物理异构图神经网络再提高 6.78%，在各个温度段上都保持了较高的精度，说明它具有较好的温度自适应性。

然而由于数据集中并没有包含大量的高温、极寒等极端温度工况，在这些情况下，该模型就很容易出现分类失准的现象。未来的研究一方面可对极端温度进行，进一步实验和测量，另一方面可将迁移学习等域自适应的方法引入到物理引导的数

据增强、域混淆的方法中去，从而对跨温度域的损伤诊断进行研究，提高模型在更加复杂多变的温度环境下泛化性和鲁棒性。

参考文献

[1] Dwivedi S K, Vishwakarma M, Soni A. Advances and researches on non destructive testing: A review[J]. Materials Today: Proceedings, 2018, 5(2): 3690-3698.

[2] 李瑶,王快社,刘长瑞. 金属板材表面缺陷检测发展现状[J].材料导报: 纳米与新材料专辑, 2011, 25(2): 238-241.

[3] 马超. 无损检测技术及应用[J]. Imaging Science & Photochemistry, 2020, 38(1).

[4] Bao W, Ma J, Yang Z, et al. ConvMPAnet: A novel end-to-end lightweight damage localization framework under heavy noise in composite structures[J]. IEEE Sensors Journal, 2024, 24(24): 42417-42427.

[5] Yang Z, Zhang Y, Bai Y, et al. The application of deep learning in pipeline inspection: current status and challenges[J]. Ships and Offshore Structures, 2025, 20(7): 1016-1027.

[6] Zhang S, Li J, Wang X, et al. Study on Horizontal Leakage Diffusion Characteristics of Small and Medium Aperture in High-Pressure Natural Gas Pipelines with Large Open Spaces[J]. ACS omega, 2025, 10(10): 10515-10529.

[7] Wang H P, Chen C, Ni Y Q, et al. Computer-aided feature recognition of CFRP plates based on real-time strain fields reflected from FBG measured signals[J]. Composites Part B: Engineering, 2023, 263: 110866.

[8] Li S, Sun J, Guo Y, et al. Experimental investigation of electro-thermal-impact synergistic damage mechanism of CFRP composites injected by impulse lightning current[J]. Composites Part B: Engineering, 2025: 112918.

[9] Wang P, Bai Y, Zhao Z, et al. Damage evolution of CFRP laminates subjected to cryogenic flexure loading using in situ X-ray computed tomography[J]. Composites Part B: Engineering, 2025: 113171.

[10] Shao W, Liao Y, Wang Y, et al. A damage identification method for aviation structure integrating Lamb wave and deep learning with multi-dimensional feature fusion[J]. Ultrasonics, 2025, 151: 107623.

[11] Ismail Z, Mustapha S, Tarhini H. Optimizing the placement of piezoelectric wafers on closed

sections using a genetic algorithm-Towards application in structural health monitoring[J]. Ultrasonics, 2021, 116: 106523.

[12] Hong X, Luo Z, Zhang B, et al. Guided-wave quick sparse decomposition approach based on novel peak-frequency modulation dictionary for efficient composite plate damage inspection[J]. Applied Acoustics, 2024, 223: 110081.

[13] Qing X, Kumar A, Zhang C, et al. A hybrid piezoelectric/fiber optic diagnostic system for structural health monitoring[J]. Smart Materials and Structures, 2005, 14(3): S98-S103.

[14] 唐庆菊,王扬,刘俊岩,等. 耐热合金涂层结构板材内部缺陷的脉冲红外热成像检测[J]. 红外与激光工程, 2013, 42(7): 1685-1690.

[15] 史洪源,李杰,周鹏,等. 钛合金小径管对接焊缝数字射线检测工艺优化与试验[J]. 无损检测, 2025, 47(7): 34-39.

[16] 刘伟成,张路根,胡智,等. 海洋石油静电脱水压力容器的超声导波检测[J]. 无损检测, 2012, 34(2): 31-34.

[17] 吕东超. 基于 Lamb 波的机翼蒙皮板材损伤检测方法研究[D]. 贵州大学, 2024.

[18] Viktorov I. Rayleigh and lamb waves: Physical theory and applications[M]. Plenum Press, 1967.

[19] Auld B. A wiley-interscience publication: Acoustic fields and waves in solids[M]. Wiley, 1973.

[20] 张海燕,马世伟,冯国瑞,等. 兰姆波结构健康监测中的概率损伤成像[J]. 声学学报, 2012, 37(4): 401-407.

[21] 魏诺珂. 基于超声兰姆波板状结构损伤定位成像精度研究[D]. 华东理工大学, 2019.

[22] Yun H, Feng K, Rayhana R, et al. A multidimensional data fusion neural network for damage localization using ultrasonic guided wave[J]. IEEE Transactions on Instrumentation and Measurement, 2023, 72: 1-12.

[23] Yan G. A Bayesian approach for damage localization in plate-like structures using Lamb waves[J]. Smart Materials and Structures, 2013, 22(3): 035012.

[24] Hong X, Lin X, Yang B, et al. Crack detection in plastic pipe using piezoelectric transducers based on nonlinear ultrasonic modulation[J]. Smart Materials and Structures, 2017, 26(10): 104012.

[25] Hughes J M, Mohabuth M, Khanna A, et al. Damage detection with the fundamental mode of edge waves[J]. Structural Health Monitoring, 2021, 20(1): 74-83.

[26] Zhang S, Li C M, Ye W. Damage localization in plate-like structures using time-varying feature

and one-dimensional convolutional neural network[J]. Mechanical Systems and Signal Processing, 2021, 147: 107107.

[27] Zhuang L, Luo K, Yang Z. A multimodal gated recurrent unit neural network model for damage assessment in CFRP composites based on Lamb waves and minimal sensing[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 1-11.

[28] Rautela M, Senthilnath J, Moll J, et al. Combined two-level damage identification strategy using ultrasonic guided waves and physical knowledge assisted machine learning[J]. Ultrasonics, 2021, 115: 106451.

[29] Liu Z, Xu K, Li D, et al. Automatic mode extraction of ultrasonic guided waves using synchrosqueezed wavelet transform[J]. Ultrasonics, 2019, 99: 105948.

[30] Liao Y, Qing X, Wang Y, et al. Damage localization for composite structure using guided wave signals with Gramian angular field image coding and convolutional neural networks[J]. Composite Structures, 2023, 312: 116871.

[31] Deng A, Hooi B. Graph neural network-based anomaly detection in multivariate time series[C]. Proceedings of the AAAI conference on artificial intelligence. 2021, 35(5): 4027-4035.

[32] Neves C, Zeng Y, Xiao Y. Parkinson's disease detection from resting state EEG using multi-head graph structure learning with gradient weighted graph attention explanations[C]. International Workshop on Machine Learning in Clinical Neuroimaging. Cham: Springer Nature Switzerland, 2024: 3-12.

[33] 姜彦吉,郭丁旭,邱友利,等. 基于图神经网络的交通场景声音事件检测[J]. 信息与控制, 2025, 54(3): 413-427.

[34] 金罡,淑琴,哈斯. 融合图神经网络与局部熵的双波段红外图像目标检测研究[J]. 激光杂志, 2025, 46(4): 192-197.

[35] 姚军,慕涛涛. 基于图神经网络的嵌入式设备固件漏洞检测[J]. 计算机应用与软件, 2026, 42(9): 255-262.

[36] Sorensen D, Dey B, Hwang M, et al. Unsupervised Anomaly Prediction with N-BEATS and Graph Neural Network in Multi-variate Semiconductor Process Time Series[J]. arXiv preprint arXiv:2510.20718, 2025.

[37] Lucchetti A, Cadini F, Giglio M, et al. Graph Network-based Structural Simulator: Graph Neural

Networks for Structural Dynamics[J]. arXiv preprint arXiv:2510.25683, 2025.

[38] Moll J, Kathol J, Fritzen C P, et al. Open guided waves: online platform for ultrasonic guided wave measurements[J]. Structural Health Monitoring, 2019, 18(5-6): 1903-1914.

[39] Luo K, Zhu J, Li Z, et al. Ultrasonic lamb wave damage detection of cfrp composites using the bayesian neural network[J]. Journal of Nondestructive Evaluation, 2024, 43(2): 48.

[40] Shang L, Zhang Z, Tang F, et al. CNN-LSTM hybrid model to promote signal processing of ultrasonic guided lamb waves for damage detection in metallic pipelines[J]. Sensors, 2023, 23(16): 7059.

[41] Ma J, Zhao S, Yang Z, et al. MCAGN: Multi-layer Coupled Attention Graph Networks for Composites Damage Detection[J]. IEEE Sensors Journal, 2025.

[42] Xu Y, Zhang C, Luo Y, et al. Multi-attention spatio-temporal fusion graph neural network for chemical process fault diagnosis[J]. IEEE Transactions on Instrumentation and Measurement, 2025.

致　谢

熬了一宿，草草落下结论，便急着提笔去写致谢。往上一翻，才蓦然发现，开篇的摘要还是一片空白——就像我本科四年，终于走到收尾的时刻，心中有千言万语，提笔却不知从何说起。转念一想，却道是“致谢一句，胜却万言”。

一谢父母。感谢你们二十年来不求回报、默默给予，用半生辛劳，换我四年轻盈，让我在学校里不必为了生计发愁。

二谢导师。感谢温银堂老师和钱泉老师对此次毕业设计的悉心指导，让这篇论文从一团模糊，渐渐显露出清晰的轮廓。感谢呼忠权老师、潘钊老师、车海军老师、袁亚洲老师、李倩老师，以及其他授业老师，让我从懵懂之中，一步一步看清楚前方的道路。

三谢同窗。感谢王思萌、李梓华、石易平、王嘉琪、付果豪、安歆尧、于艺林、申方亦、陈昊、何越、闫旭、马英杰、张宇浩、王太毅、洪孜、宋增博、蒲铭浩、朱卫哲、邹骐宇，以及科协的其他朋友，让这四年充实而又收获满满。感谢孙鑫、邓子衡、袁浩、徐晓晨、李首成、石博伦、邢博、吴佳玮、刘晨宇，以及智能车队的其他朋友，让我在比赛中收获成长。感谢袁辉、叶帅鑫、张文博、贾世杰、胡宗浩，以及无协的其他朋友，让我感受到了大家庭的温暖。感谢舍友韩昱享、李海贝、黄林烁、赵艺鹏、陈旭洋，包容我日夜颠倒的作息，让狭小的寝室充满温情。感谢电子科技大学的余洋、茹浩然，帮助我完善毕设，让我磕磕绊绊完成了任务。感谢陈志强、陈浩楠、王晓阳、郭嘉媛、李洪瑞、陈学谦、李轩汉，以及其他在大学四年一路上帮助过我的朋友，友谊地久天长。

四谢自己。感谢那个曾经焦虑、压抑、悲伤，却始终没有停下脚步的自己。感谢你努力地匍匐前进，尽管走得并不完美，但你确确实实地走过来了，一步都没有落下。

五谢致谢。感谢你，让四年的点点滴滴，化作了一篇可以郑重落笔的告别。那些未曾说出口的感激，那些散落在时光里的回忆，终于有了安放之处。

天下没有不散的筵席。再过一个多月，我们也将要搬离学校，各奔东西，跃入人海，做一朵奔涌的浪花。

今日恰是小满。

何须多虑盈亏事，终归小满胜万全。

附录 1 物理异构图神经网络主要代码

```
class PHGNN(nn.Module):
    def __init__(self,device):
        super(PHGNN, self).__init__()
        self.q_fc = torch.nn.Linear(70, 70)
        self.k_fc = torch.nn.Linear(70, 70)
        self.v_fc = torch.nn.Linear(70, 70)

        self.layer = torch.nn.MultiheadAttention(66, 11, 0.4, True)

        self.edge_index1 = self.edge_cul()
        self.edge_index1 = torch.tensor(self.edge_index1, dtype=torch.long).t()
        self.edge_index1 = self.edge_index1.transpose(0, 1).to(device)

        self.layernorm = torch.nn.LayerNorm(70)
        self.FFN_layer = nn.Sequential(nn.Linear(70, 140), nn.ReLU(), nn.Linear(
        140, 70), )

        self.gcn_layer2 = GCNConv(70, 140)
        self.gcn_layer3 = GCNConv(140, 140)
        self.gcn_layer4 = GCNConv(140, 140)

        self.bnn1 = nn.BatchNorm1d(140)
        self.bnn2 = nn.BatchNorm1d(48)

        self.cov_layer1 = nn.Conv1d(86, 43, kernel_size=3)
        self.cov_layer2 = nn.Conv1d(43, 20, kernel_size=3)

        self.bn1 = nn.BatchNorm1d(48)
        self.bn2 = nn.BatchNorm1d(43)
        self.bn3 = nn.BatchNorm1d(20)

        self.pool = nn.MaxPool1d(kernel_size=2, stride=2)

        self.fc_layer1 = torch.nn.Linear(2720, 256)
        self.fc_layer2 = torch.nn.Linear(256, 32)
        self.fc_layer3 = torch.nn.Linear(32, 5)

```

```
        self.drop = nn.Dropout(0.4)

    def forward(self, batch_waveforms):
        q = self.q_fc(batch_waveforms)
        k = self.k_fc(batch_waveforms)
        v = self.v_fc(batch_waveforms)

        q = q.reshape(q.shape[0],70,66)
        k = k.reshape(k.shape[0],70,66)
        v = v.reshape(v.shape[0],70,66)

        att,_ = self.layer(q, k, v)
        att = att.reshape(att.shape[0],66,70)

        H = self.layernorm(att + batch_waveforms)
        X = self.layernorm(self.FFN_layer(H) + H)

        res = []
        for each_epoch in X :
            padded = F.pad(each_epoch, (0, 0, 0, 20), mode='constant', value=0)
            x = self.gcn_layer2(padded, self.edge_index1)
            x = self.bnn1(x)

            res.append(x)

        res = torch.stack(res)
        res = F.relu(res)
        res = self.cov_layer1(res)
        res = self.bn2(res)
        res = F.relu(res)
        res = self.cov_layer2(res)
        res = self.bn3(res)
        res = F.relu(res)

        res = res.reshape(batch_waveforms.shape[0],-1)

        res = self.fc_layer1(res)
        res = F.relu(res)
        res = self.drop(res)
        res = self.fc_layer2(res)
        res = F.relu(res)
```

```
78.             res = self.drop(res)
79.             res = self.fc_layer3(res)
80.             return res
81.
82.         def edge_cul(self):
83.             x = [450,370,290,210,130,50]
84.             y = [470,30]
85.
86.             points = np.array([[x[j],y[i]] for i in range(len(y)) for j in range(len(x))])
87.
88.             def get_x(x1,y1,x2,y2,y):
89.                 k = (y-y1)*(x2-x1)/(y2-y1)+x1
90.                 if 0<=k<100:
91.                     return 0
92.                 elif 100<=k<200:
93.                     return 1
94.                 elif 200<=k<300:
95.                     return 2
96.                 elif 300<=k<400:
97.                     return 3
98.                 elif 400<=k<500:
99.                     return 4
100.
101.            counter = 0
102.            vin = []
103.            vout = []
104.            for i in range(len(points)):
105.                for j in range(i+1,len(points)):
106.                    if points[i][1] == points[j][1]:
107.                        counter +=1
108.                        continue
109.                    area = []
110.                    temp =int(get_x(points[i][0],points[i][1],points[j][0],points[j][1],50))
111.                    area.append(temp)
112.                    temp = get_x(points[i][0],points[i][1],points[j][0],points[j][1],150)
113.                    area.append(temp)
114.                    area.append(temp+5)
115.                    temp =get_x(points[i][0],points[i][1],points[j][0],points[j][1],250)+5
116.                    area.append(temp)
117.                    area.append(temp+5)
118.                    temp=get_x(point[i][0],points[i][1],points[j][0],points[j][1],350)+10
```

```
            area.append(temp)
            area.append(temp+5)
            temp=get_x(point[i][0],points[i][1],points[j][0],points[j][1],450)+15
            area.append(temp)
            area = list(set(area))
            area.sort()
            for i in range(len(area)):
                vin.append(counter)
                vout.append(area[i]+66)
            counter +=1
        l = [vin,vout]
        l = np.array(l)
        return l
```

附录 2 复数自适应图卷积网络主要代码

```
class CAGCN(nn.Module):
    def __init__(self, device: torch.device, channel_num, window_len):
        super().__init__()
        self.in_channels = channel_num
        self.seq_len = window_len
        # Conv1D
        self.conv1_in = channel_num   # 86
        self.conv1_out = channel_num//2
        self.conv2_in = self.conv1_out     # 43
        self.conv2_out = self.conv1_out//4
        self.kernel_size = 3
        # FC 参数
        self.fc_hidden1 = 256
        self.fc_hidden2 = 32
        self.num_classes = 5

        self.pimgc = PIMGC(device, channel_num, window_len)
        self.fhgcn = FHGCN(channel_num, window_len)
        # CNN
        self.conv1 = nn.Conv1d(self.conv1_in, self.conv1_out, self.kernel_size)
        self.conv2 = nn.Conv1d(self.conv2_in, self.conv2_out, self.kernel_size)
        self.pool = nn.MaxPool1d(kernel_size=2, stride=2)
        # 批归一化
        self.bn_conv1 = nn.BatchNorm1d(self.conv1_out)
        self.bn_conv2 = nn.BatchNorm1d(self.conv2_out)
        # 全连接层
        self._compute_fc_input_size()
        self.fc1 = nn.Linear(self.fc_input_size, self.fc_hidden1)
        self.fc2 = nn.Linear(self.fc_hidden1, self.fc_hidden2)
        self.fc3 = nn.Linear(self.fc_hidden2, self.num_classes)
        self.dropout = nn.Dropout(0.4)

    def _compute_fc_input_size(self):
        with torch.no_grad():
            dummy = torch.zeros(1, self.in_channels, self.seq_len)
            features = self._extract_features(dummy)
            self.fc_input_size = features.view(1, -1).shape[1]
```

```
38.
39.         def _extract_features(self, batch_waveforms) -> torch.Tensor:
40.             x = self.pimgc(batch_waveforms)
41.             x = self.fhgcn(x)
42.
43.             #  Conv1D
44.             x = self.conv1(x.real)
45.             x = self.bn_conv1(x)
46.             x = F.relu(x)
47.             x = self.pool(x)
48.             x = self.conv2(x)
49.             x = self.bn_conv2(x)
50.             x = F.relu(x)
51.             x = self.pool(x)
52.             return x
53.
54.         def forward(self, batch_waveforms: torch.Tensor) -> torch.Tensor:
55.
56.             x = self._extract_features(batch_waveforms)
57.             flat = x.view(batch_waveforms.shape[0], -1)
58.
59.             out = self.fc1(flat)
60.             out = F.relu(out)
61.             out = self.dropout(out)
62.             out = self.fc2(out)
63.             out = F.relu(out)
64.             out = self.dropout(out)
65.             out = self.fc3(out)
66.             return out
```

燕山大学毕业设计（论文）答辩评审表

学院：电气工程学院　　专业（方向）：测控技术与仪器

题目名称		基于深度图神经网络的板状结构超声损伤定位方法			
学号	202211030001	姓名	游寅龙	班 级	检测 22-2
指导教师姓名		温银堂	职称		

序号	评审项目	指标	满分	评分
1	设计实现	原理正确，体现科学性；方案详实，体现工程性；实物作品成果有特色；仿真研究结论有价值	30	28
2	工程社会	在毕业答辩或毕业论中能够合理有效运用相关技术标准、产业政策等，且文献引用符合学术要求；能将设计题目与实际应用中的工程背景结合起来考虑解决方案，并对工程与社会发展、环境的关系有自己的理解认识	5	5
3	项目管理	能在设计过程中将涉及各个细分学科领域的知识、技术、方法融会贯通，共同支持设计目标的实现；能够合理分析设计实现所需要的成本，能合理规划设计进程的时间节点。	5	5
4	沟通交流	态度认真，对完成的毕业设计（论文）内容完全掌握；PPT 讲解陈述清楚，回答问题正确，报告撰写规范，能反映出学生对毕业设计题目和内容有足够的理解，并投入了足够的精力	10	9

	总分	47

燕山大学毕业设计（论文）AIGC 检测核实记录表

AIGC 检测疑似度：__（AIGC 检测疑似度超过 35%，以下内容必填）

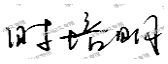
序号	评审项目	指标	情况
1	选题意义	学生是否清楚选题意义	☐非常清楚 ☑清楚 ☐不清楚
2	论文结构	学生是否清楚论文结构	☐非常清楚 ☑清楚 ☐不清楚
3	论文内容	学生是否了解论文内容	☐非常了解 ☑了解 ☐不了解
4	论文观点	学生是否能准确地表达论文观点	☐非常准确 ☑准确 ☐不准确
5	论文数据	学生是否能准确解释论文中的数据	☐非常准确 ☑准确 ☐不准确

评语：

通过

答辩委员会小组成员

姓名（签名）： 

答辩委员会（小组）负责人签名： 

2026 年 06 月 11 日

燕 山 大 学

本科毕业设计（论文）开题报告

课题名称：基于深度图神经网络的板状结构超声异常检测方法

学　　院：电气工程学院

年级专业：22 级检测技术及仪器

学生姓名：游寅龙

指导教师：温银堂

填写日期：2026 年 03 月 14 日

一、综述本课题国内外研究动态，说明选题的依据和意义

自 20 世纪中后期以来，为支撑大规模基建工程、高铁网络等国家战略项目的迫切需求，我国复合板材产业实现了跨越式发展。伴随工业化进程持续深化，复合板材构件凭借轻质高强、耐腐蚀、易成型等综合优势，已大规模替代传统木材与金属合金，成为汽车、船舶、航空航天等运输装备制造领域的核心用材。特别是在高速列车轻量化设计、大型船舶结构优化及新能源汽车车身制造中，复合材料占比持续提升，其服役性能直接决定着整体装备的运载效率与使用寿命。[1]

在此大背景下，工程项目的规模化拓展与质量标准的不断提升，对构件检测提出了更高要求，需要在不损伤构件力学性能的前提下，实现检测过程的实时化、在线化与结果的高精度量化。作为大型工程结构中的核心承力骨架与关键载荷传递单元，复合板材构件在制造及长期服役过程中，不可避免地会受到多重复杂因素的交互作用。化学腐蚀环境可诱发点蚀、晶间腐蚀等局部损伤；极端温度场会改变材料微观组织结构与力学行为；而静载、动载及交变应力的长期作用，则可能导致疲劳裂纹的萌生与扩展。值得特别关注的是，表面损伤往往成为构件失效的初始敏感区，微小的腐蚀凹坑或划痕不仅会削弱有效承载截面，更会作为局部应力集中点，在服役载荷下诱发裂纹的萌生与扩展，最终可能导致突发性断裂事故。[2]此类损伤演化过程具有显著的隐蔽性与累积性特征：初期损伤往往深埋于材料表层之下，或表现为肉眼难以识别的微观缺陷，常规检测手段难以有效捕捉；随着服役时间延长，损伤将经历从量变到质变的渐进式演化，一旦达到临界尺寸，便可能引发结构性能的急剧劣化。[3]

大量工程实践表明，表面缺陷的漏检或误判，是导致大型工程结构承载能力下降、剩余寿命缩短的主要原因之一。[5-7]若未能建立有效的在线监测与定期检测机制，及时识别并评估早期损伤状态，这些初始缺陷将持续扩展，严重削弱结构完整性，甚至引发灾难性连锁失效。因此，在众多针对复合材料缺陷特征的理论研究与实验分析基础上，采用有效的无损检测技术手段，对先进复合材料结构的生产过程与服役状态进行全生命周期监测，已成为保障产品品质进步、使用安全的重要技术路径。

1.1 板材无损检测方法

当前，板材的无损检测方法主要通过在目标结构中部署智能传感元件来进行。常见的方案包括光栅传感器法[7]，热成像法[8]，射线检测法[9]和超声导波法[10-12]。

1.1.1 光栅传感器法

光栅传感器法核心是利用光栅对应变场中拉伸部分或压缩部分的敏感性而测量。具体而言，光纤布拉格光栅作为传感元，反射特定波长的光。当应变场变化时，光栅周期及纤芯折射率改变，导致反射波长发生漂移，通过解调仪实时精确探测波长

变化量，依据线性关系反演出被测点的应变值。[13]该方案可实现高精度、分布式、抗电磁干扰的应变场测量，但探测光仅能探测表面损失，内部微损伤难以探测。

1.1.2 热成像法

热成像法核心是利用损伤区域与完整区域的热特性差异而测量。具体而言，采用高能脉冲闪光灯激励源对被试件表面进行瞬时加热，外激励热流在试件内部发生热传导，热流在传导过程中，由于试件内部热特性存在不连续性结构，将导致对应表面温度分布发生异常。[14]该方案操作简单，检测速度快，可大面积检测，但由于热扩散的过程容易引入大量噪声，因此对深层缺陷不敏感。

1.1.3 射线检测法

射线检测法核心是利用 X 射线或γ射线在穿透板材时，因材料内部结构差异而产生不同衰减的特性来识别损伤。具体而言，当强度均匀的射线穿透板材时，其能量会因材料的吸收和散射而发生衰减，缺陷区域的厚度减小或者密度降低会减弱射线的衰减作用，因此穿过损伤区域的射线强度会高于周围完好区域。检测装置将射线强度图像转化为灰度图像，通过深浅对比来判断是否存在损伤。[15]该方案适用材料广，可直观判断缺陷位置，但检测成本高昂、效率较低，且射线对人体有害，因此难以大范围推广使用。

1.1.4 超声导波法

超声导波法核心是利用了超声波场在板材内部传播的弹性波场来进行检测。[16]具体而言，换能器在板中激励特定模态的导波，当导波遇到裂纹或腐蚀等损伤时，会发生反射、透射、散射及模态转换等现象。通过布置在板面上的接收传感器阵列采集这些携带损伤信息的波信号。分析接收信号的离散数字特征来判断成像。[17]该方案具有传播距离远、衰减小、可一次性大范围快速检测的优点，是目前公认最有前景的方案，但导波固有的多模态与频散特性导致信号处理方面仍有不小挑战。

1.2 超声导波技术的国内外研究现状

超声导波的早期的损伤定位研究主要依赖于 Lamb 波传播的物理机制。1967 年，前苏联科学家 Viktorov[18]阐述了 Rayleigh 波和 Lamb 波的理论方程，并仔细探讨其在超声导波检测方面的重要用途。之后，Auld[19]进一步在声学理论上推导了各种超声导波的传播方式和模态，提出声波经过多重的反射和模态转换后会以波包的形式沿着板材的延展方向传播，从而形成导波。这一研究既证明了超声导波在板材检测领域的可行性，也提出超声导波具有的多模态和频散特性将对超声检测带来负面影响。之后的众多学者，也针对此特性提出了不同的解决方案，其中基于波包飞渡时间的椭圆定位法是应用最广泛的手段之一。该方法利用压电传感器网络激发并接收 Lamb 波，通过计算损伤散射波到达各传感器的时间差，结合波速构建椭圆轨

迹，多椭圆交点即为损伤位置。例如，张海燕[20]等人采用采用椭圆轨迹定位法布置了传感器网络对铝板进行了损伤定位，应用图像融合的方法绘制了损伤概率成像图，有效确定了损伤的尺寸大小与分布位置；魏诺柯[21]等人提出了无基准双曲线定位算法，并开展了铝板不同位置的缺陷定位实验研究，可大致确定损伤位置，误差可以控制在 10% 以下。然而，由于复合材料的各向异性及 Lamb 波固有的频散与多模态特性，波速难以精确获取，且手动提取 ToF 存在主观误差。

为克服上述问题，研究者引入了概率成像和贝叶斯推断方法。例如，Yun 等[22]比较了基于散射波 ToF 的概率矩阵算法与人工神经网络算法，指出前者定位精度受人为选择参数和材料各向异性影响较大；Yan 等[23]提出了基于贝叶斯理论的损伤定位框架，将波速作为未知参数，结合连续小波变换提取的 ToF 数据，利用马尔可夫链蒙特卡洛方法更新参数的后验概率分布。该方法不仅给出了损伤位置的估计值，还量化了由测量误差和模型简化带来的不确定性，在加筋铝板和复合材料层合板上取得了良好效果。此外，针对塑料管道的早期裂纹难以检测的问题，Hong 等[24]利用非线性超声调制技术，提取对裂纹敏感的一阶边频带信号，并通过小波包能量进行损伤评价，展示了非线性特征在小损伤检测中的潜力。尽管上述传统方法在实验室条件下取得了一定效果，但其在实际工程应用中面临诸多严峻挑战。Hughes 等[25]认为以上方法性能高度依赖于材料特性的精确建模，而实际复合材料往往存在工艺偏差和性能分散性；多模态叠加、边界反射及环境噪声干扰导致时域波形复杂，准确提取损伤散射波到达时刻极为困难；传统方法缺乏对海量监测数据的自适应学习能力，难以处理复杂损伤模式。

随着人工智能的复兴，深度学习凭借其强大的特征自提取和非线性映射能力，为解决传统方法中复杂的信号解读难题提供了新思路。最直接的方法是将传感器采集的原始一维 Lamb 波信号或其衍生的损伤指数输入神经网络。Zhang 等[26]指出，传统损伤指数虽能指示损伤存在，但缺乏时间信息。为此，他们提出了一种基于短时傅里叶变换的时变损伤指数，并结合一维卷积神经网络建立该指数与损伤坐标的映射关系。实验证明，仅用 4 个传感器即可在铝板上实现定位，且模型展现出了一定的跨板泛化能力。Zhuang 等[27]则采用门控循环单元网络，融合原始时域信号和连续小波变换提取的能量信号，在仅用一对激励-接收传感器的情况下，实现了对复合材料板的全场损伤定位，显著提高了模型在有限数据下的抗干扰能力。近些年来，有学者将图像识别技术引入该领域，将一维信号转换为二维图像，充分利用卷积神经网络在图像处理领域的优势增强识别的可靠性。转换方式主要分为时频分析和空间编码。前者基于经典数字信号处理手段，将时域转化为频域扩充，Rautela 等[28]通过连续小波变换将一维超声波数据转换为二维时频图像，并利用 CNN 和 LSTM

混合模型实现损伤检测与定位。Liu 等[29]则利用同步挤压小波变换的高分辨率时频表示，结合分水岭分割算法，实现了对牛胫骨板和钢板中多模态导波的自动分离与重构。后者则基于格拉姆角场，将离散点首位相连形成的线段转化为角度，从而保留信号的完整性和时间依赖性。Liao 等[30]提出了一种改进的分段聚合近似算法对导波信号进行压缩和特征提取，然后将多路径融合后的损伤指数序列通过 GAF 编码为二维图像。结合引入卷积块注意力模块的 CNN 网络，该方法在碳纤维复合材料板上实现了高精度的损伤坐标回归，其性能优于传统的一维 CNN 和 RAPID 成像算法。Shao 等[10]进一步拓展了该思路，将 GAF 图像与一维损伤指数序列共同输入到多维度特征融合网络中，同时实现了对单源偏移损伤和多源累积损伤的定位与量化，并在不同传感器阵列布局间验证了迁移学习的可行性。

尽管，深度学习为从超声导波信号中自动提取损伤特征提供了强大工具，但以卷积神经网络为代表的主流方法，通常将传感器阵列数据视为规则网格或独立序列进行处理，未能有效建模传感器之间的非结构化空间拓扑关系，也缺乏对导波传播物理机理的显式融合。这使得模型难以充分挖掘传感器布局、波动信号与损伤状态之间的深层耦合机制，从而在复杂实际场景中面临泛化能力和物理可信度的挑战。

1.3 图神经网络在无损检测领域的研究

近年来，图神经网络（Graph Neural Networks，GNN）凭借其强大的关系归纳偏置能力，在处理非欧几里得结构数据方面展现出独特优势。该类网络能够显式建模实体之间的交互与依赖关系，在挖掘数据深层结构方面表现出显著潜力，尤其适用于多通道时间序列的异常检测任务。Deng 等[31]于 2021 年首次将 GNN 引入时间序列异常检测，在多变量数据集上系统验证了其有效性，为相关研究奠定了方法论基础。受此启发，Neves 等[32]构建了基于脑区功能连接的图结构，将多通道脑电信号转化为图数据，并成功应用于阿尔茨海默症的病理特征识别。在应用场景不断拓展的背景下，GNN 被逐步引入更具挑战性的多模态任务中。姜彦吉等[33]针对复杂行车环境下的声音事件检测问题，提出一种融合交叉模态信息的 GNN 方法。该方法首先通过声音事件窗提取信号中的共时与历时关系，经噪声过滤后构建关系图结构；随后改进图卷积网络以平衡邻居节点与自身节点的权重，缓解过度平滑问题；最后结合卷积循环网络学习声学特征与时序信息，通过交叉模态融合提升事件检测性能。金罡等[34]则提出融合 GNN 与局部熵的双波段红外图像目标检测方法，采用单尺度 Retinex 增强图像，通过加权局部熵获取显著图，并联合卷积网络与 GNN 进行目标特征提取，实验结果表明该方法在信息保留和检测精度方面均表现优异。在软件安全领域，GNN 亦展现出强大的语义建模能力。姚军等[35]提出基于代码属性图与双向 GNN 的嵌入式设备固件漏洞检测方法，从源代码层面实现自动化漏洞识别。在

SARD 数据集和真实漏洞数据集上的实验结果表明，该方法在检测精度和 F1 分数上分别达到 93.4% 和 86.54%，显著提升了漏洞识别性能。进入 2025 年，GNN 的应用进一步向工业制造领域深化。Sorensen 等[36]针对半导体工艺过程中产生的海量多源跨尺度时序数据，将相互关联的工艺参数构建为图结构，通过图卷积操作捕捉变量间的复杂交互，实现高效异常监控。Lucchetti 等[37]则从理论层面拓展了对 GNN 应用潜力的认识，指出 GNN 不仅适用于静态图模式识别，还可作为结构模拟器用于动态场景下的结构运动分析，为探索复杂动态系统中的异常行为提供了新的理论视角。尽管 GNN 在工程实践中已取得初步成效，目前研究仍主要停留于纯粹的数据驱动范式。由于缺乏物理机制的引导与约束，现有方法普遍存在模型可解释性较差、泛化能力不足等问题，这已成为制约 GNN 进一步发展的关键挑战。如何将图结构学习与物理规律深度融合，有望成为下一阶段研究的重点方向。

1.4 选题的理论依据

在充分阅读文献，并总结前人经验的基础上，认识到传统无损检测方法单纯依赖物理模型难以处理复杂工况；纯粹数据驱动的深度学习则因缺乏物理约束而可解释性差、泛化能力弱。因此本课题依托固体超声学，希望将物理机理嵌入神经网络以增强神经网络模型的解释性能和泛化性能。

从波动理论出发，超声导波在板中的传播与散射遵循确定的弹性动力学方程[38]，这为模型构建提供了首要的物理约束。特别地，高频近似下的射线声学理论[39]，能够清晰地定义“发射-接收”路径与空间点的几何关联，这为将连续的物理场离散化为“传感器-损伤点”的二元关联图提供了严格的数学简化基础，确保了所构建图拓扑的物理可信性。

图论与几何深度学习理论则提供了处理该问题的数学工具。传感器网络与潜在损伤点构成的系统，本质上是包含异质节点与不确定连接的非欧几里得数据结构。图神经网络正是为处理此类关系数据而设计的框架，其消息传递机制能天然模拟波动能量或信息在物理网络中的传播与聚合过程。将波动理论推导的关联作为图的边，相当于为 GNN 的学习空间施加了强物理先验，引导其朝着物理解释合理的方向进行优化。

以上，选题的理论逻辑构成了闭环，以物理原理定义图结构，以图结构承载学习过程，最终通过数据驱动优化实现超越传统模型的检测性能。

1.5 选题的现实意义

本选题直面当前工业无损检测领域亟待突破的效率、精度与智能化瓶颈。在航空航天、新能源、轨道交通等领域，板状结构是关键承力部件，其内部损伤的早期精准识别直接关系到整个系统的安全运行与运维成本。传统超声检测严重依赖操作

人员经验，存在效率低下、结果主观性强、难以实现自动化全检等问题；而常规的自动化检测算法对复杂结构背景噪声和微弱损伤信号的处理能力不足。

本研究提出的物理机理与图神经网络融合的新范式，为上述问题提供了切实可行的解决方案。其端到端的自动化处理流程，能够将检测人员从繁重的数据判读中解放出来，大幅提升检测效率与一致性，为结构健康状态的在线监测与智能预警提供了核心技术支撑。

因此，本研究不仅有望推动无损检测行业向智能化、高可靠性方向转型升级，更能通过保障重大基础设施和高端装备的安全服役，产生显著的经济效益与社会安全效益。

二、研究的基本内容，拟解决的主要问题

2.1 基本内容

本课题设计并实现一个将物理机理与深度学习相结合的异构图神经网络架构，用于板材结构的损伤定位。系统以超声导波信号为输入，通过图结构建模传感器阵列与空间位置的拓扑关系，形成可解释的智能推理框架。主要工作内容如下：

1) 深入分析超声导波在板材中的频散特性与多模态传播规律，通过理论推导与数值模拟揭示波场演化机制。将传感器阵列的空间位置信息以正弦编码或可学习嵌入方式显式融入神经网络，使模型能够有效感知传感器布局与损伤位置之间的几何关联，显著增强损伤定位过程的物理可解释性。
2) 针对多通道导波信号非平稳、多模态混叠的特点，设计专用的特征提取模块，融合时频分析与图卷积操作，在时频域与空间域同步挖掘损伤敏感特征，提升模型在强噪声和复杂边界反射环境下对微弱损伤散射信号的捕获能力。
3) 基于物理信息融合的异构图神经网络，构建从原始导波信号到损伤坐标的端到端智能推断框架。通过异构边集设计表达传感器间、传感器与损伤点间的多元物理关系，在保证定位精度的同时满足实时检测系统的低延迟要求，实现对板材损伤的准确定位。
4) 在多种工况下对系统进行全面评估，重点考察定位准确率、损伤检出率、误报率及跨温度工况的泛化稳定性。通过实验对比验证物理先验约束对模型鲁棒性的提升作用，确保损伤定位正确率稳定达到 80% 以上。

2.2 前期研究

2.2.1 物理声学模型

Lamb 波是一种在板状结构中传播的超声导波，由纵波与横波在板的上、下边界来回反射并耦合干涉而形成。其传播特性由板的几何尺寸与材料属性共同决定，具

有传播距离远、能量衰减小以及对各类缺陷敏感度高等优点，已被广泛应用于板材结构的无损检测与结构健康监测领域。

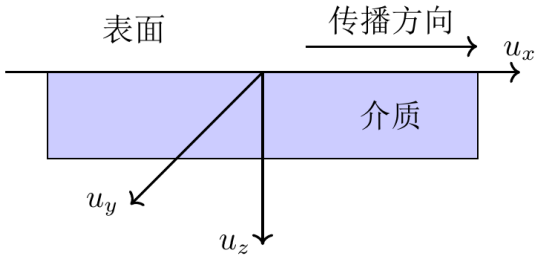


图 2-1 表面波分析坐标系

在无体积力作用下的各向同性均匀线弹性固体内部，其时变位移场 $\vec{u}(t)$ 满足 Navier-Cauchy 方程[40]：

$$\mu\nabla^2\vec{u}+(\lambda+\mu)\nabla(\nabla\cdot\vec{u})=\rho\frac{\partial^2\vec{u}}{\partial t^2} \tag{1}$$

其中，μ 和 λ 是拉梅常数，ρ 是材料的密度。将位移场进行亥姆霍兹分解，可写为标量场 ϕ 和矢量场 $\vec{\psi}$ 的线性叠加：

$$\vec{u}=\nabla\phi+\nabla\times\vec{\psi}\qquad\nabla\cdot\vec{\psi}=0 \tag{2}$$

对于如图 2-1 所示的板状材料，考虑一个厚度为 d 的无限大平板，$z=0$ 是其上表面，超声导波的传播方向定义为 x 轴正方向。Lamb 波只在板材表面传播，因此矢量场 $\vec{\psi}=(0,0,\psi_z)$ 只在 z 轴方向上有值。

将式(2)代入式(1)，经过哈密顿算子化简后可得：

$$\nabla(\rho\frac{\partial^2\phi}{\partial t^2}-(\lambda+2\mu)\nabla^2\phi)+\nabla\times(\rho\frac{\partial^2\psi_z}{\partial t^2}-\mu\nabla^2\psi_z)=0 \tag{3}$$

这个和为零，那么其梯度部分和旋度部分必须分别独立为零，即：

$$\begin{cases}\dfrac{\partial^2\phi}{\partial t^2}=\dfrac{\lambda+2\mu}{\rho}\nabla^2\phi\\[2ex]\dfrac{\partial^2\psi_z}{\partial t^2}=\dfrac{\mu}{\rho}\nabla^2\psi_z\end{cases} \tag{4}$$

标量势 ϕ 对应的位移场无旋，介质仅做体积变换，振动方向与波传播方向相同称为纵波，其波速为 $v_p=\sqrt{(\lambda+2\mu)/\rho}$；矢量势 ψ 对应的位移场无散，介质体积不变，仅做剪切变形，振动方向与波传播方向正交称为横波，其波速为 $v_s=\sqrt{\mu/\rho}$。

考虑沿 x 轴方向传播、频率为 ω 的简谐信号激励，设解具有以下形式：

$$\begin{cases}\phi(x,y,t)=\Phi(y)e^{i(ku_x-\omega t)}\\ \psi_z(x,y,t)=\Psi(y)e^{i(ku_x-\omega t)}\end{cases} \tag{5}$$

则将式(5)代入(3)得到位移场的频域-波数表达式：

$$\begin{cases}u_x=\left[ik\Phi(y)+\dfrac{d\Psi}{dy}\right]e^{i(kx-\omega t)}\\ u_y=\left[\dfrac{d\Phi}{dy}-ik\Psi(y)\right]e^{i(kx-\omega t)}\end{cases} \tag{6}$$

可见沿 u_x 方向位移场仍表现为频率 ω 的简谐波。值得注意的是，对于给定频率，波数 k 通常不唯一，因此实际位移场由多个导波模态叠加而成：

$$\vec{u}^{(m)}(t)=\vec{U}^{(m)}(y,\omega)e^{i(k^{(m)}x-\omega t)} \tag{7}$$

式中 $\vec{U}^{(m)}(y,\omega)$ 为波结构函数，描述第 m 模态在厚度方向的位移分布。

实际检测中通常采用宽带脉冲信号作为激励源，此时各频率分量 ω 在复合材料层间界面处可能发生折射与反射，从而激发或转换为多个传播模态，导致接收信号呈现多模态混叠与频散特性：

$$\vec{u}(x,y,t)=\int_{-\infty}^{\infty}\sum_{m}\vec{A}^{(m)}(y,\omega)e^{i(k^{(m)}(\omega)x-\omega t)}d\omega \tag{8}$$

其中 $\vec{A}^{(m)}(y,\omega)$ 为第 m 阶模态在频率 ω 处的振幅分布函数。因此应用中，损伤和噪声分布在未知的频率成分上，频散效应将进一步使得信号在时频平面呈现复杂结构。因此，仅依赖传统的时域或频域滤波方法，难以有效分离损伤散射信号与背景噪声。

2.2.2 基础机器学习模型

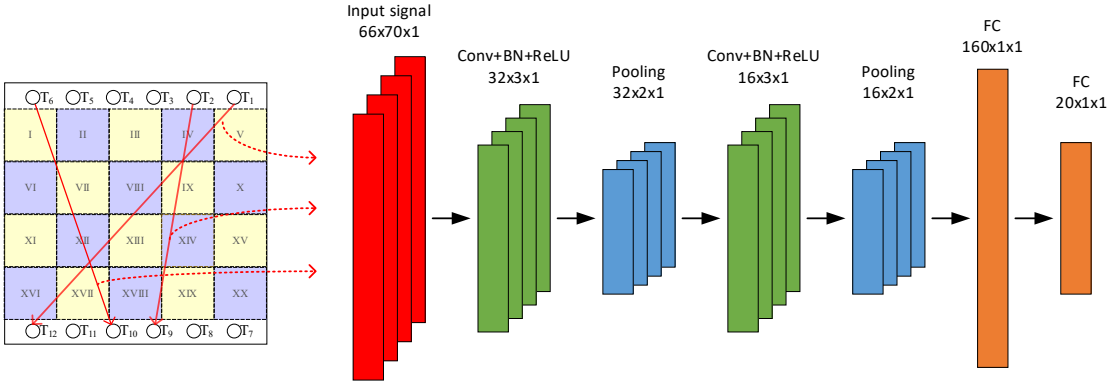


图 2-2 CNN 网络结构示意图

目前现有机器学习模型基于卷积神经网络开发，其结构图如图 2-2 所示，利用其层次化特征提取能力，对输入的 66 通道的各 70 个离散信号进行端到端的学习。该网络通过两个卷积-池化模块逐步降低空间分辨率，同时增加通道数以丰富特征表示；随后将三维特征图展平为一维向量，经由两个全连接层映射至 21 维输出，从

而实现对输入信号的分类或回归。

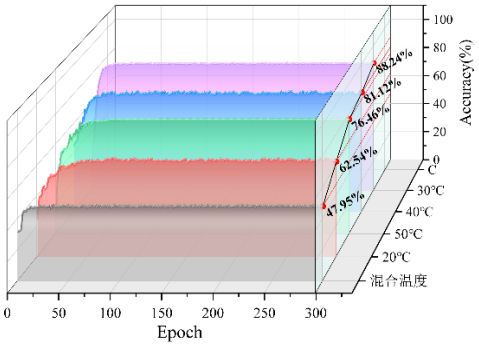


图 2-3 不同温度工况下 CNN 网络的训练正确率

CNN 网络设计在实际实验中具有一定的分类效果，其准确率显著高于随机均匀分布水平。然而，如图 2-3 所示，在混合温度工况下，模型的正确率不足 48%。这表明当前网络结构对温度这一干扰因素较为敏感，温度的大范围变化显著增加了模型的收敛难度。因此，有必要在现有基础模型中针对这一问题进行优化。

2.3 拟解决的主要问题

1) 针对实际检测环境中背景噪声、板材边界反射以及超声导波固有的频散效应所产生的多源干扰耦合问题，研究有效的信号分离方法。重点解决因上述干扰导致的频谱混叠及有效损伤特征信号被湮没的难题，通过建立物理机理引导的信号处理模型，实现高精度干扰抑制与损伤特征增强。
2) 针对纯数据驱动模型在物理机理缺失条件下存在的泛化能力弱、跨工况迁移性能差等问题，探索物理信息与深度学习有机融合的混合建模策略。重点研究如何将超声导波的传播机理、频散特性等物理先验嵌入神经网络架构、损失函数或训练过程中，以提升模型的可解释性、泛化性能及数据驱动效率。
3) 针对融合物理约束后带来的复杂优化，系统研究模型的构建方案、训练策略及参数优化手段。重点解决分类问题中交叉熵损失导致梯度过大难以收敛等难题，确保物理信息增强网络的高效稳定训练与收敛性能。
4) 利用现有测试集，对所提出的检测模型进行全面验证。对比分析本模型与传统信号处理方法及纯数据驱动模型的性能差异，从检测精度、抗干扰能力、泛化性能等多维度进行系统性评估。

三、研究步骤、方法及措施

3.1 研究步骤

如图 3-1 所示，课题研究以构建物理异构图卷积神经网络板材损伤实时检测系统，实现 80% 定位正确率为总目标，按六步进行：

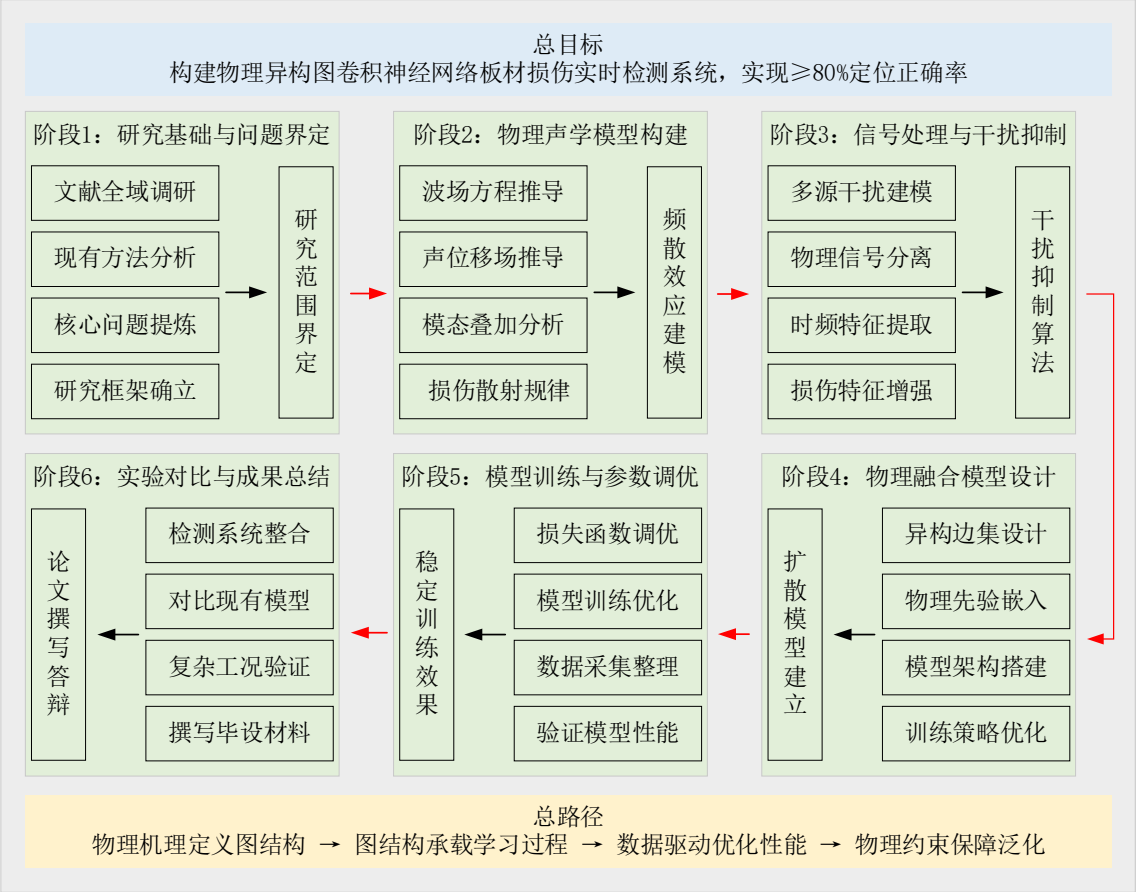


图 3-1 研究路径图

1) 通过文献调研全面梳理板材损伤检测现状，分析现有方法的优势与不足，提炼多源干扰、特征提取等核心问题。界定研究范围，明确研究对象与工况条件，最终确立整体研究框架，为后续系统构建提供理论依据和方向指导；
2) 推导波场方程与声位移场，揭示声波在板材中的传播规律。开展模态叠加分析，识别主要传播模式，并考虑频散效应建立频散模型。同时研究损伤散射规律，建立损伤与声场变化的关联，为信号处理提供物理基础；
3) 识别并建模多源干扰，利用时频分析提取信号关键特征。通过物理信号分离去除干扰成分，设计算法抑制残余噪声，并对损伤特征进行增强，为后续图神经网络输入提供高质量的特征数据；
4) 构建扩散模型描述损伤信息传播，将声场分布、频散特性等物理先验嵌入图神经网络。设计异构节点和边集，定义多种边关系表达物理过程，确保图结构真实反映机理，形成可解释的推理框架；
5) 处理实验数据，训练物理融合图神经网络并调整超参数。设计多任务损失函数兼顾定位精度与物理一致性，通过迭代验证确保模型稳定收敛，为实际应用做好性能准备；

6) 将模型集成到检测系统进行复杂工况验证，对比现有方法凸显优越性。通过数据驱动微调性能，验证物理约束对泛化的提升，最后整理成果撰写论文，完成答辩与项目总结。

3.2 研究方法

1) 对超声导波的物理机理进行理论分析，观察研究其频率的变化规律，以优化模型噪声抑制能力。
2) 采用实验对比法，调整模型训练超参数，测试不同参数对模型收敛性能的影响。
3) 结合物理机理和图神经模型，构建最优且富解释性的神经网络模型。

3.3 研究措施

1) 通过查阅文献和交流学习，自学相关检测原理。
2) 结合已有的研究经验，优化系统设计，提高研究效率。
3) 依托常见模型优化理论，从数学角度确保模型收敛的稳定性。

四、研究工作进度

4.1 预期研究进展

第 1-5 周：熟悉任务书所下发课题和任务，查阅相关参考资料，确定设计方案并参加开题报告答辩。

第 6-10 周：完成图神经网络的构建。撰写中期答辩报告并参加中期答辩。

第 11-12 周：完成超声导波无损检测的实验搭建，进行相关实验数据采集。

第 13-15 周：完成系统整合与综合测试，分析数据。撰写毕业设计论文。

第 16-17 周：整理材料，按照毕业设计论文撰写规范修改毕业设计论文，提交相关材料并准备参加毕业设计答辩。

4.2 预期成果

构建一个基于物理异构图卷积神经网络的、自动化、高精度、低成本的实时板材损失检测系统。

五、主要参考文献

[1] Dwivedi S K, Vishwakarma M, Soni A. Advances and researches on non destructive testing: A review[J]. Materials Today: Proceedings, 2018, 5(2): 3690-3698.

[2] 李瑶,王快社,刘长瑞. 金属板材表面缺陷检测发展现状[J]. 材料导报,2011,(S2):238-241.

[3] 马超. 无损检测技术及应用[J]. 影像科学与光化学,2020,38(1):46-51.

[4] Bao W, Ma J, Yang Z, et al. ConvMPAnet: A novel end-to-end lightweight damage

localization framework under heavy noise in composite structures[J]. IEEE Sensors Journal, 2024, 24(24): 42417-42427.

[5] Yang Z, Zhang Y, Bai Y, et al. The application of deep learning in pipeline inspection: current status and challenges[J]. Ships and Offshore Structures, 2025, 20(7): 1016-1027.

[6] Zhang S, Li J, Wang X, et al. Study on Horizontal Leakage Diffusion Characteristics of Small and Medium Aperture in High-Pressure Natural Gas Pipelines with Large Open Spaces[J]. ACS omega, 2025, 10(10): 10515-10529.

[7] Wang H P, Chen C, Ni Y Q, et al. Computer-aided feature recognition of CFRP plates based on real-time strain fields reflected from FBG measured signals[J]. Composites Part B: Engineering, 2023, 263: 110866.

[8] Li S, Sun J, Guo Y, et al. Experimental investigation of electro-thermal-impact synergistic damage mechanism of CFRP composites injected by impulse lightning current[J]. Composites Part B: Engineering, 2025: 112918.

[9] Wang P, Bai Y, Zhao Z, et al. Damage evolution of CFRP laminates subjected to cryogenic flexure loading using in situ X-ray computed tomography[J]. Composites Part B: Engineering, 2025: 113171.

[10] Shao W, Liao Y, Wang Y, et al. A damage identification method for aviation structure integrating Lamb wave and deep learning with multi-dimensional feature fusion[J]. Ultrasonics, 2025, 151: 107623.

[11] Ismail Z, Mustapha S, Tarhini H. Optimizing the placement of piezoelectric wafers on closed sections using a genetic algorithm–Towards application in structural health monitoring[J]. Ultrasonics, 2021, 116: 106523.

[12] Hong X, Luo Z, Zhang B, et al. Guided-wave quick sparse decomposition approach based on novel peak-frequency modulation dictionary for efficient composite plate damage inspection[J]. Applied Acoustics, 2024, 223: 110081.

[13] Qing X, Kumar A, Zhang C, et al. A hybrid piezoelectric/fiber optic diagnostic system for structural health monitoring[J]. Smart Materials and Structures, 2005, 14(3): S98-S103.

[14] 唐庆菊,王扬,刘俊岩,等. 耐热合金涂层结构板材内部缺陷的脉冲红外热成像检测[J]. 红外与激光工程,2013(7):1685-1690.

[15] 史洪源,李杰,周鹏,等. 钛合金小径管对接焊缝数字射线检测工艺优化与试验[J]. 无损检测,2025,47(7):34-39.

[16]韦迪. 海洋石油静电脱水压力容器的超声导波检测研究[J]. 清洗世界,2024,40(3):80-82.
[17]吕东超. 基于 Lamb 波的机翼蒙皮板材损伤检测方法研究[D]. 贵州:贵州大学,2024.
[18]Viktorov I. Rayleigh and Lamb Wave–Physical Theory and Applications[J].ultrasonic technology, 1967.
[19]Auld B .Acoustic fields and waves in solids[J]. 1973.
[20]张海燕,马世伟,冯国瑞,等. 兰姆波结构健康监测中的概率损伤成像[J]. 声学学报,2012,37(4):401-407.
[21]魏诺珂. 基于超声兰姆波板状结构损伤定位成像精度研究[D]. 华东理工大学.
[22]Yun H, Feng K, Rayhana R, et al. A multidimensional data fusion neural network for damage localization using ultrasonic guided wave[J]. IEEE Transactions on Instrumentation and Measurement, 2023, 72: 1-12.
[23]Yan G. A Bayesian approach for damage localization in plate-like structures using Lamb waves[J]. Smart Materials and Structures, 2013, 22(3): 035012.
[24]Hong X, Lin X, Yang B, et al. Crack detection in plastic pipe using piezoelectric transducers based on nonlinear ultrasonic modulation[J]. Smart Materials and Structures, 2017, 26(10): 104012.
[25]Hughes J M, Mohabuth M, Khanna A, et al. Damage detection with the fundamental mode of edge waves[J]. Structural Health Monitoring, 2021, 20(1): 74-83.
[26]Zhang S, Li C M, Ye W. Damage localization in plate-like structures using time-varying feature and one-dimensional convolutional neural network[J]. Mechanical Systems and Signal Processing, 2021, 147: 107107.
[27]Zhuang L, Luo K, Yang Z. A multimodal gated recurrent unit neural network model for damage assessment in CFRP composites based on Lamb waves and minimal sensing[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 1-11.
[28]Rautela M, Senthilnath J, Moll J, et al. Combined two-level damage identification strategy using ultrasonic guided waves and physical knowledge assisted machine learning[J]. Ultrasonics, 2021, 115: 106451.
[29]Liu Z, Xu K, Li D, et al. Automatic mode extraction of ultrasonic guided waves using synchrosqueezed wavelet transform[J]. Ultrasonics, 2019, 99: 105948.
[30]Liao Y, Qing X, Wang Y, et al. Damage localization for composite structure using guided wave signals with Gramian angular field image coding and convolutional

neural networks[J]. Composite Structures, 2023, 312: 116871.

[31] Deng A, Hooi B. Graph neural network-based anomaly detection in multivariate time series[C]//Proceedings of the AAAI conference on artificial intelligence. 2021, 35(5): 4027-4035.

[32] Neves C, Zeng Y, Xiao Y. Parkinson's disease detection from resting state EEG using multi-head graph structure learning with gradient weighted graph attention explanations[C]//International Workshop on Machine Learning in Clinical Neuroimaging. Cham: Springer Nature Switzerland, 2024: 3-12.

[33] 姜彦吉,郭丁旭,邱友利,等. 基于图神经网络的交通场景声音事件检测[J]. 信息与控制,2025,54(3):413-427.

[34] 金罡,淑琴,哈斯. 融合图神经网络与局部熵的双波段红外图像目标检测研究[J]. 激光杂志,2025,46(4):192-197.

[35] 姚军,慕涛涛. 基于图神经网络的嵌入式设备固件漏洞检测[J]. 计算机应用与软件,2025,42(9):255-262.

[36] Sorensen D, Dey B, Hwang M, et al. Unsupervised Anomaly Prediction with N-BEATS and Graph Neural Network in Multi-variate Semiconductor Process Time Series[J]. arXiv preprint arXiv:2510.20718, 2025.

[37] Lucchetti A, Cadini F, Giglio M, et al. Graph Network-based Structural Simulator: Graph Neural Networks for Structural Dynamics[J]. arXiv preprint arXiv:2510.25683, 2025.

[38] Lowe P S, Lais H, Paruchuri V, et al. Application of ultrasonic guided waves for inspection of high density polyethylene pipe systems[J]. Sensors, 2020, 20(11): 3184.

[39] Zhao X, Gao H, Zhang G, et al. Active health monitoring of an aircraft wing with embedded piezoelectric sensor/actuator network: I. Defect detection, localization and growth monitoring[J]. Smart materials and structures, 2007, 16(4): 1208-1217.

[40] Rose J L. Ultrasonic guided waves in solid media[M]. Cambridge university press, 2014.

指导教师意见 是否同意开题：☐同意　　☐不同意 指导教师签字：
考核组长意见 是否通过开题答辩：☐通过　　☐不通过 考核组长签字（章）：
开题答辩分数：
系级教学单位审核意见 系主任签字（章）： 年　　月　　日

燕 山 大 学

本科毕业设计（论文）中期报告

课题名称：基于深度图神经网络的板状结构超声损伤定位方法

学　　院：电气工程学院

年级专业：22 级检测技术及仪器

学生姓名：游寅龙

指导教师：温银堂

填写日期：2026 年 04 月 14 日

一、任务书中本阶段工作目标与任务要求

1.1 进行相关科学实验，阐述实验方案，论证分析实验方案的合理性

依据超声导波在板材结构中的传播机理与损伤作用规律，从弹性动力学理论及信号系统分析的角度，严密论证计算方案对后续模型训练与损伤反演的有效性与科学合理性。

1.2 设计过程中具有批判性思维和创新意识，能够对已有方法做出评判、改进或创新

在深入剖析传统时频分析与常规深度学习方法于导波信号处理中存在的局限的基础上，展现批判性思维与创新意识。重点在于对现有注意力机制与图神经网络架构做出针对性评判，并提出融合先验物理特征的改进策略或全新设计，以增强模型对复杂损伤特征的捕捉与解释能力。

1.3 掌握超声导波的探测原理及图神经网络的相关算法，了解其实际应用需求

深化对超声导波探测物理原理的理解与掌握，同时研习图神经网络及自注意力机制的核心算法。在掌握基础理论之外，洞悉二者在实际工程应用中的互补需求，探索将导波传播的物理约束形式化为图结构先验与特征变换算子的具体途径。

二、目前已完成任务情况

2.1 基础理论建立

2.1.1 多头注意力机制

注意力机制的设计灵感源于神经认知科学中的“选择性注意”理论。该理论指出，人类在面对海量信息时，会本能地将认知资源聚焦于与当前任务最相关的部分，从而显著提升信息处理的效率与决策的准确性。受此启发，研究者将这一生物现象形式化为可计算的注意力模型。对于给定的输入特征序列 $\mathbf{X}=\{x_1,x_2,\cdots,x_n\}$，注意力分配过程可表述为：

$$e_i=\mathrm{score}(x_i,q) \tag{1}$$

$$\alpha_i=\frac{\exp(e_i)}{\sum_{j=1}^{n}\exp(e_j)} \tag{2}$$

其中，q 表示查询向量，$\mathrm{score}(\cdot)$ 为得分函数，用于度量输入特征与查询之间的相关性。最终，注意力机制的输出由输入特征依所得权重加权求和得到：

$$\mathrm{Attention}(\mathbf{A})=\sum_{i=1}^{n}\alpha_i x_i \tag{3}$$

在此基础上，进一步扩展了单一注意力函数的表达能力，多头注意力机制作为 Transformer 架构的核心组件被提出。该机制通过并排执行多个独立的注意力计算，使模型能够在不同的表示子空间中联合捕捉序列内部的复杂依赖关系。其数学形式

可描述如下，首先，对于输入的查询矩阵$\mathbf{Q}$、键矩阵$\mathbf{K}$和值矩阵$\mathbf{V}$，通过h组独立学习的线性投影将其映射到不同的子空间：

$$\mathbf{h}_i = f\left(\mathbf{W}_i^{(q)}\mathbf{Q}, \mathbf{W}_i^{(k)}\mathbf{K}, \mathbf{W}_i^{(v)}\mathbf{V}\right) \tag{4}$$

其中$\mathbf{W}_i^{(q)}$、$\mathbf{W}_i^{(k)}$与$\mathbf{W}_i^{(v)}$为可学习的参数矩阵，而函数$f(\cdot)$表示注意力汇聚操作。获得所有h个头的输出$\mathbf{h}_1,\ldots,\mathbf{h}_h$之后，多头注意力机制通过拼接各头结果并施加一个线性变换$\mathbf{W}_o$生成最终输出

$$\text{MultiHead}(\mathbf{Q},\mathbf{K},\mathbf{V}) = \mathbf{W}_o\begin{bmatrix}\mathbf{h}_1\\ \vdots \\ \mathbf{h}_h\end{bmatrix} \tag{5}$$

该结构使得模型能够同时从不同角度关注输入信息，从而显著增强了对序列内多样化依赖关系的建模能力。

2.1.2 图卷积神经网络

图卷积神经网络是一类专为处理图结构数据而设计的深度学习模型，能够有效应对社交网络、交通路网、分子拓扑等非欧氏空间中的复杂数据关系。通过引入“局部连接”与“权重共享”的卷积思想，该模型实现了对图结构信息的高效特征提取与鲁棒表示学习。

图作为一种由顶点和边构成的数学结构，可形式化地表示为$\mathcal{G} = \{\mathbf{V}, \mathbf{E}\}$，其中$\mathbf{V}$为顶点集合，$\mathbf{E}$为边集合。进一步地，图的连接关系可通过邻接矩阵$\mathbf{A}$与度矩阵$\mathbf{D}$加以刻画：

$$A_{ij} = \begin{cases}1, & \text{if } (v_i, v_j) \subseteq \mathbf{E}\\ 0, & \text{otherwise}\end{cases} \tag{6}$$

$$D_{ii} = \sum_j A_{ij} \tag{7}$$

图卷积神经网络的核心思想在于通过聚合邻域节点的信息来迭代更新当前节点的特征表示。基于谱图理论，经典的图卷积操作通常借助图的拉普拉斯矩阵$\mathbf{L} = \mathbf{D} - \mathbf{A}$来定义。具体而言，拉普拉斯矩阵可进行如下特征分解：

$$\mathbf{L} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^\top \tag{8}$$

其中，$\mathbf{U}$为特征向量矩阵，$\mathbf{\Lambda}$为由特征值构成的对角矩阵。在图傅里叶域中，对于信号$\mathbf{x}$的卷积运算可表达为滤波器g_θ与信号的乘积：

$$g_\theta * \mathbf{x} = \mathbf{U}g_\theta(\mathbf{\Lambda})\mathbf{U}^\top\mathbf{x} = g_\theta(\mathbf{L})\mathbf{x} \tag{9}$$

然而，上述谱域卷积依赖于拉普拉斯矩阵的特征分解，计算代价高昂，难以直接应用于大规模图。为降低复杂度，研究者进一步采用归一化拉普拉斯矩阵$\mathbf{L}_{\text{sym}}$来近似卷积传播过程：

$$\mathbf{y} = g_\theta(\mathbf{L}_{\text{sym}})\mathbf{x} = g_\theta(\widetilde{\mathbf{D}}^{-\frac{1}{2}}\widetilde{\mathbf{A}}\widetilde{\mathbf{D}}^{-\frac{1}{2}})\mathbf{x} \tag{10}$$

据此，图卷积网络经典的逐层传播规则可表述为：

$$\mathbf{H}^{(l+1)}=\sigma(\widetilde{\mathbf{D}}^{-\frac{1}{2}}\widetilde{\mathbf{A}}\widetilde{\mathbf{D}}^{-\frac{1}{2}}\mathbf{H}^{(l)}\mathbf{W}^{(l)}) \tag{11}$$

式中，$\widetilde{\mathbf{A}}=\mathbf{A}+\mathbf{I}_N$ 表示添加了自环的邻接矩阵，用以保留节点自身的特征信息；$\widetilde{\mathbf{D}}$ 为 $\widetilde{\mathbf{A}}$ 对应的度矩阵；$\mathbf{H}^{(l)}$ 为第 l 层的节点特征矩阵；$\mathbf{W}^{(l)}$ 是该层可训练的权重矩阵；$\sigma(\cdot)$ 代表非线性激活函数。该设计在保留图拓扑结构先验的同时，实现了高效且可扩展的半监督节点表示学习。

2.2 问题定义

在结构健康检测与导波无损检测的背景下，本课题考虑一个由 M 个探头构成的监测系统，如图 1 所示。

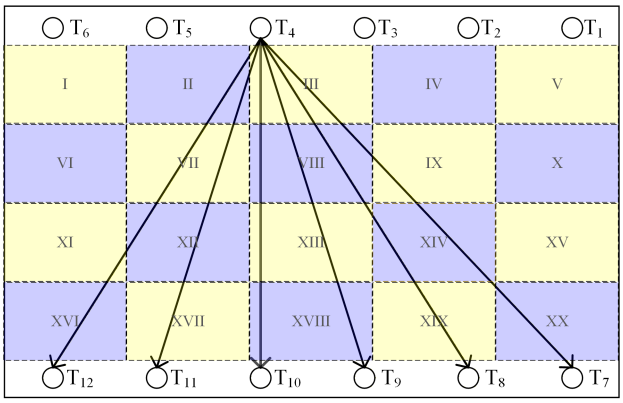


图 1 检测系统示意图

这些探头对称布置于板材结构的上下两侧，从而形成 $N=M(M-1)/2$ 个独立的测量信道。每个信道对应由发射探头 T_i 激励、接收探头 T_j 采集的导波传播信号 $x^{(i,j)}(t)$，其中 $0\le i<j<M$ 。从物理角度看，信号 $x^{(i,j)}(t)$ 可视为对总波场 $\vec{u}$ 在接收探头位置处的离散采样。给定某一时间窗口内的观测数据矩阵 $\mathbf{X}_{0:L-1}\in\mathbb{R}^{N\times L}$，其中 L 表示窗口长度，元素 $x_\tau^{(i,j)}$ 表示第 (i,j) 信道在时刻 τ 处的采样值。本研究旨在解决如何从混叠多模态入射波与环境噪声的观测信号 $\mathbf{X}$ 中，准确诊断出板材结构内部是否存在损坏以及损坏所在定位的问题。该问题可表示为学习一个映射函数 $f:\mathbb{R}^{N\times L}\to\hat{\mathbf{y}}$，其中 $\hat{\mathbf{y}}=\{0,1,\cdots,K\}$ 为损坏分类集合，0 表示无损状态，1至 K 分别对应 K 个不同的损坏定位区域。

2.3 物理信息多粒度自注意力机制

在超声导波传播过程中，频散效应导致波包发生畸变，尽管激励信号中各频率分量的频率保持不变，但波数随材质变化，使得波包在折射中难以保持原始完整性。这一现象使得传统数字信号处理方法难以从整体上对信号进行有效处理。然而，频率的不变性为数据驱动方法提供了关键的理论支撑，具体论证如下：

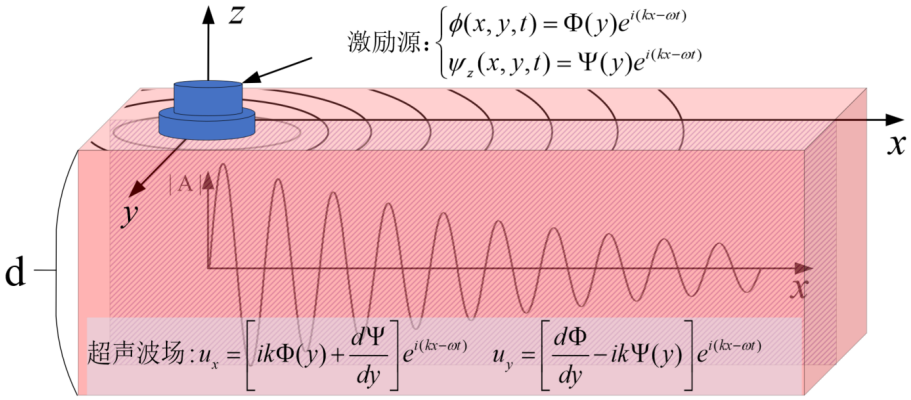


图 2 超声导波分析坐标系

超声导波在板材结构中的传播与损伤相互作用可由波动方程描述，对于各向同性均匀弹性介质，质点运动满足 Navier–Cauchy 方程：

$$\mu\nabla^2\vec{u}+(\lambda+\mu)\nabla(\nabla\cdot\vec{u})=\rho\frac{\partial^2\vec{u}}{\partial t^2} \tag{12}$$

其中 $\vec{u}=(x,y,z,t)$ 为时变位移向量场，μ 和 λ 是材料的 Lamé常数，ρ 为材料密度。针对图 2 所示的导波结构，设 $z=0$ 为其表面边界条件，忽略 z 方向的影响。通过亥姆霍兹分解，时变位移场 $\vec{u}=(x,y,0,t)$ 可表示为标量势 ϕ 与矢量势 $\vec{\psi}=(0,0,\psi_z,t)$ 的组合：

$$\vec{u}=\nabla\phi+\nabla\times\vec{\psi}\qquad\nabla\cdot\vec{\psi}=0 \tag{13}$$

将式(13)代入式(12)求解可得在亥姆霍兹分解下的位移分量的具体形式：

$$\vec{u}=(x,y,0,t)=\left(\frac{\partial\phi}{\partial x}+\frac{\partial\psi_z}{\partial y},\frac{\partial\phi}{\partial y}-\frac{\partial\psi_z}{\partial x},0\right) \tag{14}$$

考虑沿 x 方向传播、频率为 ω 的简谐信号激励，设解具有以下形式：

$$\begin{cases}\phi(x,y,z,t)=\Phi(y)e^{i(kx-\omega t)}\\ \psi_z(x,y,z,t)=\Psi(y)e^{i(kx-\omega t)}\end{cases} \tag{15}$$

则将式(15)代入式(14)得到位移场的频域-波数表达式：

$$\begin{cases}u_x=\left[ik\Phi(y)+\frac{d\Psi}{dy}\right]e^{i(kx-\omega t)}\\ u_y=\left[\frac{d\Phi}{dy}-ik\Psi(y)\right]e^{i(kx-\omega t)}\end{cases} \tag{16}$$

该式表明，在基体材料中，单一频率 ω 激励下，位移场保持简谐波形式，其模态结构及频率成分均不发生变化。然而，实际检测中通常采用宽带脉冲信号作为激励源，此时各频率分量 ω 在复合材料层间界面处可能发生折射与反射，从而激发或转换为多个传播模态，导致接收信号呈现多模态混叠与频散特性：

$$\vec{u}(x,y,t)=\int_{-\infty}^{\infty}\sum_m\vec{A}^{(m)}(y,\omega)e^{i(k^{(m)}(\omega)x-\omega t)}\mathrm{d}\omega \tag{17}$$

其中 $\vec{A}^{(m)}(y,\omega)$ 为第 m 阶模态在频率 ω 处的振幅分布函数。在实际应用中，损伤和噪声分布在未知的频率成分上，频散进一步使得信号在时频域上呈现复杂结构。

针对上述问题，一个关注导波信道间与信道内的物理信息多粒度自注意力机制被提出，其从多粒度角度出发，建模不同尺度下的信号关联模式。

在信道间重要性建模方面，信道与损伤定位之间的关系需被重点关注。具体而言，给定原始信号 $\mathbf{X}\in\mathbb{R}^{N\times L}$，首先将其样本空间划分为 m 个相互独立的子空间。对于第 i 个子空间，通过线性投影分别得到三组变换特征：

$$\mathbf{Q}_i=\mathbf{X}\mathbf{W}_i^{Q}\quad \mathbf{K}_i=\mathbf{X}\mathbf{W}_i^{K}\quad \mathbf{V}_i=\mathbf{X}\mathbf{W}_i^{V} \tag{18}$$

其中 $\mathbf{W}_i^{Q},\mathbf{W}_i^{K},\mathbf{W}_i^{V}\in\mathbb{R}^{L\times d_h}$ 为可学习投影矩阵，$d_h=L/m$ 为每个子空间的维度。在此基础上，计算特征间的相关性矩阵并进行归一化，得到融合权重：

$$\mathbf{h}_i=\mathrm{softmax}\left(\frac{\mathbf{Q}_i\mathbf{K}_i^{\top}}{\sqrt{d_h}}\right)\mathbf{V}_i \tag{19}$$

将 m 个子空间的加权聚合后的特征 $\mathbf{h}_i$ 沿最后一维拼接，得到信道间的增强特征：

$$\mathbf{Y}_t=\mathrm{Concat}(\mathbf{h}_1,\mathbf{h}_2,\ldots,\mathbf{h}_m)\in\mathbb{R}^{N\times L} \tag{20}$$

在信道内重要性建模方面，根据式(17)，需利用频率不变性针对性地突出特定频段。为此，采用离散小波变换将信号映射至时频域，以提取局部振荡特征。选用 Haar 小波基，其尺度函数 $\phi(t)$ 与小波函数 $\psi(t)$ 定义如下：

$$\phi(t)=\begin{cases}1, & 0\le t<1\\ 0, & \text{otherwise}\end{cases} \tag{21}$$

$$\psi(t)=\begin{cases}1, & 0\le t<0.5\\ -1, & 0.5\le t<1\\ 0, & \text{otherwise}\end{cases} \tag{22}$$

对单信道离散信号 $X_n[t]$ 进行单层分解，得到近似系数 $a_n[k]$ 与细节系数 $d_n[k]$：

$$a_n[k]=\sum_{t=1}^{L}X_n[t]\phi(2t-k) \tag{23}$$

$$d_n[k]=\sum_{t=1}^{L}X_n[t]\psi(2t-k) \tag{24}$$

为便于批处理，分解过程可改写为线性变换格式，构造小波变换矩阵 $\mathbf{W}_{\mathrm{DWT}}\in\mathbb{R}^{L\times L}$。每行均由尺度函数与小波函数的离散采样构成，则系数矩阵 $\mathbf{C}_f=\mathbf{X}\mathbf{W}_{\mathrm{DWT}}^{\top}\in\mathbb{R}^{N\times L}$ 的前 $L/2$ 列为近似系数，后 $L/2$ 列为细节系数。将 $\mathbf{C}_f$ 作为变换后的频域特征。采用与式(18)-(20)相同的机制，自适应增强与损伤相关的频率成分，得到更新后的系数 $\mathbf{C}'_f$。最后通过逆离散小波变换重构时域信号：

$$\mathbf{Y}_f=\mathbf{C}'_f\mathbf{W}_{\mathrm{IDWT}}^{\top} \tag{25}$$

其中 $\mathbf{W}_{\mathrm{IDWT}}$ 满足正交性，保证信号完整重构。

为综合信道间与信道内的互补信息，且保留原始信号的底层结构，并引入可学

习的加权残差连接融合策略：

$$\mathbf{Z} = \mathbf{X} + \alpha \cdot \mathbf{Y}_t + \beta \cdot \mathbf{Y}_f \tag{26}$$

其中 $\alpha, \beta \in \mathbb{R}$ 为可学习权重参数，在反向传播中进行优化更新。该设计允许模型自适应地平衡全局依赖与局部振荡特征的重要性。

2.4 物理异构图卷积提取器

在实际检测中，传感器接收到的信号通常表现为基线响应与损伤特征相互混叠的复杂波形。为实现对损伤信息的有效解耦与辨识，需借助合理的机制将二者加以分离。为此，本研究基于先验物理机理，构建了一种物理信息引导的信号分解与反演框架。

对于混杂着损伤特征的基线信号特征 $\mathbf{Z}$ 可被视为 Born 近似框架下各等效散射源强度 $\vec{s}_j$。根据 Born 近似，在弱散射条件下，总的散射波场可近似为各损伤点所等效的散射波场的线性叠加，其数学表达为：

$$\vec{u}^{\mathrm{sc}}(\mathbf{r}, t) \approx \sum_{j=1}^{N_d} \int_0^t \mathcal{G}(\mathbf{r}_i, \mathbf{r}_j, t-\tau) * \vec{s}_j(\tau) \mathrm{d}\tau \tag{27}$$

其中，$\mathcal{G}$ 为格林函数，描述了单位脉冲激励在介质中的传播规律；$\vec{s}_j(\tau)$ 表示第 j 个虚拟损伤节点处的等效源强度。从物理先验的角度而言，损伤的存在等价于在波动方程中引入一虚拟体力项 $\vec{f}_d$，修正后的控制方程可写为：

$$\mu \nabla^2 \vec{u} + (\lambda + \mu) \nabla(\nabla \cdot \vec{u}) - \overrightarrow{f_d} = \rho \frac{\partial^2 \vec{u}}{\partial t^2} \tag{28}$$

依据波场叠加原理，总波场 $\vec{u}$ 可分解为入射波 $\vec{u}^{in}$ 与散射波 $\vec{u}^{sc}$ 之和：

$$\vec{u} = \vec{u}^{in} + \vec{u}^{sc} \tag{29}$$

为实现式(29)所示物理正向过程的逆映射，从接收信号中反演等效源强度 $\vec{s}_j$，本研究构建了一种有向异构图 $\mathcal{G} = \{\mathcal{V}, \mathcal{E}\}$。其中，节点集合 $\mathcal{V}$ 由物理测量节点 $\mathcal{V}_p$ 与虚拟损伤节点 $\mathcal{V}_d$ 共同构成，即 $\mathcal{V} = \mathcal{V}_p \cup \mathcal{V}_d$。$\mathcal{V}_p$ 对应于实际的“激励-接收”探头对，其初始特征由前述物理信息多粒度自注意力机制提取的特征 $\mathbf{Z}$ 进行赋值；$\mathcal{V}_d$ 则代表潜在的损伤位置，其初始特征设为零向量。异构图的边集 $\mathcal{E}$ 严格遵循声束覆盖的物理原理加以定义：仅当虚拟损伤节点 v_j^d 位于物理节点 v_k^p 所对应的声束主覆盖区域 $\mathcal{S}_k$ 内时，二者之间方才建立连接。据此，边集 $\mathcal{E}$ 可形式化表示为：

$$\mathcal{E} = \left\{ (v_k^p, v_j^d) \mid \forall k \in [1, N_p], \forall j \in \mathcal{S}_k \right\} \tag{30}$$

为量化不同虚拟损伤节点对测量路径的贡献差异，本研究构建了边权重度量函数。设第 k 个探头对的主声轴直线为 L_k，其端点分别为 T_k^{src} 与 T_k^{rcv}。定义主声轴 L_k 的垂直距离 $d_{kj}^{\perp}$ 不大于波束半宽 r 的区域为该探头有效探测范围 $\mathcal{S}_k$，在此范围内的虚拟损伤节点 v_j^d 可能对探头对 $\mathcal{K}_k$ 的测量产生影响：

表 1 物理测量节点与虚拟损伤节点的异构图构建算法伪代码

算法 1：物理测量节点与虚拟损伤节点的异构图构建

输入：探头坐标集合 $\mathcal{T}=\{(x_m,y_m)\}$，探头对列表 $\mathcal{K}=\{(T_n^{\mathrm{src}},T_n^{\mathrm{rcv}})\}$，损伤探测区域 $\mathcal{A}\subset\mathbb{R}^2$，损伤网格数量 N_d，波束半宽 r

输出：异构图边集 $\mathcal{E}$

节点定义：

  将每个探头对 $(T_n^{\mathrm{src}},T_n^{\mathrm{rcv}})$ 定义为物理测量节点 v_k^p

  将区域 $\mathcal{A}$ 离散化为 N_d 个网格单元，每个单元定义为虚拟损伤节点 v_j^d

边集计算：

  $\mathcal{E}\leftarrow\varnothing$

  for 每个探头对 $k=1$ 到 N_p ***do***

    $(x_{\mathrm{src}},y_{\mathrm{src}})\leftarrow T_k^{\mathrm{src}},(x_{\mathrm{rcv}},y_{\mathrm{rcv}})\leftarrow T_k^{\mathrm{rcv}}$

    $L_k\leftarrow\mathrm{LineSegment}((x_{\mathrm{src}},y_{\mathrm{src}}),(x_{\mathrm{rcv}},y_{\mathrm{rcv}}))$

    $\mathcal{D}_k\leftarrow\mathrm{GenerateParallelLines}(L_k,r,\Delta d)$

    $\mathcal{S}_k\leftarrow\varnothing$

    for 每条探测线 $D_i\in\mathcal{D}_k$ ***do***

      for 每个损伤节点 v_j^d ***do***

        if D_i 与 v_j^d 对应的网格单元相交 ***then***

          $\mathcal{S}_k\leftarrow\mathcal{S}_k\cup\{j\}$

        end if

      end for

    end for

    $\mathcal{S}_k\leftarrow\mathrm{Unique}(\mathcal{S}_k)$

    for 每个 $j\in\mathcal{S}_k$ ***do***

      $\mathcal{E}\leftarrow\mathcal{E}\cup\{(v_k^p,v_j^d)\}$

    end for

  end for

return $\mathcal{E}$

$$r_{kj}=\mathbb{I}\left(d_{kj}^{\perp}\le r\right) \tag{31}$$

其中 $\mathbb{I}(\cdot)$ 为指示函数，当条件成立时取值为 1，否则为 0。将节点排序为物理测量节点在前、虚拟损伤节点在后，则整体邻接矩阵 $\mathbf{A}\in\mathbb{R}^{(N_p+N_d)\times(N_p+N_d)}$ 具有分块稀疏结构：

$$\mathbf{A}=\begin{bmatrix}\mathbf{0}_{N_p\times N_p} & \mathbf{R}\\ \mathbf{0}_{N_d\times N_p} & \mathbf{0}_{N_d\times N_d}\end{bmatrix} \tag{32}$$

具体边集构造算法详见表 1 的算法，将此邻接矩阵 A 和零填充后的节点向量 Z' 应用于式(11)的前向传播公式，可实现先验物理机制上的散射源强度隐式求解。经过多次迭代更新，节点特征 $\mathbf{H}$ 中逐步编码了损伤位置与强度信息的隐式表征。

2.5 基于物理异构图神经网络的板材损失定位框架

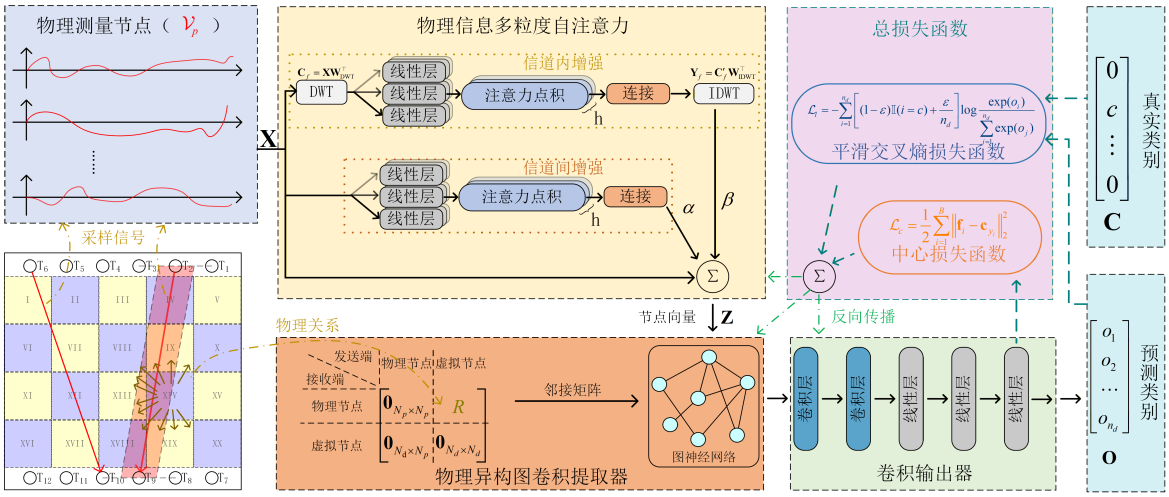


图 3 基于物理异构图神经网络的板材损失定位框架

基于前述的物理信息多粒度自注意力机制与物理异构图卷积提取器，本研究构建了一种面向复合板材的损伤定位深度学习网络。其具体训练流程如表 2 所示，网络总体架构如图 3 所示。该网络能够充分融合多源监测信息的时空特征，从而显著提升超声导波板材损伤定位的准确性与泛化能力。完整的损伤定位流程包含以下几个步骤：

1）数据采集与预处理：从部署于板材表面的多通道超声波换能器阵列中采集原始导波监测数据，随后对信号依次执行异常值剔除与同步对齐等预处理操作，以形成满足模型输入要求的规范化信号样本。

2）物理信息多粒度自注意力特征提取：将预处理后的传感器序列输入物理信息多粒度自注意力模块。该模块融合卷积结构与注意力机制，深入捕获信号序列内部的依赖关系及退化趋势特征，进而提取出传感器节点的高维时序表示。

3）物理异构图卷积信息传播与散射源反演：通过物理异构图卷积分类器，在预先构建的异构边集约束下进行信息传播。该异构边集由物理测量节点与虚拟损伤节点两类节点连接而成。在图卷积层的模拟扩散过程中，信息由测量节点沿预设的物理连接路径定向传播至虚拟损伤节点，并逐步更新后者的特征表示。这一过程在先验物理特征的约束下，实现了从观测信号到散射源分布的反向推理。

4）损伤类别映射与定位输出：卷积分类器将更新后的虚拟损伤节点特征图作为输入，经一维卷积层进一步提取深层特征，最终由全连接层映射为损伤类别的概率预测 $\mathbf{O}$，并输出最终预测类别 $\hat{\mathbf{y}} = \arg\max_i \mathbf{O}_i$。

表 2 物理异构图神经网络方法训练流程算法伪代码

算法 2：物理异构图神经网络方法训练流程

输入：带标签训练数据集 $\{\mathbf{X}, y\}$，探头物理参数 $\{\mathcal{T}, \mathcal{K}, r\}$，损伤探测参数 $\{\mathcal{A}, N_d\}$，小批量大小 B，学习率 η_t，平滑因子 z，超参数 δ，迭代轮数 T

输出：训练完成的模型参数 θ_T

初始化模型参数 θ_0

构建小波变换矩阵 $\mathbf{W}_{\mathrm{DWT}}$，并计算逆变换矩阵 $\mathbf{W}_{\mathrm{IDWT}} = \mathbf{W}_{\mathrm{DWT}}^{-1}$

依据表 1 的算法计算异构图边集 $\mathcal{E}$

for 迭代轮数 $\mathrm{iter} = 1$ ***to*** T ***do***

  for 每个小批量数据 ***do***

    根据式(19)至(20)计算通道内增强特征 $\mathbf{Y}_{\mathrm{time}}$

    计算离散小波变换 $\mathbf{C}_{\mathrm{freq}} = \mathbf{X}_b \mathbf{W}_{\mathrm{DWT}}^{\top}$ 增强特征后，按式(25)进行逆变换 $\mathbf{Y}_{\mathrm{freq}}$

    根据式(26)融合两分支并引入残差连接：$\mathbf{Z} = \mathbf{X}_b + \alpha \cdot \mathbf{Y}_{\mathrm{time}} + \beta \cdot \mathbf{Y}_{\mathrm{freq}}$

    将增强特征 $\mathbf{Z} \in \mathbb{R}^{B \times N_p \times L}$ 零填充为 $\mathbf{Z}' \in \mathbb{R}^{B \times (N_p + N_d) \times L}$

    将 $\mathbf{Z}'$ 与图 $\mathcal{G} = \{\mathcal{V}, \mathcal{E}\}$ 输入图卷积层，根据式(11)计算更新后的节点特征 $\mathbf{H}$

    对 $\mathbf{H}$ 执行卷积操作，并经全连接层映射为类别预测概率 $\mathbf{O}$

    获取预测类别：$\hat{\mathbf{y}} = \arg\max_i \mathbf{O}_i$

    根据式(34)计算标签平滑交叉熵损失 $\mathcal{L}_l$

    根据式(35)计算中心损失：$\mathcal{L}_c = \frac{1}{2} \sum_{i=1}^{B} \| \mathbf{f}_i - \mathbf{c}_{y_i} \|_2^2$

    根据式(33)计算总损失：$\mathcal{L} = \mathcal{L}_l + \delta \cdot \mathcal{L}_c$

    计算梯度 $\nabla_\theta \mathcal{L}$，并采用 Adam 优化器更新模型参数

  end for

end for

return θ_T

为引导模型原始阵列信号 $\mathbf{X}$ 中准确推断损伤类别，本研究设计了一个联合优化目标，包含标签平滑交叉熵损失 $\mathcal{L}_l$ 和中心损失 $\mathcal{L}_c$。总损失函数定义为：

$$\mathcal{L} = \mathcal{L}_l + \lambda \mathcal{L}_c \tag{33}$$

其中 λ 为平衡两类损失贡献的超参数。传统的交叉熵损失采用独热标签，容易导致模型对训练样本过度自信，降低泛化能力。为缓解这一问题，引入了标签平滑技术，构造平滑后的标签分布。对于真实类别为 c 的样本，模型输出层第 i 类的逻辑值为 o_i，则 $\mathcal{L}_c$ 可统一表示为：

$$\mathcal{L}_l = -\sum_{i=1}^{n_d}\left[(1-\varepsilon)\mathbb{I}(i=c)+\frac{\varepsilon}{n_d}\right]\log\frac{\exp(o_i)}{\sum_{j=1}^{n_d}\exp(o_j)} \tag{34}$$

其中ε为平滑因子，$\mathbb{I}(\cdot)$为指示函数，当$i=c$时取 1，否则为 0。该损失函数促使模型输出概率分布更加平滑，避免过拟合，从而提升对未知工况的泛化能力。

为进一步增强特征的可判别性，引入了中心损失函数，其通过最小化样本特征与其对应类别中心之间的距离，使得同一损伤类别的特征在嵌入空间中更加聚集：

$$\mathcal{L}_c = \frac{1}{2}\sum_{i=1}^{B}\left\|\mathbf{f}_i-\mathbf{c}_{y_i}\right\|_2^2 \tag{35}$$

其中B为批大小，$\mathbf{f}_i\in\mathbb{R}^d$为分类器倒数第一层输出的特征向量，$\mathbf{c}_{y_i}$为第$y_i$类的特征中心。

模型采用 Adam 优化器进行端到端训练，初始学习率设为1×10^{-3}，中心损失平衡系数$\lambda=0.01$。学习率采用余弦退火策略动态调整，以稳定收敛并提升泛化性能。通过最小化联合损失$\mathcal{L}$，模型能够在先验物理特征与监测数据特征的共同引导下，学习到具有强判别力与泛化性能的损伤特征，从而实现高精度的损伤定位。

三、存在的问题和拟解决方法

3.1 常规图卷积网络在导波相位特征提取中的局限性

在阵列超声导波检测中，各通道信号间的相位关系承载着损伤空间定位的关键信息。设激励信号的频谱为$S(\omega)$，则由第l个探头r_l激励、第j个探头r_j接收的信号频谱$X_{lj}(\omega)$可表示为：

$$X_{lj}(\omega)=S(\omega)\cdot G(r_l,r_j,\omega) \tag{36}$$

其中，$G(r_l,r_j,\omega)$为介质中的格林函数。相应的传递函数定义为：

$$H_{lj}(\omega)=\frac{X_{lj}(\omega)}{S(\omega)}=G(r_l,r_j,\omega)\approx\frac{C(\omega)}{\sqrt{k(\omega)d_{lj}}}\cdot e^{-\alpha(\omega)d_{lj}}\cdot e^{i\left(k(\omega)d_{lj}-\frac{\pi}{4}\right)}\triangleq\Gamma_{lj}(\omega),e^{i\phi_{lj}(\omega)} \tag{37}$$

式中，$k(\omega)$为波数；$C(\omega)$表征与频率相关的幅值因子；$\alpha(\omega)$为材料衰减系数；d_{lj}为收发探头间距；常数项$\pi/4$源自二维格林函数的远场渐近展开。$\Gamma_{lj}(\omega)$与$\phi_{lj}(\omega)$分别代表幅值衰减因子与相位延迟。鉴于实际检测通常采用宽带脉冲激励，接收信号本质上是各频率分量响应的线性叠加，其相位谱中蕴含了损伤位置与传播路径的丰富信息。

传统图卷积网络通常基于实值图拉普拉斯矩阵构建卷积算子，其层间传播规则如式(10)所示。尽管上述架构在图节点特征聚合与扩散建模方面表现优异，但因其图拉普拉斯算子的构造仅依赖实值邻接关系，故本质上忽视了信号在波导中传播时由

频率决定的相位延迟效应。由式(37)可知，不同频率分量在跨越相同空间距离 d_{ij} 时，将经历不同的相位偏移 $\phi_{ij}(\omega)=k(\omega)d_{ij}-\pi/4$。这一频率–相位耦合特性意味着，传感器阵列各通道间的信息交互不仅取决于空间拓扑连接，更显著地依赖于信号频域成分的具体分布。然而，常规图神经网络所采用的图移位算子 $\widetilde{\mathbf{D}}^{-1/2}\widetilde{\mathbf{A}}\widetilde{\mathbf{D}}^{-1/2}$ 为实对称矩阵，其特征分解仅能刻画实值信号在图上的平滑扩散过程，缺乏对复数域中相位旋转及频率选择性传播行为的编码能力。因此，将传统图神经网络直接应用于多通道导波信号处理将面临以下两方面的固有局限：

1. 相位信息丢失：图卷积网络对节点特征的聚合本质上是实值加权求和，这一操作在复数域中等价于仅对幅值进行调制而忽略相位旋转，导致通道间精细的时延与相干结构无法被有效捕捉。

2. 频率混叠与分辨率受限：宽带激励下，不同频率的相位响应在图卷积网络的单一实值聚合框架下发生混叠，限制了网络对多模态频散特征的解耦能力。

因此为实现对导波阵列信号中隐含的损伤散射信息的充分挖掘，有必要在传统图卷积结构的基础上引入复数域表示或频域自适应机制，使网络能够同时感知幅值衰减与相位延迟，从而提升对损伤位置与程度的反演精度。

3.1.1 图希尔伯特变换

为在不额外增加网络监督负担的前提下，赋予图神经网络对信号瞬时相位特征的感知能力，本课题拟引入希尔伯特变换作为图信号预处理与结构化先验嵌入的关键环节。在经典信号处理理论中，希尔伯特变换提供了构建解析信号、提取瞬时幅值与瞬时相位的数学框架。其时域定义为主值积分形式的卷积运算：

$$\mathcal{H}[x(t)]=x(t)*\frac{1}{\pi t}=\frac{1}{\pi}\int_{-\infty}^{+\infty}\frac{x(\tau)}{t-\tau}\mathrm{d}\tau \tag{38}$$

尽管变换算子本身作用于实信号空间，其实质在于通过卷积核 $1/(\pi t)$ 引入一个 $\pm\pi/2$ 的正交相位偏移。由此构成的复解析信号在不丢失物理可观测能量信息的前提下，将一维实信号嵌入二维复平面，从而赋予了信号明晰的瞬时幅值包络与瞬时相位演化轨迹：

$$z(t)=x(t)+j\mathcal{H}[x(t)]\triangleq A(t)e^{j\phi(t)} \tag{39}$$

其中，瞬时相位 $\phi(t)$ 的微分特性与波达时刻紧密相关，恰好对应导波检测中损伤散射波包的到达时间与群延迟信息。

然而，上述经典定义严格依赖于连续时间变量 t 下的傅里叶变换性质，无法直接应用于定义在离散、不规则传感器拓扑图结构上的阵列信号。为将时频域中的正交移相思想推广至图信号处理领域，需借助图傅里叶变换在图谱空间中构建等效的频率相关相位偏移操作。

具体而言，传统傅里叶变换中的复指数基函数 $e^{j\omega t}$ 在图域被图拉普拉斯矩阵 $\mathbf{L}$ 的特征向量 $\mathbf{U}$ 所替代。对于定义在图节点上的实信号 $\mathbf{x}\in\mathbb{R}^N$，其图傅里叶变换为 $\hat{\mathbf{x}}=\mathbf{U}^\top\mathbf{x}$。为了在谱域实现类似希尔伯特变换的 90° 相位滞后，需构造一个依赖于图谱虚部符号的移相算子。为此，本课题将式(8)中的特征值矩阵 $\mathbf{\Lambda}=\mathrm{diag}(\lambda_1,\lambda_2,\cdots,\lambda_n)$ 替换为基于特征值虚部极性定义的复数对角矩阵 $\widehat{\mathbf{H}}$：

$$\widehat{\mathbf{H}}[k,k]=\begin{cases}-j & ,\mathrm{Im}(\lambda_k)>0\\ 0 & ,\mathrm{Im}(\lambda_k)=0\\ j & ,\mathrm{Im}(\lambda_k)<0\end{cases} \tag{40}$$

该定义调整各路信号的相位，基于此谱域核函数，定义在图上的信号 $\mathbf{x}$ 的图希尔伯特变换可严格表述为其在图傅里叶基下的谱域加权与逆变换过程：

$$\mathcal{H}[\mathbf{x}]=\mathbf{U}\widehat{\mathbf{H}}\mathbf{U}^\top\mathbf{x} \tag{41}$$

通过式(41)构造希尔伯特图卷积神经网络：

$$\tilde{\mathbf{x}}=\mathbf{x}+j\mathcal{H}[\mathbf{x}]=\mathbf{U}(\mathbf{I}+j\widehat{\mathbf{H}})\mathbf{U}^\top\mathbf{x} \tag{42}$$

相比于式(11)图卷积神经网络，该方案表示能够将式(37)中隐含的频率-相位耦合关系显式地表征于图节点特征中。

3.2 下一步工作计划

3.2.1 复数特征嵌入与相位感知图网络融合

为弥补传统实值图卷积网络在导波相位特征提取中的不足，后续研究将图希尔伯特变换输出的复解析信号 $\widetilde{\mathbf{X}}=\mathbf{X}+j\mathcal{H}[\mathbf{X}]$ 无缝嵌入深度图网络架构，探索两条技术路径：一是复值图卷积网络集成，即将复数特征直接输入复值图卷积层，利用复数权重矩阵在前向传播中同时调制幅值与相位，使邻域聚合过程能自然区分同相叠加与反相抵消；二是构建相位注意力图变换器，在注意力得分中引入相位差余弦项作为偏置，使模型优先关注具有稳定相位关系的节点对。该融合策略将导波传播的物理相位约束显式编码进网络计算，预期可显著增强对损伤微小扰动引起的相位异常检测灵敏度，为高准确率损伤定位提供更坚实的算法基础。

3.2.2 对比实验设计与有效性验证

为系统评估所提框架的性能优势，后续将设计多维对比实验：选取传统时频方法、纯数据驱动深度模型及若干消融变体作为基线，以损伤定位准确率、F1 分数及抗噪泛化性为核心定量指标，在复合材料层合板数据集上进行统一评估。同时辅以注意力权重热力图等定性分析手段，从机理层面验证物理先验嵌入与相位感知机制对多模态频散条件下损伤特征解耦的实际贡献。通过上述实验，预期可充分证明所提方法在定位精度、鲁棒性与物理可解释性方面的综合优势。

指导教师意见 是否同意参加中期检查答辩：☐同意　☐不同意 指导教师签字：
考核组长意见 是否通过中期检查：☐通过　☐不通过 考核组长签字（章）：
中期检查分数：
系级教学单位审核意见 系主任签字（章）： 年　月　日

燕 山 大 学

本科毕业设计（论文）中期检查

英文文献阅读与翻译

课题名称: 基于深度图神经网络的板状结构超声损伤定位方法

学　　号: 202211030001

年级专业: 22 级检测技术及仪器

学生姓名: 游寅龙

指导教师: 2026 年 04 月 18 日

英文文献 1	
文献信息	Ma J, Zhao S, Yang Z, et al. MCAGN: Multi-layer Coupled Attention Graph Networks for Composites Damage Detection[J]. IEEE Sensors Journal, 2025.
英文题目	MCAGN: Multilayer Coupled Attention Graph Networks for Composites' Damage Detection
英文摘要	Damage detection in carbon-fiber-reinforced polymer (CFRP) composites is essential for maintaining structural integrity and preventing catastrophic accidents. Recently, machine-learning-based damage detection methods have garnered increasing attention. However, existing approaches often face challenges in extracting relational information about damage, both within guided wave paths and between damage samples. These limitations result in insufficient detection stability under varying training sample conditions and increase the risk of model overfitting when relying solely on high-dimensional information extracted from guided wave signals. To address these challenges, this article proposes a multilayer graph network with a coupled attention mechanism based on feature fusion. In the proposed method, by encoding sensor coordinates and fusing guided wave signal features, positional information can be integrated into the guided wave signals. A multilayer graph network is further used to extract signal features, while the interlayer coupled attention mechanism and multilayer graph construction fully explore the relational information associated with the damage. Experimental datasets collected from real CFRP composites demonstrate the effectiveness of the proposed method. Comparative results show that the multilayer graph neural network (GNN) achieves superior stability and accuracy, even with limited training samples and noisy training samples.
中文题目	MCAGN：用于复合材料损伤检测的多层耦合注意力图网络
中文摘要:	碳纤维增强聚合物（CFRP）复合材料的损伤检测对保障结构完整性、防止灾难性事故至关重要。近年来，基于机器学习的损伤检测方法日益受到关注。然而，现有方法在提取损伤相关关系信息方面仍面临挑战，既难以刻画导波传播路径内部的损伤关联，也难以建模不同损伤样本之间的关联。这些局限导致模型在训练样本数量或质量变化时检测稳定性不足，且若仅依赖从导波信号中提取的高维特征，则更易发生过拟合。为应对上述问题，本文提出一种基于特征融合的多层图网络，并引入层间耦合注意力机制。该方法通过编码传感器空间坐标并融合导波信号特征，将位置信息嵌入导波信号；再借助多层图网络提取信号特征，同时利用层间耦合注意力机制与多层图构建策略，充分挖掘与损伤相关的各类关系信息。在真实 CFRP 复合材料采集的实验数据集上验证了所提方法的有效性。对比结果表明，所提出的多层图神经网络（GNN）即便在训练样本有限或存在噪声的情况下，仍能保持优异的检测稳定性和精度。
文献理解	该文献创新的将多层图结构与层间耦合注意力机制相结合，既建模单个损伤内各导波路径间的内部关联，又挖掘不同损伤样本间的外部共性；同时引入高斯坐标映射实现传感器位置信息与信号特征的深度融合，有效缓解高维特征导致的过拟合，显著提升小样本与噪声下的泛化能力与鲁棒性。

英文文献 2	
文献信息	Zhao Y, Tang D, Ding C, et al. TFA_Net: A Time-Frequency Attention Network for Enhancing Defect Recognition and Noise Robustness in Ultrasonic Guided Wave Pipeline Inspection[J]. International Journal of Pressure Vessels and Piping, 2025: 105735.
英文题目	TFA_Net: A time-frequency attention network for enhancing defect recognition and noise robustness in ultrasonic guided wave pipeline inspection
英文摘要	Ultrasonic guided wave-based pipeline defect detection is crucial for achieving efficient and cost-effective structural health monitoring of pipelines. However, signal attenuation and noise interference during wave propagation severely hinder the accurate identification of defect signals. To address this challenge, a Time- Frequency Attention Network (TFA_Net) is proposed, integrating time-frequency domain signal processing with deep learning techniques to improve defect recognition accuracy and enhance noise robustness in ultrasonic guided wave signals. First, the Ultrasonic Guided Wave Defect Dataset (UGW-Dataset) was established, including experimental and simulated data, covering cracks and corrosion defects of various sizes and shapes. Next, a time- frequency attention block (TFA_Block) was designed in TFA_Net to perform multi-scale feature extraction in both time and frequency domains, enabling effective capture of global and local characteristics of defect signals. Experimental results demonstrate that TFA_Net achieves a defect recognition accuracy of 99.4 % on the UGW-Dataset, confirming its exceptional feature extraction and defect recognition capabilities. Furthermore, TFA_-Block significantly enhances the robustness of TFA_Net within the signal-to-noise ratio (SNR) range from 40 dB to 10 dB, effectively mitigating the negative impact of noise on recognition accuracy. This study provides an efficient and noise-resilient approach for defect recognition in pipeline structural health monitoring (SHM).
中文题目	TFA_Net：一种面向超声导波管道检测的时频注意力网络，用于提升缺陷识别精度与抗噪能力
中文摘要:	基于超声导波的管道缺陷检测对实现高效、低成本的管道结构健康监测至关重要。然而，导波传播过程中的信号衰减与噪声干扰严重阻碍了缺陷信号的准确识别。为应对这一挑战，本文提出一种时频注意力网络（TFA_Net），将时频域信号处理与深度学习技术相结合，以提升缺陷识别精度并增强超声导波信号的抗噪能力。首先，构建了超声导波缺陷数据集（UGW-Dataset），涵盖实验与仿真数据，覆盖多种尺寸与形状的裂纹与腐蚀缺陷；其次，在 TFA_Net 中设计了时频注意力模块（TFA_Block），在时域与频域同步执行多尺度特征提取，从而有效捕获缺陷信号的全局与局部特征。实验结果表明，TFA_Net 在 UGW-Dataset 上实现了 99.4%的缺陷识别准确率，验证了其卓越的特征提取与缺陷识别能力；此外，TFA_Block 显著提升了 TFA_Net 在信噪比（SNR）为 40 dB 至 10 dB 范围内的鲁棒性，有效缓解了噪声对识别精度的负面影响。本研究为管道结构健康监测（SHM）中的缺陷识别提供了一种高效且抗噪的解决方案。

文献理解	该文献将时频注意力模块和频域增强机制融合在 CNN-Transformer 混合架构中，频域增强机制通过 FFT-可学习频带选择-IFTT 实现物理意义明确的频域注意力，GW-MSA 提升全局建模效率，显著增强导波信号在噪声下对裂纹、腐蚀等缺陷的判别能力。

英文文献 3	
文献信息	Sun L, Song R, Wei J, et al. Physics-Augmented Spatial-Temporal graph convolutional network for damage localization using Ultrasonic guided waves[J]. Mechanical Systems and Signal Processing, 2024, 221: 111738.
英文题目	Physics-Augmented Spatial-Temporal graph convolutional network for damage localization using Ultrasonic guided waves
英文摘要	Structural health monitoring technology based on ultrasonic guided waves (UGW) is a potential application for damage detection in plate-like composite structures. This paper introduces a novel physics-augmented spatial–temporal graph convolutional network (P-STGCN) for the damage detection task in composite plate. Firstly, the graph topology containing edge weight attributes is constructed based on the spatial correlation of the sensors and the UGW scattering principle, which strengthens the expression of the data spatial information of the data. Then, a spatial feature extractor and a temporal feature extractor are constructed based on graph convolutional network and convolutional neural network, respectively. Further, the spatial–temporal fusion method is proposed for the first time in the field of UGW damage detection, which enables the perception of multi-level damage information. In addition, a sample compensation attention module based on wavefield scattering energy is designed to compensate for the samples' spatial distribution. Finally, a dataset was constructed in a composite plate containing only four sensors to evaluate the model's performance. The results show that the average localization error is 10.36 mm. Compared with other deep learning localization methods, the P-STGCN model is superior in both localization accuracy and computational resources.
中文题目	基于超声导波的物理增强型时空图卷积网络用于损伤定位
中文摘要:	基于超声导波（UGW）的结构健康监测技术在板状复合结构损伤检测中具有潜在应用价值。本文针对复合板中的损伤检测任务，提出一种新型物理增强型时空图卷积网络（P-STGCN）。首先，基于传感器的空间相关性和 UGW 散射原理构建包含边权重属性的图拓扑结构，强化了数据空间信息的表达。接着，分别基于图卷积网络和卷积神经网络构建空间特征提取器和时间特征提取器。进一步地，首次在 UGW 损伤检测领域提出时空融合方法，实现了多层次损伤信息的感知。此外，设计了一种基于波场散射能量的样本补偿注意力模块，用于补偿样本的空间分布。最后，构建了一个仅含四个传感器的复合板数据集以评估模型性能。结果表明，平均定位误差为 10.36 mm。与其他深度学习定位方法相比，P-STGCN 模型在定位精度和计算资源消耗方面均表现更优。
文献理解	本文献将物理先验嵌入时空图卷积网络，提出物理增强型图结构，依据 UGW 散射能量动态构建加权邻接矩阵，设计样本补偿注意力模块，融合波场散射能量实现空间分布自适应加权；并开创性地在 UGW 损伤定位中引入时空特征协同提取与融合机制，显著提升小传感器配置下的定位精度与可解释性。

英文文献 4	
文献信息	Xu X, Liu C. Physics-guided deep learning for damage detection in CFRP composite structures[J]. Composite Structures, 2024, 331: 117889.
英文题目	Physics-guided deep learning for damage detection in CFRP composite structures
英文摘要	Structural health monitoring of carbon fiber reinforced plastics composite structures based on deep learning usually builds on black box models for damage detection. However, the lack of physics knowledge limits its application into real-world problems where structural property or environmental condition varies. To overcome this limitation, we propose a physics-guided deep learning framework to integrate physics into data-driven models. This physics-guided convolutional neural network leverages structural degradation trend and physical consistency by combining the output of the physical model with the observed feature in a hybrid model. This hybrid model uses an additional branch to observe the information of stiffness degradation, which is the input into the physical model to describe the damage growth in structures by establishing a relationship with the power spectral density change in the guided wave signals. Additionally, the physics-based loss function is designed as part of the learning objective to ensure the model outputs satisfy the existing physics and maintain physical consistency. Experiment results show that our method demonstrates great generalizability that by training on data of only one particular CFRP composite structure, the PGCNN model can expand its great performance on all other CFRP layups in the NASA-published CFRP Dataset with over 90% accuracy.
中文题目	CFRP 复合结构损伤检测中的物理引导深度学习
中文摘要:	基于深度学习的碳纤维增强塑料复合结构健康监测通常依赖黑箱模型进行损伤检测。然而，缺乏物理知识限制了其在结构属性或环境条件变化的真实问题中的应用。为克服这一局限，我们提出一种物理引导的深度学习框架，将物理知识融入数据驱动模型。该物理引导卷积神经网络通过在混合模型中结合物理模型输出与观测特征，利用结构退化趋势和物理一致性。该混合模型使用额外分支观测刚度退化信息，作为物理模型的输入，通过建立其与导波信号中功率谱密度变化的关系来描述结构中损伤的增长。此外，设计基于物理的损失函数作为学习目标的一部分，确保模型输出符合现有物理规律并保持物理一致性。实验结果表明，我们的方法展现出强大的泛化能力：仅在一个特定 CFRP 复合结构的数据上训练，PGCNN 模型即可在 NASA 发布的 CFRP 数据集中所有其他 CFRP 铺层上均实现超过 90%的准确率。
文献理解	本本文献将 CFRP 刚度退化趋势与导波功率谱密度变化的物理关系，通过双分支网络架构和基于物理的损失函数深度嵌入深度学习框架，实现端到端的物理引导训练，在仅用单一铺层数据训练下即获得强跨结构泛化能力，显著提升模型可解释性与工程适用性。

英文文献 5	
文献信息	Liu C, Chen Y, Xu X, et al. Domain generalization-based damage detection of composite structures powered by structural digital twin[J]. Composites Science and Technology, 2024, 258: 110908.
英文题目	Domain generalization-based damage detection of composite structures powered by structural digital twin
英文摘要	This research addresses the challenge of generalizing deep learning models for different CFRP composite structures in the task of fatigue damage detection. To overcome this challenge, knowledge distillation is employed to enhance the generalizability of deep learning models. A teacher network processes continuous wavelet transform images using Fourier transform and neural networks, while a student network distills the teacher network. This framework improves the models' generalization performance by transferring knowledge from the teacher network to the student network. Additionally, soft gradient boosting is utilized to further enhance the generalizability. By constructing a main sub-network and multiple parallel auxiliary sub-networks within the teacher network, the student network mimics the main sub-network to achieve improved accuracy in the target domain and prevent overfitting. To augment limited datasets of real CFRP monitoring signals and help to learn domain-invariant features, structural digital twin technology is leveraged to generate simulated monitoring signals, which enables the models to capture domain invariant information, significantly enhancing its performance of fatigue damage detection across different structures. Damage detection based on the gener-alization results between multiple Layups demonstrates a test accuracy exceeding 80 % when the monitoring data of the target CFRP structure is unavailable during training. Therefore, the cross-structure damage detection ability of the proposed approach is well proved.
中文题目	基于结构数字孪生的复合结构域泛化损伤检测
中文摘要:	本研究针对在不同 CFRP 复合结构之间进行疲劳损伤检测时深度学习模型泛化能力的挑战。为克服这一挑战，采用知识蒸馏来增强深度学习模型的泛化能力。教师网络使用傅里叶变换和神经网络处理连续小波变换图像，学生网络则从教师网络中蒸馏知识。该框架通过将知识从教师网络传递给学生网络，提升了模型的泛化性能。此外，利用软梯度提升进一步增强泛化能力。通过在教师网络中构建主子网络和多个并行辅助子网络，学生网络模仿主子网络，从而在目标域中提高准确性并防止过拟合。为了扩充有限的真实 CFRP 监测信号数据集并帮助学习域不变特征，利用结构数字孪生技术生成模拟监测信号，使模型能够捕捉域不变信息，显著提升在不同结构间的疲劳损伤检测性能。基于多铺层间泛化结果的损伤检测表明，在训练过程中目标 CFRP 结构的监测数据不可用时，测试准确率仍超过 80%。因此，所提方法的跨结构损伤检测能力得到了充分验证。
文献理解	该文献将结构数字孪生与域泛化深度融合，构建了基于知识蒸馏与集成学习的 DGDT 框架；利用 FEM 驱动数字孪生生成高保真模拟信号，弥补真实数据稀缺，强化域不变特征学习，并通过傅里叶相位约束与软梯度提升机

	制，显著提升模型跨 CFRP 铺层结构的泛化能力与可解释性。。